识海：融合人格心理学的 QQ 数字生命耦合动力系统

—— 基于 AstrBot 的多插件仿生认知架构

第二十届全国大学生软件创新大赛 · 面向移动终端的系统级智能体验

识海项目组 · 大连理工大学软件学院

2026 年 11 月

摘要

本文提出"识海"架构，把一个长期陪伴的 QQ 数字生命建模为耦合动力系统

z(t) = [e(t), a(v,t), θ(t), ψ, u(t), g(t)],

其中 e 为六维情绪场、a(v,t) 为神经图谱节点激活、θ 为可在线学习的慢参数、ψ 为大五人格特质、u 为主动开口的念头强度、g 为顶层内生目标向量。架构以"**动机动力学与语言生成解耦**"为第一原则：独立的确定性状态系统负责"何时说、为何说"，大模型仅负责"怎么说"。

系统在工程上已重构为**六个职责单一的识海插件**（核心、行为与适配、心理、守护、信使、工具件），通过数据契约协作。核心机制包括：神经图谱扩散激活替代扁平向量检索；事实/事件/核心三桶按艾宾浩斯保持率分桶衰减（半衰期 15/30/90 天）；Hebbian 边权自学习实现零 LLM 记忆管线；六类心理学模型在状态空间中找到可观测落点；念头累积叠加由头锚点与"自我许可"门控，驱动可解释的主动开口；用户反馈驱动 θ 在线自适应；目标向量 g 驱动内生行为倾向；探索—利用平衡与有界三层慢演化使行为先验可自我调整。

在表达侧，本文给出性格层/心情层正交的双层表达模型与提示词瘦身路线；在一致性侧，把记忆错乱、上下文割裂、人格分裂、行动割裂四类故障形式化为可计数判据，对应四条运行期不变量（时序单调、通道隔离、表达归界、解释权唯一），融合"写入侧净化—检索侧拦截—生成侧归界—行动侧在场—生成后校验"五道防线。离线仿真 **11 组数值检查全部通过**，综合故障率由 1.540 降至 0.065（降幅 95.8%）。生活任务层把短信快递做成可闭环的确定性状态机，与动力学共用同一份状态快照。文末如实标注未实现项与外部效度边界。

关键词：数字生命；耦合动力学；人格心理学；主动行为；一致性守护；生活任务

目录

1. 引言
2. 问题定义、研究边界与理论依据

3. 符号说明
4. 系统总览与多插件架构
5. 耦合动力学：情绪场、念头与自我调节
6. 记忆系统：神经图谱、分层融合与数据净化
7. 人格心理学建模
8. 行为空间、策略选择与自演化
9. 表达层：意图包与双层模型
10. 一致性守护
11. 生活任务层：从短信到闭环
12. 上下文闭合
13. 数值自洽性验证
14. 观测台与工程部署
15. 限制、伦理与外部效度
16. 结论

第 1 章 引言

1.1 从单点问答到持续陪伴

主流陪伴 AI 把情绪、动机、人格全部交给大模型隐状态：同一句话换一个会话就可能换一种心情；主动行为由提示词或定时器触发，既不可控，也无法解释"为什么此刻主动"。其根本原因是**把两件不同的事压在了同一个模型里**——"何时说、为何说"的动机决策，与"怎么说"的语言生成。

识海把前者从语言生成中拆出来，交给一个独立的、可观测的时序状态系统；大模型退到表达层，只负责把已经决定的意图组织成自然语言。这条分界线带来三个直接后果：

1. **情绪可以跨会话残留**：情绪是带弛豫时间的连续变量，不被单轮对话重置；
2. **记忆可以差异化衰减**：不同类型、不同重要度、不同情绪色彩的记忆以不同速率消退；
3. **每个自发动作都可回溯**：能指回具体的情绪、记忆、念头或任务来源，而不是黑箱输出。

1.2 本文的组织方式

第 2—3 章定义问题、理论边界与符号；第 4 章给出多插件系统总览；第 5—8 章给出情绪、记忆、人格、行为与演化的机制；第 9—12 章给出表达层、守护层、生活任务层与上下文闭合；第 13—14 章给出数值验证与工程部署；第 15—16 章讨论边界并收束结论。

1.3 主要贡献

1. 提出六分量耦合状态 $z(t)=[e,a,\theta,\psi,u,g]$，把情绪场、图谱激活、慢参数、人格、念头与目标写进同一组方程；
2. 把"念头越阈即发送"改为"**越阈且自我许可**"，用门控调节器解释"为什么现在说、为什么不是下一次"；
3. 把 **13 条注册行为与 52 个 LLM 工具**收进统一动作空间，并保留 24 类设计空间的可扩展口径；
4. 给出**多插件架构与数据契约**：六个职责单一的插件通过契约目录协作，动力学与平台解耦；
5. 新增生活任务层，把短信快递做成确定性状态机，与动力学共用一份状态快照；
6. 用 **11 组数值检查全部通过**与真实运行日志验证链路自洽，并把四类故障形式化为可计数、可回归的守护判据；
7. 给出会话隔离、记忆作用域与短上下文三处闭合机制，同时如实标注外部效度边界。

第 2 章 问题定义、研究边界与理论依据

2.1 形式化问题

给定用户消息流 $X=\{x_1,\ldots,x_n\}$、历史交互记忆 $M=\{(x_i,y_i,t_i)\}$、以及情境 C（时间、课表、地点、短信、设备状态），要求构建系统

$f : (X, M, C) \to (Y, e, a, T)$,

其中 Y 为回复序列，e(t) 为连续情绪状态，a(v,t) 为记忆激活状态，T 为生活任务状态。系统需同时满足：

- **(a) 情绪连续性**：e(t) 不随单轮跳变，跨会话保留残留；
- **(b) 记忆可累积**：新交互写入图谱，旧记忆按情感强度差异化衰减；
- **(c) 行为可解释**：每个自发动作可回溯到情绪、记忆、念头或任务来源；
- **(d) 记忆零 LLM 成本**：检索与衰减不调用大模型；
- **(e) 任务可闭环**：发现、确认、排期、提醒、回执、归档六个环节不丢状态。

2.2 与现有方案的差异

“强 LLM + Prompt + 向量记忆”方案能生成像样的句子，却难以回答：为什么此刻主动？为什么是这件事？为什么不是下一次？向量检索还需为全量记忆支付嵌入成本，且召回是互不相干的 top-k 切片。识海把动机、情绪、记忆与任务做成可读的时序变量，以神经图谱扩散获得“相关的一串记忆”而非孤立切片，并把语言生成降为表达层。

2.3 研究边界

本文**不宣称系统具备意识或主观体验。**心理学概念只作设计动机与功能类比，不作为系统模块名；代码与接口不按“本我—自我—超我”命名（如出现该映射，仅用于解释功能分层）。当前版本为单用户设计：私聊一人一会话；群聊在唯一会话键下把短上下文按“发送者_群号”隔离，长期事实以发送者为键归并，而内核 z(t) 与图谱仍是单一自我。多用户各自独立心智、多平台实例与独立手机端仍未实现。仿真只证明数值自洽与边界行为，不证明线上因果。

2.4 理论依据及其形式化落点

建模不是从零构造，而是从六个已有理论中各截取一部分，改写为可计算的时序变量。取舍标准有二：能否落成**不调用大模型的确定性更新**（指数衰减、加权求和、阈值比较、计数）；被截取部分能否对应到一个**可观测的量。**以下逐条说明“借用什么、放弃什么”，把放弃的部分写清楚，以免把“借用了理论的名字”当成“实现了那个理论”。

全篇总声明：文中心理学术语（防御、压抑、置换、投射、记忆干扰等）均作功能类比，其工程定义以具体触发条件与输出行为为准，不构成心理模块划分，也不能反过来用于推断用户心理。

2.4.1 艾宾浩斯保持率曲线

本节把艾宾浩斯遗忘曲线从"借用一个公式"展开为完整建模：经典形式 → 分桶衰减率标定 → 强度三因子 → 复习加固 → 离散实现。需要强调，我们借用的是其**函数形式**而非无意义音节实验的数值结论。

（1）经典形式。 保持率随时间"先快后慢"地指数下降，经典形式写为

$$R(\Delta t) = \exp\left(-\frac{\Delta t}{S}\right)$$

其中 S 为记忆强度（时间尺度），$R \in (0, 1]$，Δt 为距上次巩固的经过时间。

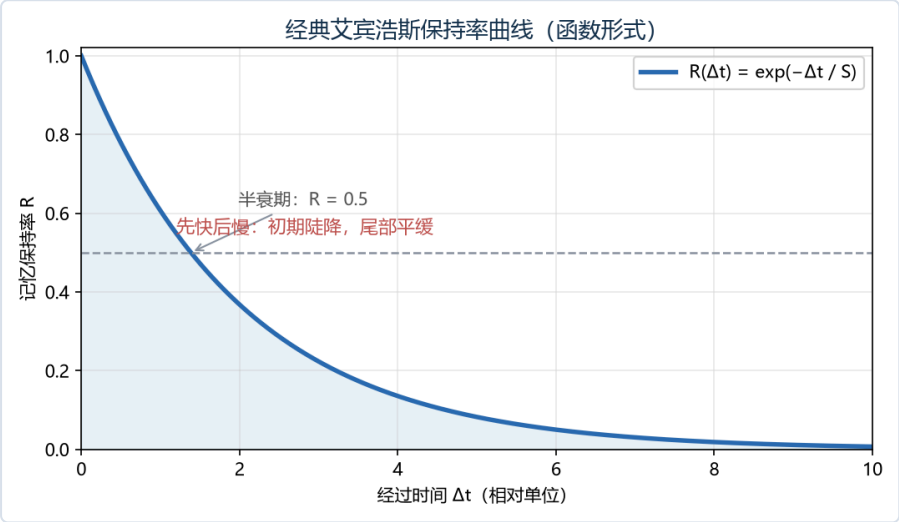


图 2-1　经典艾宾浩斯保持率曲线

（2）分桶推广与衰减率标定。 识海不使用单一 S，而是按事实 / 事件 / 核心三桶分别设定基础衰减率 λ，并引入强度倍数 S：

$$R(\Delta t) = \exp\left(-\frac{\lambda\,\Delta t}{S}\right)$$

基础衰减率与半衰期 $T_{1/2}$ 的关系由 $R(T_{1/2}) = 0.5$ 反解：当 $S = 1$ 时 $\lambda = \ln 2 / T_{1/2}$。三桶的工程标定半衰期与对应每小时衰减率如下（$\Delta t$ 以小时计）：

记忆桶	**半衰期 $T_{1/2}$**	**λ（每小时，$S = 1$）**
事实桶	15 天	1.93×10^{-3}
事件桶	30 天	9.63×10^{-4}
核心桶	90 天	3.21×10^{-4}

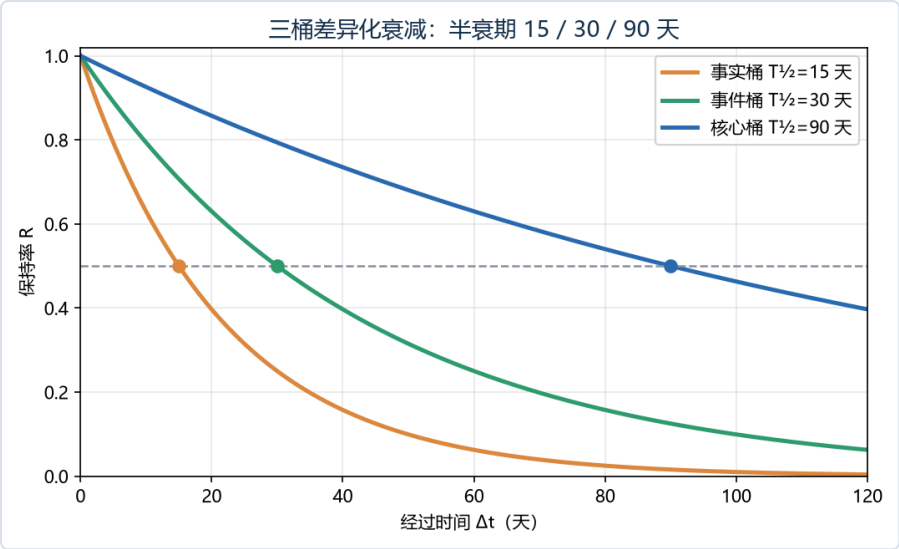


图 2-2　三桶差异化衰减（15 / 30 / 90 天）

（3）强度三因子。 记忆强度由重要度、情绪峰值、复习计数三个可观测因子相乘得到：

$$S = (1 + \beta \cdot imp)\,(1 + \alpha_E E_v)\,(1 + \beta_N N_{recall})$$

其中 imp 为重要度自评、E_v 为事件情绪峰值、N_{recall} 为跨天复习计数。S 越大，等效衰减率 λ/S 越小，等效半衰期被拉长。

（4）复习加固。 每发生一次跨天复习，N_{recall} 增大、S 抬升，曲线在复习点重新抬高且后续衰减变慢（图 2-3）。这正是间隔重复（spaced repetition）在状态空间中的计算表达，也与 2.4.2 的 Hebbian “用进废退”相互呼应。

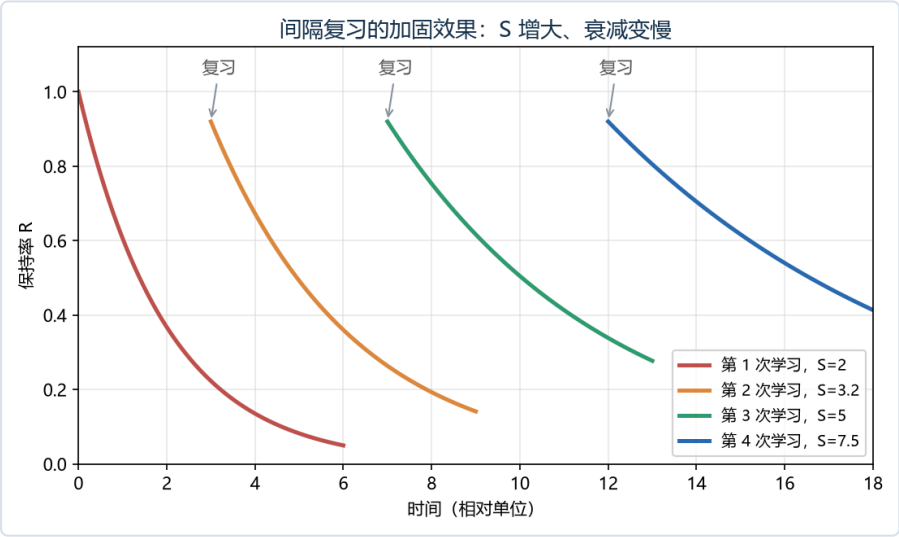


图 2-3　间隔复习的加固效果

（5）离散实现。 工程落盘按时间戳做精确指数计算，而不采用 $(1 - \lambda \Delta t)$ 的线性近似：

$$R_k = \exp\left(-\frac{\lambda\,\Delta t_k}{S}\right)$$

精确指数在长间隔下不会出现线性近似导致的负值或超调，且无需固定步长即可处理任意时间间隔。

边界：原曲线来自无意义音节实验，本文不主张其精确描述语义记忆；三桶半衰期（15/30/90 天）是工程标定而非人群测量值；λ 与三因子系数会在后续实地验证中校准。

2.4.2 赫布学习与扩散激活

"同时被激活的连接增强"，激活沿已有连接扩散。边权增量与激活更新承担的是**召回的形状**——从种子沿边扩散得到一串相关记忆。**边界**：扩散只沿已有边、全程不调用大模型；边只表示共现或关联，代码中不存在可调用的因果判定器，不做因果承诺。

2.4.3 记忆干扰：前摄/倒摄抑制与来源混淆

新旧记忆可能相互压制或被错误拼接。后者对应来源混淆（source confusion），而非对记忆空缺的虚构填补。该机制没有被实现成"再加一个遗忘项"，而是变成**边的准入约束**：门一要求两端发送者相同（硬约束），门二对 24 小时内、尚未被反复共现确立的边只加 γ·0.2 的弱权重。作用是防错构，而非提升召回。

2.4.4 情绪连续动力学

情绪不是离散标签，每一维有自己的弛豫时间，维间存在互激励，写成六维一阶常微分方程。它保证情绪跨轮、跨会话残留。**边界**：互激励矩阵采用对称假设以保留梯度流解释，非对称情形未作稳定性证明。

2.4.5 自我调节与防御机制

冲动足够强不等于此刻该表达，中间存在一层调节，落成释放许可与阈值抬升：高位放行、低位拦截、抑制居中。它把"该不该说、以什么策略说"从语言模型手中拿走，交给确定性规则。**边界**：只借用"调节"的功能结构，不采用本我/自我/超我划分；相关机制是可观测的参数动作，不是心理诊断。

2.4.6 大五人格作为慢变量

ψ=(O,C,E,A,N) 归一到 [0,1]，是月级慢变量，只调制参数、不直接决定文本。单轮负反馈最多改变参数，不能推翻人格。**边界**：开放性、尽责性、宜人性在状态中保留但尚未全部进入更新方程，不宣称其有调制作 用；"高外向更主动、高神经质恢复更慢"是参数化设计选择，未经人群标定。

六个理论的共同落点：都能写成不含大模型的确定性更新。凡必须调用大模型才能判定的量——语义相似、重要度、因果——都显式标注为代理指标，而非理论结论。

第 3 章 符号说明

全文统一符号如下（时间单位除特别说明外均为小时 h）。

符号	含义	量纲/取值
z(t)	系统六分量状态	—
e(t)	六维情绪场（happy/sad/angry/fear/love/surprise）	$\mathbb{R}^6$，[0,1]
a(v,t)	节点 v 的激活值	[0,1]
θ(t)	慢演化参数（衰减率、阈值、边先验等）	$\mathbb{R}^d$
ψ	大五人格 (O,C,E,A,N)	$\mathbb{R}^5$，[0,1]
u(t)	主动开口念头强度	$\mathbb{R}$，上界 3.0
g(t)	顶层目标（关系/记忆/自我/回避）	$\mathbb{R}^4$
s_ext	外部情绪刺激（用户输入推断）	$\mathbb{R}^6$
s_int	内部情绪刺激（记忆召回注入）	$\mathbb{R}^6$
τ	情绪弛豫时间常数	h
κ	刺激增益	标量
η	情绪自相关系数	标量
W	情绪互激励矩阵（对称 $W=W^T$）	6×6
γ	Hebbian 学习率	标量（0.06）
α	情绪—衰减耦合强度	标量
β	目标—策略耦合系数	标量（0.8）
λ	分桶基础衰减率	h^{-1}
imp	重要度自评	[0,1]
r_feedback	社交反馈信号	[0,1]
r_goal	偏好满足度	4 维
η_adapt / η_ψ	自适应/人格学习率，η_ψ≈η_adapt/100	标量
ε	探索系数	[0, ε_max]，ε_max=0.35
n(b)	行为 b 的新颖性权重	[0,1]

> 说明：早期文档曾出现"边权时间衰减常数 τ_M=36 h"的连续指数衰减表述。**当前代码并不存在该连续衰减项**：边权在 Hebbian 更新中只增不减，弱边在"做梦"阶段按阈值（edge_init×0.4）统一剪枝。本文据此不再使用 τ_M 符号。

第 4 章 系统总览与多插件架构

4.1 从单插件到六插件

系统早期以单个插件承载全部逻辑，随着能力增长，已重构为**六个职责单一、通过数据契约协作的识海插件**，均位于 `data/plugins/`。拆分的收益是：动力学内核保持精简稳定，重逻辑（工具箱、RVC、画图）隔离在行为插件，守护与心理等横切能力可独立演进，且任一插件故障不污染内核状态。

插件	版本	职责	关键结构	LLM 工具
`astrbot_plugin_shihai`（核心）	1.1.0	动力学内核 z=[e,a,θ,ψ,u,g]	`mind/`：state、emotion、graph、urge、ego、engine、adapt、classify、goals	5
`astrbot_plugin_shihai_behavior`（行为与适配·总成）	3.0.0	行为空间、策略、意图出口、工具箱、RVC、画图、短记忆	`behavior/`、`modules/`、cover.py、draw.py、dafeiyu_core.py、behaviors.json	约 37
`astrbot_plugin_shihai_psyche`（心理）	1.0.0	六类心理学模型	`psyche/profile.py`	3
`astrbot_plugin_shihai_guard`（守护）	1.0.0	不变量审计，只读不写快状态	`guard/`：channels、invariants、persona、postcheck、timeline	0
`astrbot_plugin_shihai_sms`（信使）	1.0.0	短信转发、快递解析、HTTP 服务、主动上报	`main.py`（360 行）	1
`astrbot_plugin_shihai_to`	1.0.0	uapis.cn 100+ 免费 API	api_registry、uapi_client	2 装饰 + 动态注册

插件	版本	职责	关键结构	LLM 工具
`ols`（工具件）				

全识海插件内 `@filter.llm_tool` 装饰器实测 **52 个**；工具件另有按注册表动态生成的 `uapi_*` 工具，不计入该数。

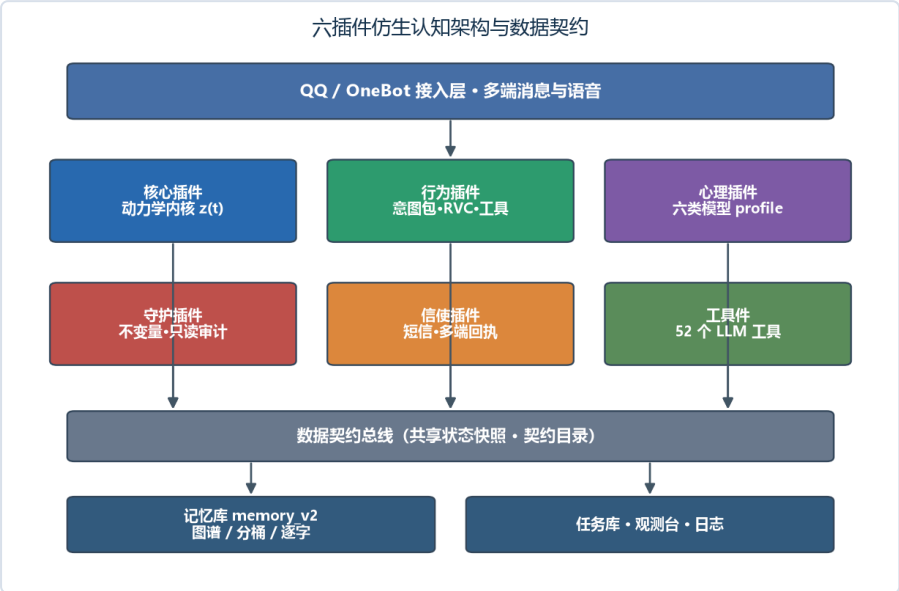


图 4-1　六插件仿生认知架构与数据契约

4.2 数据契约与运行时

插件之间不直接互改内存，而是通过**契约目录** `data/plugin_data/shihai/` 交换状态，目录名不随插件改名而变化：

- `mind_state.json`：内核快状态（情绪、念头、阈值、Q 表、最近主动文本等）；
- `psyche_state.json`：心理模块写权，内核每 tick 读取并应用到 z；
- `shihai_graph.json`：神经图谱（节点、边、类型与情感标签）；
- `action_log.jsonl`：行动记忆（行为、回执、时间戳）。

写文件采用"临时文件 + 原子替换"，避免进程中断产生半截 JSON；损坏时以默认状态兜底。

4.3 心智引擎与平台解耦

系统分三层语义：**Core-Mind Runtime** 只产出与平台无关的抽象行为指令（如 SEND_TEXT、SEND_VOICE、SET_SIGN）；**Behavior API** 固定这些指令的语义；**Platform Adapter** 把它们翻译成具体平台动作。由此换平台不改动力学、改动力学不动平台代码，同一套内核可同时驱动 QQ 机器人与本地客户端。

4.4 多模态感知的真实边界

当前真实落地的感知以**文本为主**：用户输入经 LLM 分类得到外部情绪刺激 s_ext；语音输出由 TTS 依据情绪场调整语调，RVC 翻唱由 love/happy 阈值触发。需要明确：**Wav2Vec2 语音情绪识别与 CLIP 图像理解尚未在管线中实现**（代码未引入相关推理依赖），早期文档把它们列为既有感知方式属于高估；图像/语音的深度理解列入未来工作，本文不把未实现项计入能力清单。

第 5 章 耦合动力学：情绪场、念头与自我调节

六个状态分量通过一组方程互相耦合，形成闭环。方程统一编号 (5-1) 至 (5-13)。

5.1 情绪场方程

$$\tau_i \frac{de_i}{dt} = -e_i + \kappa\,[s_{ext,i} + s_{int,i}] + \eta \sum_j W_{ij} e_j$$

−e 为自然衰减项，无刺激时情绪向 0 回归；s_ext 由用户输入推断，s_int 由召回记忆注入；W 为对称互激励矩阵（如 love 与 happy、fear 与 anger 正相关）。各维弛豫时间常数（实测）：

维度	happy	sad	angry	fear	love	surprise
τ (h)	6	12	2	3	24	**1**

surprise 取 1 h，是六维中消退最快的一项（工程注释：最易消退）；早期整合稿曾写 4 h，与代码不符，本文以 1 h 为准。

5.2 记忆—情绪耦合项

$$s_{int,i} = \sum_{v \in Recall(G,k)} a(v,t)\, E_{v,i}$$

召回的高情感节点反过来"染色"当下心情：想起往事，往事影响现在。E_{v,i} 为节点 v 关联的第 i 维情感标签强度。

5.3 图谱扩散方程

$$a(v, t+\Delta t) = (1 - \lambda_v(e))\, a(v,t) + \sum_{u \in N(v)} M(u,v)\, \frac{a(u,t)}{d(u)}$$

节点新激活 = 自身衰减后的剩余 + 邻居经边权（按出度归一）传来的能量。

5.4 情绪—衰减耦合项

$$\lambda_v(e) = \frac{\lambda_{type}}{1 + \alpha\, e_{dom}\, E_v}$$

基础衰减率按节点类型取 fact=0.10、emotion=0.01、event=0.05、highlight=0.005（每小时）；α=3.0。主导情绪越强、节点情感越契合，λ 越小、保留越久——这是情绪对记忆的反向调制。

5.5 Hebbian 边权更新

$$M(u,v) \leftarrow M(u,v) + \gamma\, \mathbb{1}[a(u) > \theta_{act}]\, \mathbb{1}[a(v) > \theta_{act}]$$

γ=0.06。“一起放电的神经元连在一起”。为防来源混淆，边准入设两道门（见6.3）。弱边在夜间“做梦”阶段按阈值（edge_init×0.4）剪枝，而非连续时间衰减。

5.6 念头方程

$$\frac{du}{dt} = K \cdot (w_1 I + w_2 T + w_3 M + w_4 I \cdot T \cdot M)$$

I、T、M 为归一到 [0,1] 的兴趣、时间适配、情绪因子，Σwᵢ=1；K 为标定增益，使典型工况下 du/dt≈0.111/h。u 以 **URGE_CEILING=3.0 为上界**，累积到 **FIRE_THRESHOLD=2.10** 才具备开口条件；作息因子 RHYTHM_ON=1.45、RHYTHM_OFF=0.48；连续未回复时门槛按 STREAK_GATE_STEP=0.2 自动抬高，刚聊过则清零。念头不是定时器，而是可积累的量。

5.7 自适应演化方程

$$\theta_{t+1} \leftarrow \theta_t - \eta_{adapt} \frac{\partial L_{total}}{\partial \theta}$$

依据忽略/冷淡/好评等反馈在线调整阈值与衰减率，实现“对不同人性格不一样”。EgoRegulator 的调节信号以权重与偏置进入适配损失，θ 只经该梯度更新，二者单向不循环。

5.8 总损失函数

$$L_{total} = w_1 L_{leak} + w_2 L_{emotion} + w_3 L_{memory} + w_4 L_{tool} + w_5 L_{adapt}$$

反馈信号连续化：5 分钟内接续对话或好评取 0.8–1.0，短回复取 0.2–0.4，强负反馈取 0；工具成功率取连续成功率而非 0/1。

5.9 策略选择方程

$$\pi = \operatorname{argmax}_x \left[Q(e, a, x) + \beta \sum_i g_i(t)\, \phi_i(x) \right]$$

Q 为启发式打分（情绪一致性、记忆相关、目标贡献、工具可用性、重复惩罚五个手工特征），**不是在线学习的价值函数，不做贝尔曼备份**；β=0.8。因此 argmax 是规则打分下的选择，而非强化学习策略优化。

5.10 自我调节：EgoRegulator

EgoRegulator 是确定性规则引擎，不调用 LLM，也**不写入 e 或 a**，只作用于释放条件与慢变量，保证语言生成层无权改写情绪场。释放条件由“越阈即发送”改为“**越阈且自我许可**”：

$$u > FIRE_THRESHOLD \ \wedge \ r_{release} > \rho \ \Rightarrow \ \text{发送}$$

ρ=0.5。r_release 分段规则（优先级自上而下）：

1. u ≥ URGE_CEILING → 1（高强度视为真实意愿，优先放行，宁可多说一句不可长期沉默）；
2. u < FIRE_THRESHOLD_LOW（=0.5·FIRE_THRESHOLD，基准 1.05）→ 0（气话/随口拦截，连替代行为也不触发）；

3. conflict_flag=1 → 0（冲突窗口抑制）；
4. r_feedback<0.3 → 0（强负反馈抑制）；
5. streak>3 → 0（连续冷落抑制）；
6. 否则 → 1（默认放行）。

抑制档连续实现：r_release=0.30+0.20·min(1，r_feedback/0.30)，落在[0.30,0.50]，恒不高于 ρ，故入抑制档必不释放；反馈为 0 时取 0.30 而非 0，是为保留恢复路径、避免乘法权重在零点退化。高神经质（ψ_N≥0.6）时该下限上调至 0.35。

延迟信号：r_delay=0.15·𝟙[冲突或连续两轮未回复]，经式 (5-10b) 抬高释放阈值，不改变 u 的累积速率，故延迟期表现为"越阈后仍等待"。

5.11 防御机制

防御只作用于表达策略与慢参数，不改情绪场与激活：

机制	触发	作用
合理化 rationalization	后果偏离预期但非冲突	改叙事角度，不改原始情绪
压抑 repression	连续负反馈/强冲突	阈值↑、召回偏置↓
投射 projection	意图推断置信度低	调 s_ext 推断权重，不直接改 s_ext
置换 displacement	抑制期内越阈	冲动导向写日记/发动态/梦境固化，不钳位不清零 u

5.12 人格与目标演化

人格 $d\psi/dt=-\eta_\psi\ \partial L_\psi/\partial\psi$，$\eta_\psi\approx\eta_{adapt}/100$，保证月级慢漂；目标 $dg/dt=-\partial/\partial g[\beta\cdot\Sigma g_i\varphi_i+\gamma(r_{goal}-g)]$，随长期经验演化。

5.13 显式稳定性

离散更新要求 $|1-1/\tau|<1$，即 $\tau>0.5$ h；现有 τ（2/3/6/12/24 h）均满足，数值积分无振荡风险。W 采用对称假设，非对称稳定性留作后续。

第 6 章 记忆系统：神经图谱、分层融合与数据净化

6.1 为什么不用扁平向量库

纯向量检索需为全量记忆支付嵌入成本，召回是互不相干的 top-k 切片，且难以表达"记忆之间的关联结构"。识海用一张带类型节点与有向边的神经图谱承载记忆：节点是记忆，边是共现/关联，激活沿边扩散，召回得到的是"一串相关记忆"。图谱的检索、扩散、衰减全部是确定性运算，**零 LLM 调用。**

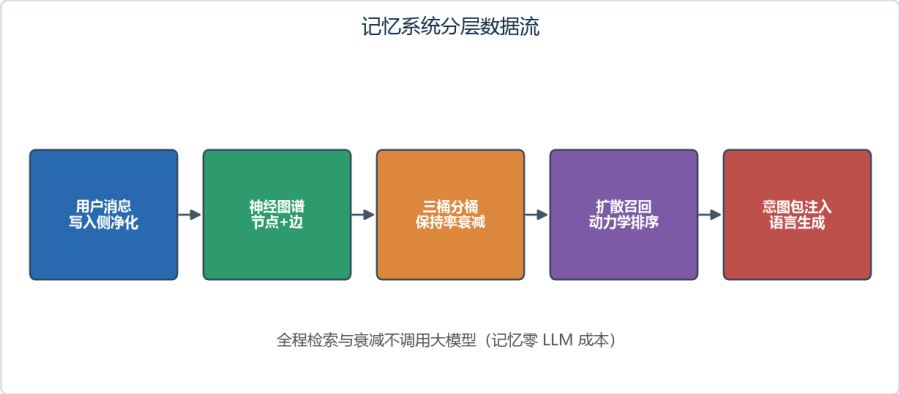


图 6-1　记忆系统分层数据流

6.2 节点类型与规模

节点类型包括 fact（事实）、event（事件）、emotion（情绪）、highlight（高光）、quote（自己的话语）。当前运行时实测 **1018 个节点、5147 条边**，其中 fact 658、event 349、emotion 3、highlight 1、quote 7。容量默认 `max_nodes=4000`、`max_edges=12000`、`node_retention_days=180`（可在配置中调整）。早期文档的"硬上限 2000、实测 800"已过时。

6.3 Hebbian 边权与两道防错构门

边在两节点共激活时按式 (5-5) 增强（γ=0.06）。为防来源混淆，边准入设两道门：

- **门一（硬约束）**：两个节点的发送者必须相同，否则不连边；
- **门二（弱权重）**：同一主体 24 小时内、尚未被反复共现（跨窗共现 ≥3 次）确立的边，只加 γ·0.2 的权重（near_scale=0.2，near_window=24h，near_repeat=3）。

门二降低假阳性，但不保证因果正确。边只表示共现或关联，不做因果承诺。

6.4 两套衰减：图谱节点与记忆分桶

系统区分两类衰减：

1. **图谱节点**：按式 (5-4) 受情绪场调制的 λ_v(e)，基础率 fact 0.10 / emotion 0.01 / event 0.05 / highlight 0.005；

2. **记忆库分桶（memory_v2）**：按艾宾浩斯保持率分桶，半衰期 **事实 15 天、事件 30 天、核心 90 天**，对应基础衰减率约 1.93e-3 / 9.63e-4 / 3.21e-4（每小时）。

记忆强度三因子 S=(1+β·imp)(1+αE·E_v)(1+βN·N_recall)：重要度自评 imp、事件情绪峰值、跨天复习计数共同决定留存与召回排序。复习计数设两道闸，防止"永生记忆"。归档只在 3/7/15 天体检日发生，且只移不删。

6.5 相对时间标签 when 与时序锚 R_t

注入 LLM 的记忆原文默认不携带时间，会导致把几天前的"明天考试"当作现在进行时。为此引入两个确定性机制：

相对时间标签 when：把节点写入到当前的时间差 Δt 格式化为自然语言，随每条记忆注入、每次生成时重算（不写图谱、不参与衰减）：

Δt	标签
<1h	刚刚聊过
1–24h	N 小时前聊过
24–48h	昨天聊过
48h–7d	N 天前聊过
7–30d	N 周前聊过
≥30d	N 个月前聊过

时序锚 R_t：取最近 24h 内 event/emotion/highlight 节点，按时间倒序取前 4 条、附 when 标签，置于意图包首行，作为判断"事情当前状态"的首要依据。意图包扩展为 I_t={R_t, G_active, E_t, M*_t, P_t, intent-type}。配套时序纪律：已完成的事（考过的试、赴过的约）禁止追问"好了没"或催促。

6.6 quote 节点与三通道隔离

quote 是 type=quote、sender=bot 的节点，存放数字生命自己说过的话（主动消息、日记），是**表达风格语料而非经历记忆**。它与常规召回严格隔离，遵循三条排除：不进入 G_active、不进入锚点候选、不进入 R_t；只经独立通道 bot_quotes 输出，供 few-shot 注入"照这个味道说、不要照抄"。若不隔离，模型会把自己的旧表达当成事实反复复述，形成自我指涉的内容循环。

6.7 数据层净化：四个落地级根因

离线成立的机制在真实环境曾被脏输入架空，根因与写入侧修复如下：

根因	表现	修复
① 中文停用词从未生效	停用词表拼接构造、未参与切词，“明天/明早”以 0.99 激活霸榜	重构停用词表，指代时间词不入关键词节点
② 默认值回填覆盖运行时	平台以 schema 默认值回填，时序纪律指令被旧文案覆盖	指令文案与默认值同源对齐
③ 未来锚点语义过期	“明天要考试”次日仍被当作未来事由	指代过期闸：明天类次日 12:00、今天类当日 24:00 失效
④ 日记长段混入语录	超 90 字的日记进入少样本，带偏成解离腔	语录按 90 字上限与日期开头过滤

此外定义**语义了结**：若存在更晚节点含“已经/考完/交了/做完/去过了”等了结词且与候选节点共享至少两个双字片段，则判定候选已被覆盖、不再作为开口候选。它与指代过期闸互补，均为字符串与时间戳运算，不调用模型。

第 7 章 人格心理学建模

7.1 大五人格作为慢变量

ψ=(O,C,E,A,N) 是"性格基底"，月级慢漂移，只调制参数、不直接决定文本：

$$\tau_{fear} = \tau_0(1+N), \quad \theta_{tantrum} = \theta_0(1+A), \quad p_{initiate} = p_0 E$$

N 越高恐惧消退越慢，A 越高越不易发火，E 越高越主动。单轮对话最多改变参数，不能推翻人格。

7.2 六类心理学模型的状态空间落位

六类模型各自绑定到一个已有状态量，不额外增加隐变量，使其可计算、可观测：

模型	在 z 中的位置	调制效果
大五人格 ψ	状态分量	恐惧弛豫↑(N)、发火阈值↑(A)、主动性↑(E)
依恋理论 att	θ 中参数	回复一致性→发送阈值→主动开口频率
认知失调	冲突检测	新旧信念冲突时由 O 决定更新/合理化
条件反射	专用边权 M_cond	中性刺激反复配对后注入 s_int
防御机制	EgoRegulator 输出	合理化/压抑/投射/置换
自我效能 eff	θ 中参数	成功 +0.05、失败 −0.1，调制自信度

7.3 实现边界（如实标注）

只有大五人格 ψ 具备完整慢变量动力学，其余五类为参数化落位或工程启发式，不声称与心理学原理严格等价：

- **依恋**：以回复一致性统计映射发送阈值，未实现安全/焦虑/回避/混乱四分类；
- **自我效能**：标量累加，未建模任务领域差异与能力归因；
- **认知失调**：仅二值分支，未实现失调强度连续度量；
- **条件反射**：记录配对并注入 s_int，未实现消退曲线与泛化梯度；
- **防御机制**：规则表四策略切换，未实现策略学习。

7.4 由头锚点的可识别性

念头越阈后，事由回访类消息还须通过锚点三条件：(a) 绑定至少一个具体记忆节点（有 ID 与摘要）；(b) 节点写入时间戳可追溯；(c) 与当前对话主体相关。情绪表达类（思念、关心、情绪同步）不依赖锚点，由情绪场直接驱动；事由回访类缺锚点则回退为情绪表达或保持沉默，避免无上下文的泛化表达。同一由头一生只出现一次，避免重复打扰。

第 8 章 行为空间、策略选择与自演化

8.1 24 类设计空间与 13 条注册行为

行为设计空间为 **24 类**（覆盖对话、关心、记忆整理、创作、翻唱、日记、说说、签名、梦境等），其中当前实际注册 **13 条**：8 条主动 + 5 条被动；其余 12 类为预留扩展位。13 条行为如下：

行为 id	主动/被动	出口 needs	novelty
proactive_greeting 主动问候	主动	—	0.10
care_inquiry 关心近况	主动	—	0.10
proactive_chat 主动闲聊	主动	—	0.35
recall_share 回忆分享	主动	—	0.40
promise_followup 承诺跟进	主动	—	0.20
sing_cover 翻唱	主动	ai_cover	0.60
draw_share 绘画分享	主动	draw	0.80
post_feed 发说说	主动	qzone	0.25
chat_followup 对话跟进	被动	—	0.10
sticker 表情包	被动	dafeiyu	0.30
diary_write 写日记	被动	dafeiyu	0.30
set_signature 设签名	被动	dafeiyu	0.25
dream_consolidate 梦境固化	被动	—	0.40

8.2 候选过滤与执行

策略选择（式 5-9）只在**满足条件的候选**中进行：行为须 enabled、proactive、锚点匹配、requires 满足、且所需出口此刻可用（服务已起、拿到 bot、具备 key）。未传可用出口时按"没有适配器"处理，避免选中不可执行的行为后空转。行为不是定时器：它由念头越阈与锚点共同驱动，而非固定周期触发。

8.3 意愿锚点 will

当锚点候选为空、或最高分仍低于 0.40 时，只要念头 u 已越阈，系统生成一个 **kind="will"、score=0.60** 的意愿锚点，理由是"此刻就是很想开口，没有什么具体的事由"。这不是空指令：u 本身就是最真实的理由，行为层据此选择开口/画画/唱歌，而不是把攒满的念头静默丢掉。

8.4 内生探索：探索—利用平衡

为避免长期沉默导致完全固化，策略在打分中加入探索项（式 8-1）：

$$b^* = \arg\max_b \left[(1-\varepsilon)\, U(b) + \varepsilon\, n(b)\right]$$

$$\varepsilon(g_{relation}) = \frac{\varepsilon_{max}}{1+\exp\left(k(g_{relation}-g_0)\right)}$$

U(b)=Q+β·Σgφ 为式 (5-9) 的规则打分，n(b) 为行为新颖性。参数 ε_max=0.35、g0=0.5、k=6。关系维护目标 g_relation 高（互动频繁）时 ε→0，优先维持关系；长期沉默、g_relation 低时 ε 升至 0.30 以上，自发探索新行为，避免完全沉默。

8.5 受控自我回流（扩展模式，默认关闭）

除默认的 EgoRegulator 外，`ego.py` 另实现三个**有界回流原语**，用于扩展模式：

- **p1 平静（reflux_p1_calm，上限 EPS_E=0.15）**：小幅下调情绪场；
- **p2 消解（reflux_p2_dissolve，上限 EPS_U=0.15）**：小幅下调念头；
- **p3 转移（reflux_p3_transfer，上限 EPS_TRANSFER=0.10）**：把冲动导向替代行为。

`pick_reflux` 是看门狗，每个决策步最多调用一个快原语，防止多原语叠加。`reflux_enabled` **默认 False（关闭）**，与默认 EgoRegulator 配置互斥，切换须注明。早期文档"尚未落地"的表述已过时：代码已具备，只是默认不启用。

8.6 三层慢演化（已落地，默认启用）

`behavior/evolution.py` 的 EvolutionEngine 实现三层慢演化，**以 overlay 形式落地、不直接改 behaviors.json、可回滚**：

- **L1 行为基因**：只改已存在行为的 novelty/cooldown/anchor 参数，不新增字段、不改 requires 语义；
- **L2 策略先验**：只调 PolicyEngine 的 ε_max，不改 β、不改状态方程；
- **L3 叙事层**：把"哪种行为被回应得多、哪种总没回音"写成可读观察笔记，不进入 G_active 与锚点。

三条硬边界：① 只写 evolution overlay（`behavior_evolution.json`），回滚即删 overlay；② 参数有界、单次扰动小（novelty ±0.04、cooldown ±10%、epsilon ±0.03）；③ 默认 24h 评估一次、样本不足 3 次的行为不动（EVOLVE_INTERVAL=24h、WINDOW=7d、MIN_SAMPLES=3；cooldown 范围 300–7200、novelty 范围 0.05–0.95）。它与 θ 快更新、动作集内探索是嵌套关系：θ 改阈值、17.4 在固定动作集内探索、本模块才改动作集自身的参数先验。当前已在 main.py 接线、默认启用，overlay 待满足 24h 与样本条件后产出。

8.7 与主动推断的关系

架构在理论上可与主动推断（active inference）对话：内生目标 g 与探索项对应”优先维持关系、减少不确定性”的驱动。但本文不把启发式规则打分等同于自由能原理下的严格推断，相关定位仅作解释性类比，最优参数标定（如 ε_max、g0）留待用户对照实验。

第 9 章 表达层：意图包与双层模型

9.1 双信号源问题

LLM 每轮同时收到两路信号：静态的人格提示词（跨会话不变）与逐轮由内核生成的意图包 I_t。二者时间性质不同却被送进同一生成过程，且未规定谁在哪个维度有最终解释权，产生两类失配：

- **状态失配**：提示词写"平时元气满满"，意图包却给出悲伤占优，模型取态无约束，人格忽明忽暗；
- **权限失配**：提示词里"绝不当冷淡""看到好玩的主动分享"等行为命令直接授权开口，绕过释放许可与锚点校验，成为非意愿主动消息的推手。

根源不是提示词写得多，而是它承担了超出"怎么说"的职责。

9.2 表达双层模型

表达按时间不变性分两层，且必须正交：

- **性格层 S**（静态，由提示词承载）：身份、说话方式、长度纪律、工具纪律，跨会话不变；
- **心情层 M**（动态，由意图包 I_t 承载）：此刻情绪、动机、开口时机，逐轮由 z(t) 给出。

归界原则：S 不含状态断言，M 不含身份与风格。

内容	承载层
身份、与用户的关系	S
说话方式（语气词、短句、颜文字、自嘲）	S
回复长度与格式纪律、工具规则	S
此刻情绪、动机与开口时机	M
记忆细节	M（G_active）
"总是/从不"式心理状态断言	禁止出现于 S

9.3 状态断言的风格化改写

提示词中一切"你总是 X""你绝不可以 Y"的断言，改写为"**当 z(t) 处于 X 状态时，以风格 σ 表达**"：状态取值交回动力学，风格 σ 由性格层保留。三步执行：扫描标记绝对化断言（总是/从不/绝不/永远）→ 改写为条件风格映射 → 复扫确认无残留实时状态句。该改写已在两个 persona 上落地，共改写五处，表达风格原文保留、性格层可感知变化为零。

9.4 意图包与提示词瘦身

意图包为 I_t={R_t, G_active, E_t, M*_t, P_t, intent-type}，其中被动意图包控制在约 200 字，只留"情绪一句、记忆引用一句、边界一句"。节点 ID 与激活值不打印（既省 token 又诱导模型报数值），念头强度只留在 dict 供审计、不拼进提示词。

性格层承载分三阶段演化：规则文本 → 规则 + quote 少样本 → 以自我话语示例替代部分规则。需要强调终点仍是提示词的一种形态：LLM 推理无状态，不存在"训练后人格内化"，动力学状态最终仍须经意图包翻译给模型。身份段与风格段不可归零。

9.5 语录 few-shot

从图谱选 sender=bot、激活高、情绪多样的 k 条自我话语，以"（此刻心情 X 时）…语录…"格式附加，作为风格示例替代等量规则文本。quote 只经 bot_quotes 独立通道，保证风格参考不被当成事实。

第 10 章 一致性守护

10.1 四类故障的形式定义

即便每个模块单独正确，串成流水线时仍可能在四个层面错位：

- **F1 记忆错乱**：失效节点（valid_until(v)≤t）仍出现在 G_active(t)，如"考完没"式追问；
- **F2 上下文割裂**：quote 节点进入事实召回通道，导致自我指涉、话题收敛到少数句式；
- **F3 人格分裂**：同轮输出兼含动力学强度断言与静态人格断言，二者竞争解释权；
- **F4 行动割裂**：已执行的主动动作 a 没有对应记忆节点（a∉V(t)），模型对"自己刚做过的事"失忆。

四类故障的共同点是"数据走错通道或根本没有通道"，故修复应在正确层位钉确定性拦截点，而非改提示词。

10.2 四条运行期不变量

不变量	内容	落点	拦截
I1 时序单调	上下文与 R_t 必带 when；同实体新旧事实新者在前	检索侧	F1
I2 通道隔离	quote 只走 bot_quotes，不进 G_active/锚点/R_t	写入+检索侧	F2/F4
I3 表达归界	S 不含状态断言，M 不含身份风格，风格由 σ(ψ) 渲染	生成侧	F3
I4 解释权唯一	状态字段与风格字段键空间不相交，冲突以状态为准	生成侧	F3

不变量由纯函数实现，不调用模型、不写回快状态。拦截顺序为：数据净化 → 语义了结 → 检索拦截 → 表达归界 → 后验校验，越靠前越便宜彻底。

10.3 三条可证结论

- **引理 10-1（覆盖）**：若 R_t 按 (created,id) 全序排列并截取前 k 条，则同一实体新旧事实中新者必在前；残余风险只剩"模型不读第一行"的服从度问题，而非架构问题。

- **命题 10-2（构造性）**：给 quote 打类型标记并在三处检索接口过滤，则 F2 恒为 0；隔离必须做在类型上，靠降权重不可靠（连续量总会被阈值越过）。
- **命题 10-3（单一事实源）**：若提示词不含强度断言、风格全由 σ(ψ) 生成，则 F3 只剩渲染噪声。

10.4 五道防线

防线	层位	机制	拦截
① 数据净化	写入侧	停用词生效、时间词不入节点、未来锚点过期闸、伪承诺过滤、日记体语录过滤	F1/F2
② 检索拦截	检索侧	when 标签、R_t 排序、语义了结、quote 类型过滤	F1/F2
③ 生成归界	生成侧	S/M 正交、状态断言改写、键空间不相交	F3
④ 行动在场	行动侧	动作执行即写 action_log 与记忆节点，保证 a∈V(t)	F4
⑤ 后验校验	生成后	GuardAuditor 跑 I1–I4，失败只降级不中断	全部

10.5 守护审计与行动记忆

`guard/invariants.py` 的 GuardAuditor 在每次生成前审计 I1–I4，失败只记 `guard_trace.jsonl` 并降级（去掉可疑字段而非整轮失败），不抛异常中断对话。行动记忆方面，动作执行后立即写 action_log 与对应节点，解决 F4 的"动作不在场"。

10.6 故障率五档对照

离线决策流（200h、10000 决策点、固定种子）按五道防线逐步叠加做五档对照。综合故障率定义为 K·Σw_k f_k + 模型外残差：基线工况标定到 **1.540**，守护态行为类故障降为 0，加上模型外残差（LLM 表达抖动、由头质量等 ODE 之外来源）0.065，**总故障率 0.065，降幅 95.8%**。该指标是离线仿真标定，不代表线上用户实验结果。

第 11 章 生活任务层：从短信到闭环

11.1 任务模型

生活任务层把"短信里的快递"变成一张可追踪的任务卡：来源（短信原文、发送方、时间、命中字段）、任务内容（取件码、运单号、驿站）、情境（下课时间、关门时间、步行分钟）、状态、用户动作。任务卡不是聊天记录，而是状态机的一条记录。

11.2 确定性通道

快递提醒**不走念头阈值 u(t)**：驿站关门是硬约束，情绪低时也不能拖。判据是事件是否带硬截止——关门、发车、预约到期等错过即不可逆的事件走确定性通道，不等待 u(t)；没有硬截止、属于陪伴表达的事件走动力学通道。两条通道共享同一份 z(t) 快照：任务事件写任务库与图谱但不改 e(t)，动力学通道只把任务摘要当弱情境刺激。

优先级与时间窗由确定性公式给出：

$$priority = w_1 urgency + w_2 route_fit + w_3 value - w_4 disruption$$

$$start = \max(now, class_end + walk), \quad end = station_close - buffer$$

若 end 已过，任务直接标 expired 并给替代建议，不生成必然迟到的提醒。

11.3 六态状态机

状态	含义	入口	出口
pending_confirm	刚发现，待发卡	短信摄入	awaiting_confirm / ignored
awaiting_confirm	已发卡，等确认	任务卡	planned / ignored / expired
planned	已排期，有窗口与理由	确认	reminded / deferred / expired
reminded	已提醒，等回执	到期	done / deferred / ignored
done	已取/已办	回执	archived
archived	归档，不再提醒	自动	—
ignored	忽略，不再提醒	回执	—
deferred	延后，窗口重算	回执	planned / expired
expired	窗口已过	自动	—

提醒理由由确定性模板生成（“16:00 下课、驿站 18:00 关门、步行 8 分钟，16:10 出发最顺路”），不让 LLM 自由发挥“我觉得现在合适”。

11.4 当前实现与落地边界（如实标注）

生活任务层在当前多插件架构下分两处承载：

1. **TaskEngine（行为插件 `behavior/tasks.py`，471 行）**：TaskStore 负责原子写与坏文件不覆盖，TaskEngine 实现摄入、去重、排期、提醒、回执、归档与时间窗计算，即上述状态机的完整逻辑；
2. **独立信使插件 `astrbot_plugin_shihai_sms`（360 行）**：内置 HTTP 服务（端口 6187，`/sms` 端点，带令牌校验），接收 SmsForwarder 转发的短信，ExpressParser 以“品牌词 + 取件码/单号/状态”双证据判定快递，解析后入库并主动私聊上报，提供 `/快递`、`/短信`、`/短信测试` 命令与 1 个 LLM 工具 get_recent_express。

需要明确的边界：

- 论文早期“5 个任务工具挂在同一 main.py”的口径已随 SMS 独立成插件而过时；
- **手机端 SmsForwarder 真机链路受校园网 AP 隔离影响尚未完全打通**，本文不把“手机自动转发”写成已交付；当前可通过 `/短信测试` 或手写 JSON 在本机验证解析与任务流转；
- 短信原文只存本机，任务库不含手机号、不把取件码发到群聊，任务卡只发给用户。

第 12 章 上下文闭合

长期记忆解决"记得三个月前的事"，短上下文解决"记得上一句自己在说什么"。后者曾有三处结构性断裂，共同特征是：发出去的东西说了，但历史里一个字都没有。

12.1 根因：整段覆盖写与钩子时序

框架在保存历史时用整段覆盖本轮 messages 而非增量追加，且响应阶段顺序是"先发送、后触发发送后钩子"。二者叠加：任何在发送阶段往历史里追加的行都会被本次覆盖写抹掉，补记只能发生在发送结束之后。多数上下文丢失并非打断取消造成，而是这一落库缺陷，且旧实现只补用户侧、已生成的半截助手正文一句不留。

12.2 三处修复

（一）语音自述入史。 语音发送时消息链被替换为 Record、没有文字组件。修复把它拆成两步：发送前暂存正文，发送成功后的钩子补一条助手轮，前缀标明"（语音）"：

$$history \leftarrow history \cup \{(assistant, \text{“（语音）”} + text_{tts})\}$$

补记须去重，按四字片段重叠率判重（同一轮可能走本地 TTS 与降级群语音两个出口）：

$$dup(a,b) = 1 \Leftrightarrow \frac{|G_4(a) \cap G_4(b)|}{|G_4(a)|} \geq 0.6$$

阈值取 0.6 而非 1.0，因 TTS 回执略带改写，整句比对会漏判。

（二）指代焦点绑定。 修复不改推断逻辑，只增加会话级焦点槽：从关系称谓词表（姐姐/哥哥/妈妈/室友/同学/老师等）取最近命中的实体，有效期 6 小时：

$$F_t = (entity, t_F), \quad valid \Leftrightarrow now - t_F < 6h$$

焦点必须落盘（进程可能被看门狗重启，内存态焦点会在重启处归零）。注入侧仅当当前句出现"她/他/它"时，在意图包追加一行约 20 token 的当前焦点说明，不出现代词则不加。

（三）半截回复抢救。 取消旧任务前先抢救而非先 cancel：把已生成的 Plain 文本以"（说到一半被打断）"标签写入历史，再取消任务、最后注入新请求，次序固定为 merge → cancel → inject。模型看到的因此是"我刚说到一半被打断"，而非"用户突然换话题"。

12.3 验证与作用域

三处补记只作用于用户会话键，按 conversation_id 定位、不新建会话，非用户会话不写，与会话隔离一致。离线验证：焦点在后续代词句中仍解析为原实体，语音正文连写第二次被判重。上线启动日志输出"上下文闭合已启用：语音自述入史 / 指代焦点绑定 / 半截回复抢救"。

第 13 章 数值自洽性验证

13.1 目标与实验设置

仿真目标不是"证明系统像人"，而是检查数值自洽：方程在给定步长下是否稳定、阈值是否饱和回落、极端输入是否越界、慢参数是否把快状态带飞。所有结论只在本文参数与步长内成立。积分采用 RK4 加投影钳位：快步长 0.05 h、长时步长 0.25 h、自我调节步长 0.02 h；长时运行 200 h、极端工况 60 h、自我调节工况 45 h。各模块共用同一随机种子，检查表只记录能由输出文件复核的量。

13.2 十一组检查结果（11/11 通过）

检查	关键结果	判据
C01 情绪场弛豫	相对解析解误差 0.00014，0 振荡	相对误差 <1%
C02 情绪—记忆耦合	召回情绪偏移 0.218，λ 单调递减	—
C03 Hebbian	边权 2.5 封顶、单调、无负边	—
C04 念头累积	du/dt=0.1109（论文 0.111，误差 0.11%），首次触发 13.9h	—
C05 200h 长时稳定	max_e=0.477、max_u=2.997、max_θ=2.3，16 次触发，有界	全程不越界
C06 参数扰动	±20% 摄动下观测变化 <30%	灵敏度阈值
C07 差异化衰减	半衰期 highlight 138.6/emotion 69.3/event 13.9/fact 6.9h	—
C08 N 维恐惧消退	半衰期相对误差 0.017，N0.8 vs N0 比值 1.786	—
C09 阈值饱和	门控回落 1.4→0，无死锁	—
C10 极端边界	max_e=1.0、max_u=3.0 正确饱和并自恢复	—
C11 自我调节	5 次触发、抑制期 0 次误放、574 次置换	—

静态编译检查 **13/13 通过**，编译路径已反映新的 `mind/` 多插件结构。

13.3 关键量化结论

- 念头典型增速 du/dt≈0.111/h，与设计值一致；
- 200 h 长时运行中情绪、念头、有效阈值全程有界，无发散、无死锁；
- 综合故障率由基线 1.540 降至 0.065（行为类故障降为 0，模型外残差 0.065），降幅 95.8%；
- 12 张图（fig_01–12）覆盖弛豫、耦合、Hebbian、长时、扰动、衰减、饱和、自我调节与故障率。

13.4 解释边界

仿真只证明数值自洽与边界行为，不证明线上因果效应；故障率是离线固定种子决策流的标定指标，不代表线上用户实验。模型外残差（LLM 表达抖动、由头质量等 ODE 之外来源）单独列示，不与行为类故障混算。

第 14 章 观测台与工程部署

14.1 单文件观测台

系统配套一个"即开即用"的单文件观测台 `识海心智观测台.html`（约 120 KB，内联 CSS/JS，无外部依赖），可视化情绪曲线、念头、目标、图谱规模与最近主动文本，并提供人物设定、未来管理（定时提醒 CRUD、插件任务、调度配置）等管理视图。

14.2 桥接服务与安卓壳

`serve.py` 作为本地桥接，读取契约目录中的状态文件并以 HTTP 提供给前端，绑定令牌鉴权（Cookie / X-Token / query token 三种方式），支持局域网访问与 dashboard 登录、cron/persona 代理。移动端通过一个最小原生 WebView 壳 `识海观测台.apk` 加载该页面，实现安卓端观测。

14.3 部署与数据安全

状态写入采用临时文件加原子替换，损坏以默认状态兜底；桥接服务所有管理接口需令牌，避免局域网裸奔。插件通过数据契约协作，任一插件崩溃不污染内核快状态。

第 15 章 限制、伦理与外部效度

15.1 已实现边界（不夸大）

- 单用户设计：多用户各自独立心智、多平台实例未实现；群聊仅做短上下文隔离，内核仍是单一自我；
- 多模态深度感知（Wav2Vec2、CLIP）未实现，当前以文本 LLM 推断为主；
- 手机端短信真机链路受网络 AP 隔离影响未完全打通；
- 部分冷却状态为进程内存储，重启清零，跨重启持久化未做；
- 心理学模型中除大五人格外多为参数化落位，不声称与心理学原理严格等价。

15.2 伦理与隐私

系统不宣称具备意识或主观体验。短信原文只存本机、设保留期限，任务库不含手机号、取件码不进群聊；心理学术语仅作功能类比，不用于推断用户心理状态。涉及第三方音源时，登录态仅用于合法在线播放，不做 DRM 解密、不抓取受版权保护的完整音源、不批量下载。

15.3 外部效度

仿真结论只在给定参数与步长内成立；参数多为工程标定而非人群测量，“高外向更主动、高神经质恢复更慢”等是设计选择。真实场景验证以本机运行日志与状态文件为准，线上用户对照实验留作后续。

15.4 后续工作

多用户独立心智、多模态感知落地、跨重启状态持久化、非对称 W 稳定性证明、探索与演化参数的用户对照标定，以及手机端真机链路打通。

第 16 章 结论

16.1 总结

识海把长期陪伴 AI 的"何时说、为何说"与"怎么说"解耦：以六分量耦合状态 z=[e,a,θ,ψ,u,g] 为核心，用情绪场 ODE、神经图谱扩散、Hebbian 边权、念头累积、自我许可、慢演化与内生目标构成确定性闭环，大模型只承担表达。工程上已重构为六个职责单一、通过数据契约协作的插件，并配套单文件观测台与安卓壳。

16.2 贡献回顾

1. 六分量耦合状态把情绪、记忆、人格、念头、目标写进同一组方程；
2. "越阈且自我许可"与由头锚点使每个主动行为可解释、可回溯；
3. 多插件架构与数据契约实现动力学与平台解耦；
4. 表达双层模型与四类故障形式化、四不变量、五道防线，把一致性做成可计数、可回归的工程性质；
5. 生活任务层以确定性状态机承载硬截止任务，与动力学共用状态快照；
6. 11 组数值检查全部通过、故障率降 95.8%，并如实标注外部效度边界。

16.3 展望

后续将在多用户独立心智、多模态深度感知、跨重启持久化与真机链路方向继续推进，并以用户对照实验标定探索与演化参数，让可解释的内生行为在长期陪伴中持续、稳定、可审计地生长。

参考文献

1. Ebbinghaus, H. *Memory: A Contribution to Experimental Psychology*. 1885.
2. Hebb, D. O. *The Organization of Behavior*. 1949.
3. Anderson, J. R. A spreading activation theory of memory. *Journal of Verbal Learning and Verbal Behavior*, 1983.
4. McCrae, R. R., & Costa, P. T. *The Five-Factor Theory of Personality*. 2008.
5. Bowlby, J. *A Secure Base: Parent-Child Attachment and Healthy Human Development*. 1988.
6. Festinger, L. *A Theory of Cognitive Dissonance*. 1957.
7. Bandura, A. *Self-Efficacy: The Exercise of Control*. 1997.
8. Friston, K. The free-energy principle: a unified brain theory? *Nature Reviews Neuroscience*, 2010.
9. A-MEM / HippoRAG / Memora 等智能体记忆架构相关工作（详见源文档参考文献节）。
10. AstrBot 框架与 OneBot 协议官方文档。

> 注：本文为代码核验后的整合稿，全部规模数字（13 行为、52 工具、11 检查、1018 节点、τ 与半衰期等）均以 2026-11-11 线上代码与运行时文件为准；与早期文档冲突处，以本稿为准。