识海：融合人格心理学的 QQ 数字生命耦合动力系统

—— 基于 AstrBot 的多插件仿生认知架构

第二十届全国大学生软件创新大赛 · 面向移动终端的系统级智能体验

识海项目组 · 大连理工大学软件学院

2026 年 11 月

目录

第 1 章 引言

第 2 章 问题定义、研究边界与理论依据

第 3 章 符号说明

第 4 章 系统总览与多插件架构

第 5 章 耦合动力学：情绪场、念头与自我调节

第 6 章 记忆系统：神经图谱、分层融合、分区访问与逐字归档

第 7 章 人格心理学建模

第 8 章 行为空间、策略选择与自演化

第 9 章 表达层：意图包与双层模型

第 10 章 一致性守护

第 11 章 生活任务层：从短信到闭环

第 12 章 上下文闭合

第 13 章 数值自洽性验证

第 14 章 观测台与工程部署

第 15 章 限制、伦理与外部效度

第 16 章 结论

参考文献

摘要

本文提出”识海”架构，把一个长期陪伴的 QQ 数字生命建模为耦合动力系统

z(t) = [e(t), a(v,t), θ(t), ψ, u(t), g(t)],

其中 e 为六维情绪场、a(v,t) 为神经图谱节点激活、θ 为可在线学习的慢参数、ψ 为大五人格特质、u 为主动开口的念头强度、g 为顶层内生目标向量。架构以”**动机动力学与语言生成解耦**”为第一原则：独立的确定性状态系统负责”何时说、为何说”，大模型仅负责”怎么说”。

系统在工程上已重构为**六个职责单一的识海插件**（核心、行为与适配、心理、守护、信使、工具件），通过数据契约协作。核心机制包括：神经图谱扩散激活替代扁平向量检索；事实/事件/核心三桶按艾宾浩斯保持率分桶衰减（半衰期 15/30/90 天）；Hebbian 边权自学习实现零 LLM 记忆管线；六类心理学模型在状态空间中找到可观测落点；念头累积叠加由头锚点与”自我许可”门控，驱动可解释的主动开口；用户反馈驱动 θ 在线自适应；目标向量 g 驱动内生行为倾向；探索—利用平衡与有界三层慢演化使行为先验可自我调整。

在表达侧，本文给出性格层/心情层正交的双层表达模型与提示词瘦身路线；在一致性侧，把记忆错乱、上下文割裂、人格分裂、行动割裂四类故障形式化为可计数判据，对应四条运行期不变量（时序单调、通道隔离、表达归界、解释权唯一），融合”写入侧净化—检索侧拦截—生成侧归界—行动侧在场—生成后校验”五道防线。离线仿真 **11 组数值检查全部通过**，综合故障率由 1.540 降至 0.065（降幅 95.8%）。生活任务层把短信快递做成可闭环的确定性状态机，与动力学共用同一份状态快照。

在多会话侧，本文给出**权限投影**而非人格切换：身份判定被收回到三个可核验谓词（主人 / 已登记熟人 / 其余），以离散 if-else 取代连续打分，三档只切”能看到什么、能做什么、要不要含糊”，人格恒为同一套。记忆归属以中性短标签标注并支持视角自反跳过；承诺以绝对时间白名单抽取、只对主人可见；熟人名单允许模型提议但只有主人能批准；逐字归档层与摘要层并存，使”原话”可被回查。工程上给出两处可量化的负结果：存量事实 449/461 无对话来源、按来源推定 `involved` 完全失效；协议端前缀漂移使 86% 的既有原话在检索中被静默排除。工具按下发核心集裁剪，schema 由 27,570 字符降至 13,745（**−50.1%**）。文末如实标注未实现项与外部效度边界。

关键词：数字生命；耦合动力学；人格心理学；主动行为；一致性守护；记忆分区；权限投影；逐字归档

第 1 章 引言

1.1 从单点问答到持续陪伴

主流陪伴 AI 把情绪、动机、人格全部交给大模型隐状态：同一句话换一个会话就可能换一种心情；主动行为由提示词或定时器触发，既不可控，也无法解释”为什么此刻主动”。其根本原因是**把两件不同的事压在了同一个模型里**——“何时说、为何说”的动机决策，与”怎么说”的语言生成。

识海把前者从语言生成中拆出来，交给一个独立的、可观测的时序状态系统；大模型退到表达层，只负责把已经决定的意图组织成自然语言。这条分界线带来三个直接后果：

1. **情绪可以跨会话残留**：情绪是带弛豫时间的连续变量，不被单轮对话重置；
2. **记忆可以差异化衰减**：不同类型、不同重要度、不同情绪色彩的记忆以不同速率消退；
3. **每个自发动作都可回溯**：能指回具体的情绪、记忆、念头或任务来源，而不是黑箱输出。

1.2 本文的组织方式

第 2—3 章定义问题、理论边界与符号；第 4 章给出多插件系统总览；第 5—8 章给出情绪、记忆、人格、行为与演化的机制；第 9—12 章给出表达层、守护层、生活任务层与上下文闭合；第 13—14 章给出数值验证与工程部署；第 15—16 章讨论边界并收束结论。

1.3 主要贡献

1. 提出六分量耦合状态 $z(t)=[e,a,\theta,\psi,u,g]$，把情绪场、图谱激活、慢参数、人格、念头与目标写进同一组方程；
2. 把”念头越阈即发送”改为”**越阈且自我许可**”，用门控调节器解释”为什么现在说、为什么不是下一次”；
3. 把 **13 条注册行为与 65 个 LLM 工具**收进统一动作空间（按下发核心集常驻 30 个），并保留 24 类设计空间的可扩展口径；
4. 给出**多插件架构与数据契约**：六个职责单一的插件通过契约目录协作，动力学与平台解耦；
5. 新增生活任务层，把短信快递做成确定性状态机，与动力学共用一份状态快照；
6. 用 **11 组数值检查全部通过**与真实运行日志验证链路自洽，并把四类故障形式化为可计数、可回归的守护判据；
7. 给出会话隔离、记忆作用域与短上下文三处闭合机制；
8. 提出**权限投影**模型：身份判定离散化为三个可核验谓词，三档只投影权限不改变人格，并以中性归属标签与视角自反跳过约束注入内容；
9. 建立**逐字归档层**与承诺账簿，给出摘要层原话保真率（事实 13.6% / 事件 43.3%）这一可复现的负结果，并把”没存 / 没取到 / 取到了没说”三层失败区分开；

10. 如实标注外部效度边界与四处未接线能力（承诺主动出口、原文锚点、scope 过滤、压缩回灌）。

第 2 章 问题定义、研究边界与理论依据

2.1 形式化问题

给定用户消息流 $X=\{x_1,\ldots,x_n\}$、历史交互记忆 $M=\{(x_i,y_i,t_i)\}$、以及情境 C（时间、课表、地点、短信、设备状态），要求构建系统

$f : (X, M, C) \to (Y, e, a, T)$，

其中 Y 为回复序列，e(t) 为连续情绪状态，a(v,t) 为记忆激活状态，T 为生活任务状态。系统需同时满足：

- **(a) 情绪连续性**：e(t) 不随单轮跳变，跨会话保留残留；
- **(b) 记忆可累积**：新交互写入图谱，旧记忆按情感强度差异化衰减；
- **(c) 行为可解释**：每个自发动作可回溯到情绪、记忆、念头或任务来源；
- **(d) 记忆零 LLM 成本**：检索与衰减不调用大模型；
- **(e) 任务可闭环**：发现、确认、排期、提醒、回执、归档六个环节不丢状态。

2.2 与现有方案的差异

“强 LLM + Prompt + 向量记忆”方案能生成像样的句子，却难以回答：为什么此刻主动？为什么是这件事？为什么不是下一次？向量检索还需为全量记忆支付嵌入成本，且召回是互不相干的 top-k 切片。识海把动机、情绪、记忆与任务做成可读的时序变量，以神经图谱扩散获得”相关的一串记忆”而非孤立切片，并把语言生成降为表达层。

2.3 研究边界

本文**不宣称系统具备意识或主观体验。**心理学概念只作设计动机与功能类比，不作为系统模块名；代码与接口不按”本我—自我—超我”命名（如出现该映射，仅用于解释功能分层）。当前版本在**单一主人**前提下支持多会话：私聊一人一会话，群聊把短上下文按”发送者_群号”隔离，长期记忆按归属 `owner` 分区并在向非主人会话注入时作可见度折算（6.11）；身份判定离散为三档权限投影（6.15），情绪场的慢分量已按对象与会话分片（6.10），但内核 $z(t)$ 的快状态与图谱仍是单一自我。多用户各自独立心智、多平台实例与独立手机端仍未实现。仿真只证明数值自洽与边界行为，不证明线上因果。

2.4 理论依据及其形式化落点

建模不是从零构造，而是从六个已有理论中各截取一部分，改写为可计算的时序变量。取舍标准有二：能否落成**不调用大模型的确定性更新**（指数衰减、加权求和、阈值比较、计数）；被截取部分能否对应

到一个**可观测的量**。以下逐条说明”借用什么、放弃什么”，把放弃的部分写清楚，以免把”借用了理论的名字”当成”实现了那个理论”。

全篇总声明：文中心理学术语（防御、压抑、置换、投射、记忆干扰等）均作功能类比，其工程定义以具体触发条件与输出行为为准，不构成心理模块划分，也不能反过来用于推断用户心理。

2.4.1 艾宾浩斯保持率曲线

本节把艾宾浩斯遗忘曲线从”借用一个公式”展开为完整建模：经典形式 → 分桶衰减率标定 → 强度三因子 → 复习加固 → 离散实现。需要强调，我们借用的是其**函数形式**而非无意义音节实验的数值结论。

（1）经典形式。 保持率随时间”先快后慢”地指数下降，经典形式写为

$$R(\Delta t) = \exp\left(-\frac{\Delta t}{S}\right) \qquad (2\text{-}1)$$

其中 S 为记忆强度（时间尺度），$R \in (0, 1]$，Δt 为距上次巩固的经过时间。

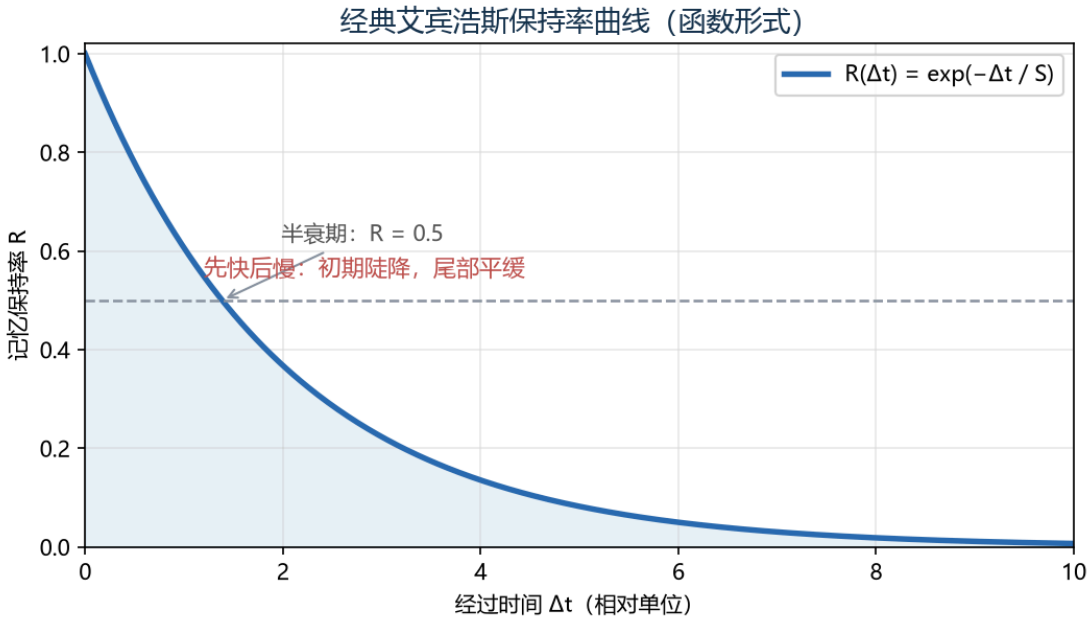


图 2-1　经典艾宾浩斯保持率曲线

（2）分桶推广与衰减率标定。 识海不使用单一 S，而是按事实 / 事件 / 核心三桶分别设定基础衰减率 λ，并引入强度倍数 S：

$$R(\Delta t) = \exp\left(-\frac{\lambda\,\Delta t}{S}\right) \qquad (2\text{-}2)$$

基础衰减率与半衰期 $T_{1/2}$ 的关系由 $R(T_{1/2}) = 0.5$ 反解：当 $S = 1$ 时 $\lambda = \ln 2 / T_{1/2}$。三桶的工程标定半衰期与对应每小时衰减率如下（$\Delta t$ 以小时计）：

记忆桶	半衰期 $T_{1/2}$	λ（每小时，$S=1$）
事实桶	15 天	1.93×10^{-3}
事件桶	30 天	9.63×10^{-4}
核心桶	90 天	3.21×10^{-4}

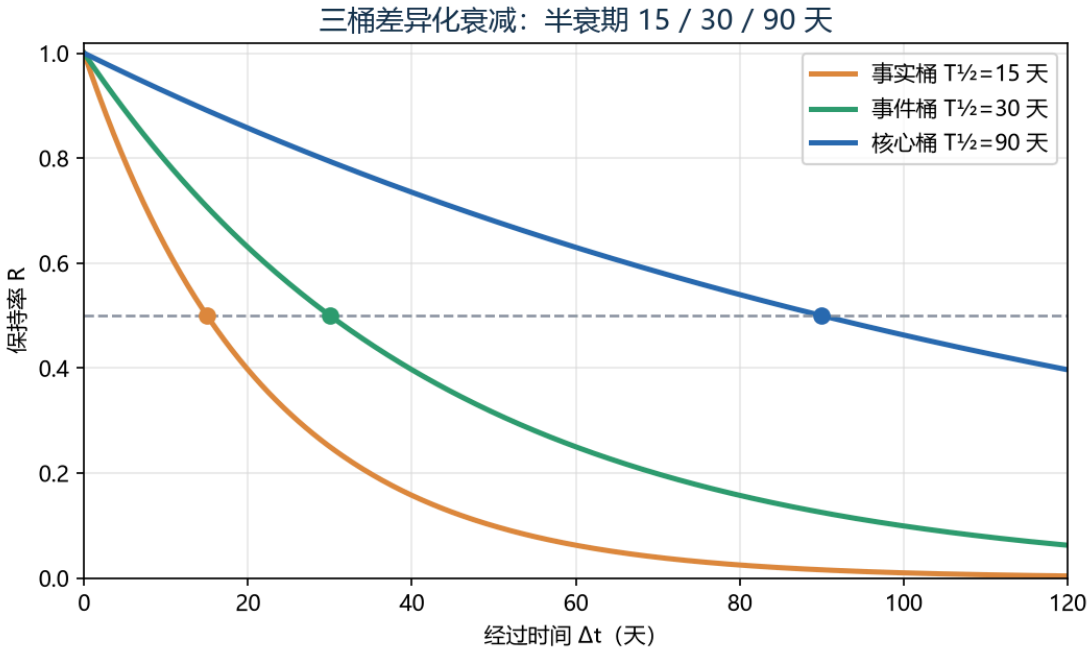


图 2-2　三桶差异化衰减（15 / 30 / 90 天）

（3）强度三因子。 记忆强度由重要度、情绪峰值、复习计数三个可观测因子相乘得到：

$$S=(1+\beta\cdot imp)\,(1+\alpha_E E_v)\,(1+\beta_N N_{recall}) \qquad (2\text{-}3)$$

其中 imp 为重要度自评、E_v 为事件情绪峰值、N_{recall} 为跨天复习计数。S 越大，等效衰减率 λ/S 越小，等效半衰期被拉长。

（4）复习加固。 每发生一次跨天复习，N_{recall} 增大、S 抬升，曲线在复习点重新抬高且后续衰减变慢（图 2-3）。这正是间隔重复（spaced repetition）在状态空间中的计算表达，也与 2.4.2 的 Hebbian “用进废退”相互呼应。

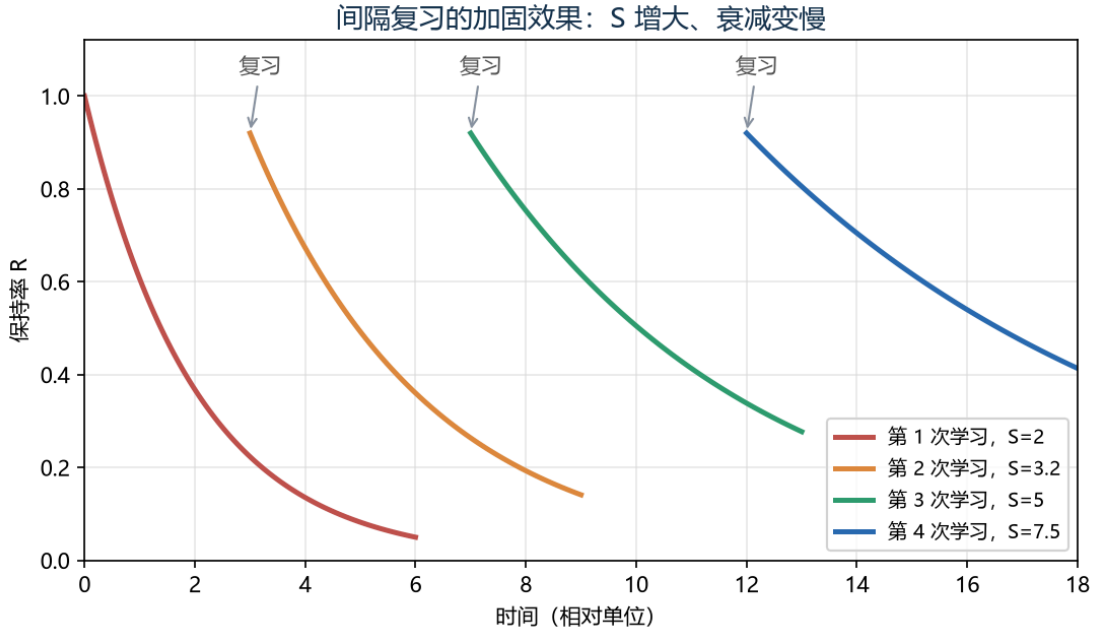


图 2-3　间隔复习的加固效果

（5）离散实现。 工程落盘按时间戳做精确指数计算，而不采用 $(1-\lambda\Delta t)$ 的线性近似：

$$R_k = \exp\left(-\frac{\lambda\,\Delta t_k}{S}\right) \qquad (2\text{-}4)$$

精确指数在长间隔下不会出现线性近似导致的负值或超调，且无需固定步长即可处理任意时间间隔。

边界：原曲线来自无意义音节实验，本文不主张其精确描述语义记忆；三桶半衰期（15/30/90 天）是工程标定而非人群测量值；λ 与三因子系数会在后续实地验证中校准。

2.4.2 赫布学习与扩散激活

“同时被激活的连接增强”，激活沿已有连接扩散。边权增量与激活更新承担的是**召回的形状**——从种子沿边扩散得到一串相关记忆。**边界**：扩散只沿已有边、全程不调用大模型；边只表示共现或关联，代码中不存在可调用的因果判定器，不做因果承诺。

2.4.3 记忆干扰：前摄/倒摄抑制与来源混淆

新旧记忆可能相互压制或被错误拼接。后者对应来源混淆（source confusion），而非对记忆空缺的虚构填补。该机制没有被实现成”再加一个遗忘项”，而是变成**边的准入约束**：门一要求两端发送者相同（硬约束），门二对 24 小时内、尚未被反复共现确立的边只加 γ·0.2 的弱权重。作用是防错构，而非提升召回。

2.4.4 情绪连续动力学

情绪不是离散标签，每一维有自己的弛豫时间，维间存在互激励，写成六维一阶常微分方程。它保证情绪跨轮、跨会话残留。**边界**：互激励矩阵采用对称假设以保留梯度流解释，非对称情形未作稳定性证明。

2.4.5 自我调节与防御机制

冲动足够强不等于此刻该表达，中间存在一层调节，落成释放许可与阈值抬升：高位放行、低位拦截、抑制居中。它把”该不该说、以什么策略说”从语言模型手中拿走，交给确定性规则。**边界**：只借用”调节”的功能结构，不采用本我/自我/超我划分；相关机制是可观测的参数动作，不是心理诊断。

2.4.6 大五人格作为慢变量

ψ=(O,C,E,A,N) 归一到 [0,1]，是月级慢变量，只调制参数、不直接决定文本。单轮负反馈最多改变参数，不能推翻人格。**边界**：开放性、尽责性、宜人性在状态中保留但尚未全部进入更新方程，不宣称其有调制作 用；“高外向更主动、高神经质恢复更慢”是参数化设计选择，未经人群标定。

六个理论的共同落点：都能写成不含大模型的确定性更新。凡必须调用大模型才能判定的量——语义相似、重要度、因果——都显式标注为代理指标，而非理论结论。

第 3 章 符号说明

全文统一符号如下（时间单位除特别说明外均为小时 h）。

符号	含义	量纲/取值
z(t)	系统六分量状态	—
e(t)	六维情绪场（happy/sad/angry/fear/love/surprise）	$\mathbb{R}^6$，[0,1]
a(v,t)	节点 v 的激活值	[0,1]
θ(t)	慢演化参数（衰减率、阈值、边先验等）	$\mathbb{R}^d$
ψ	大五人格 (O,C,E,A,N)	$\mathbb{R}^5$，[0,1]
u(t)	主动开口念头强度	$\mathbb{R}$，上界 3.0
g(t)	顶层目标（关系/记忆/自我/回避）	$\mathbb{R}^4$
s_{ext}	外部情绪刺激（用户输入推断）	$\mathbb{R}^6$
s_{int}	内部情绪刺激（记忆召回注入）	$\mathbb{R}^6$
τ	情绪弛豫时间常数	h
κ	刺激增益	标量
η	情绪自相关系数	标量
W	情绪互激励矩阵（对称 $W=W^T$）	6×6
γ	Hebbian 学习率	标量（0.06）
α	情绪—衰减耦合强度	标量
β	目标—策略耦合系数	标量（0.8）
λ	分桶基础衰减率	h^{-1}
imp	重要度自评	[0,1]
r_feedback	社交反馈信号	[0,1]
r_goal	偏好满足度	4 维
η_adapt / η_ψ	自适应/人格学习率，η_ψ≈η_adapt/100	标量
ε	探索系数	$[0,\varepsilon_{\max}]$，$\varepsilon_{\max}=0.35$
n(b)	行为 b 的新颖性权重	[0,1]

> 说明：早期文档曾出现”边权时间衰减常数 τ_M=36 h”的连续指数衰减表述。**当前代码并不存在该连续衰减项**：边权在 Hebbian 更新中只增不减，弱边在”做梦”阶段按阈值（edge_init×0.4）统一剪枝。本文据此不再使用 τ_M 符号。

第 4 章 系统总览与多插件架构

4.1 从单插件到六插件

系统早期以单个插件承载全部逻辑，随着能力增长，已重构为**六个职责单一、通过数据契约协作的识海插件**，均位于 `data/plugins/`。拆分的收益是：动力学内核保持精简稳定，重逻辑（工具箱、RVC、画图）隔离在行为插件，守护与心理等横切能力可独立演进，且任一插件故障不污染内核状态。

插件	版本	职责	关键结构	LLM 工具
`astrbot_plugin_shihai`（核心）	1.1.0	动力学内核 z=[e,a,θ,ψ,u,g]	`mind/`：state、emotion、graph、urge、ego、engine、adapt、classify、goals	5
`astrbot_plugin_shihai_behavior`（行为与适配·总成）	3.0.0	行为空间、策略、意图出口、工具箱、RVC、画图、短记忆	`behavior/`、`modules/`、cover.py、draw.py、dafeiyu_core.py、behaviors.json	约 37
`astrbot_plugin_shihai_psyche`（心理）	1.0.0	六类心理学模型	`psyche/profile.py`	3
`astrbot_plugin_shihai_guard`（守护）	1.0.0	不变量审计，只读不写快状态	`guard/`：channels、invariants、persona、postcheck、timeline	0
`astrbot_plugin_shihai_sms`（信使）	1.0.0	短信转发、快递解析、HTTP 服务、主动上报	`main.py`（360 行）	1
`astrbot_plugin_shihai_tools`（工具件）	1.0.0	uapis.cn 100+ 免费 API	api_registry、uapi_client	2 装饰 + 动态注册

全识海插件内 `@filter.llm_tool` 装饰器实测 **65 个**；工具件另有按注册表动态生成的 `uapi_*` 工具，不计入该数。下发并非全量：按下发核心集裁剪后常驻 30 个，单轮 schema 字符由 27,570 降至 13,745（−50.1%，见 6.21）。

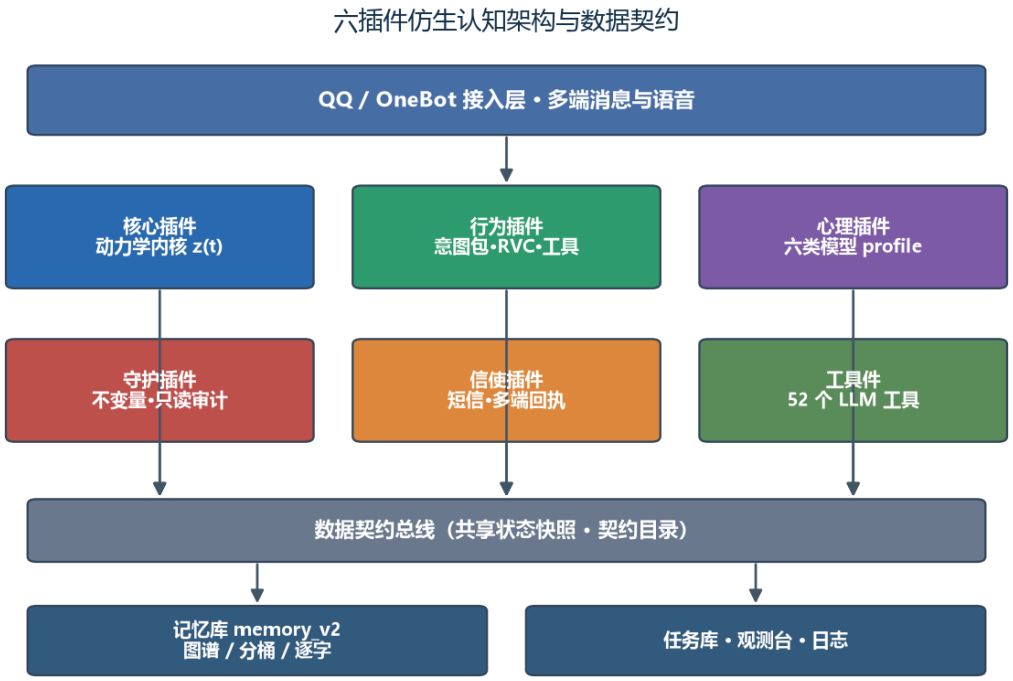


图 4-1　六插件仿生认知架构与数据契约

4.2 数据契约与运行时

插件之间不直接互改内存，而是通过**契约目录** `data/plugin_data/shihai/` 交换状态，目录名不随插件改名而变化：

- `mind_state.json`：内核快状态（情绪、念头、阈值、Q 表、最近主动文本等）；
- `psyche_state.json`：心理模块写权，内核每 tick 读取并应用到 z；
- `shihai_graph.json`：神经图谱（节点、边、类型与情感标签）；
- `action_log.jsonl`：行动记忆（行为、回执、时间戳）。

写文件采用”临时文件 + 原子替换”，避免进程中断产生半截 JSON；损坏时以默认状态兜底。

4.3 心智引擎与平台解耦

系统分三层语义：**Core-Mind Runtime** 只产出与平台无关的抽象行为指令（如 SEND_TEXT、SEND_VOICE、SET_SIGN）；**Behavior API** 固定这些指令的语义；**Platform Adapter** 把它们翻译成具体平台动作。由此换平台不改动力学、改动力学不动平台代码，同一套内核可同时驱动 QQ 机器人与本地客户端。

4.4 多模态感知的真实边界

当前真实落地的感知以**文本为主**：用户输入经 LLM 分类得到外部情绪刺激 s_{ext}；语音输出由 TTS 依据情绪场调整语调，RVC 翻唱由 love/happy 阈值触发。需要明确：**Wav2Vec2 语音情绪识别与 CLIP**

图像理解尚未在管线中实现（代码未引入相关推理依赖），早期文档把它们列为既有感知方式属于高估；图像/语音的深度理解列入未来工作，本文不把未实现项计入能力清单。

第 5 章 耦合动力学：情绪场、念头与自我调节

六个状态分量通过一组方程互相耦合，形成闭环。方程统一编号 (5-1) 至 (5-13)。

5.1 情绪场方程

$$\tau_i \frac{de_i}{dt} = -e_i + \kappa\,[s_{ext,i} + s_{int,i}] + \eta \sum_j W_{ij} e_j \qquad (5\text{-}1)$$

$-e$ 为自然衰减项，无刺激时情绪向 0 回归；s_{ext} 由用户输入推断，s_{int} 由召回记忆注入；W 为对称互激励矩阵（如 love 与 happy、fear 与 anger 正相关）。各维弛豫时间常数（实测）：

维度	happy	sad	angry	fear	love	surprise
τ (h)	6	12	2	3	24	**1**

surprise 取 1 h，是六维中消退最快的一项（工程注释：最易消退）；早期整合稿曾写 4 h，与代码不符，本文以 1 h 为准。

5.2 记忆—情绪耦合项

$$s_{int,i} = \sum_{v \in Recall(G,k)} a(v,t)\, E_{v,i} \qquad (5\text{-}2)$$

召回的高情感节点反过来”染色”当下心情：想起往事，往事影响现在。$E_{v,i}$ 为节点 v 关联的第 i 维情感标签强度。

5.3 图谱扩散方程

$$a(v, t+\Delta t) = (1 - \lambda_v(e))\, a(v,t) + \sum_{u \in N(v)} M(u,v)\, \frac{a(u,t)}{d(u)} \qquad (5\text{-}3)$$

节点新激活 = 自身衰减后的剩余 + 邻居经边权（按出度归一）传来的能量。

5.4 情绪—衰减耦合项

$$\lambda_v(e) = \frac{\lambda_{type}}{1 + \alpha\, e_{dom}\, E_v} \qquad (5\text{-}4)$$

基础衰减率按节点类型取 fact=0.10、emotion=0.01、event=0.05、highlight=0.005（每小时）；$\alpha = 3.0$。主导情绪越强、节点情感越契合，λ_v 越小、保留越久——这是情绪对记忆的反向调制。

5.5 Hebbian 边权更新

$$M(u,v) \leftarrow M(u,v) + \gamma\, \mathbb{1}[a(u) > \theta_{act}]\, \mathbb{1}[a(v) > \theta_{act}] \qquad (5\text{-}5)$$

γ=0.06。“一起放电的神经元连在一起”。为防来源混淆，边准入设两道门（见 6.3）。弱边在夜间“做梦”阶段按阈值（edge_init×0.4）剪枝，而非连续时间衰减。

5.6 念头方程

$$\frac{du}{dt} = K \cdot (w_1 I + w_2 T + w_3 M + w_4 I \cdot T \cdot M) \qquad (5\text{-}6)$$

I、T、M 为归一到 [0,1] 的兴趣、时间适配、情绪因子，Σwᵢ=1；K 为标定增益，使典型工况下 du/dt≈0.111/h。u 以 **URGE_CEILING=3.0 为上界**，累积到 **FIRE_THRESHOLD=2.10** 才具备开口条件；作息因子 RHYTHM_ON=1.45、RHYTHM_OFF=0.48；连续未回复时门槛按 STREAK_GATE_STEP=0.2 自动抬高，刚聊过则清零。念头不是定时器，而是可积累的量。

5.7 自适应演化方程

$$\theta_{t+1} \leftarrow \theta_t - \eta_{adapt} \frac{\partial L_{total}}{\partial \theta} \qquad (5\text{-}7)$$

依据忽略/冷淡/好评等反馈在线调整阈值与衰减率，实现”对不同人性格不一样”。EgoRegulator 的调节信号以权重与偏置进入适配损失，θ 只经该梯度更新，二者单向不循环。

5.8 总损失函数

$$L_{total} = w_1 L_{leak} + w_2 L_{emotion} + w_3 L_{memory} + w_4 L_{tool} + w_5 L_{adapt} \qquad (5\text{-}8)$$

反馈信号连续化：5 分钟内接续对话或好评取 0.8–1.0，短回复取 0.2–0.4，强负反馈取 0；工具成功率取连续成功率而非 0/1。

5.9 策略选择方程

$$\pi = \operatorname{argmax}_x \left[Q(e, a, x) + \beta \sum_i g_i(t)\, \phi_i(x) \right] \qquad (5\text{-}9)$$

Q 为启发式打分（情绪一致性、记忆相关、目标贡献、工具可用性、重复惩罚五个手工特征），**不是在线学习的价值函数，不做贝尔曼备份**；β=0.8。因此 argmax 是规则打分下的选择，而非强化学习策略优化。

5.10 自我调节：EgoRegulator

EgoRegulator 是确定性规则引擎，不调用 LLM，也**不写入 e 或 a**，只作用于释放条件与慢变量，保证语言生成层无权改写情绪场。释放条件由”越阈即发送”改为”**越阈且自我许可**”：

$$u > FIRE_THRESHOLD \ \wedge \ r_{release} > \rho \ \Rightarrow \ \text{发送} \qquad (5\text{-}10)$$

ρ=0.5。r_release 分段规则（优先级自上而下）：

1. u ≥ URGE_CEILING → 1（高强度视为真实意愿，优先放行，宁可多说一句不可长期沉默）；
2. u < FIRE_THRESHOLD_LOW（=0.5·FIRE_THRESHOLD，基准 1.05）→ 0（气话/随口拦截，连替代行为也不触发）；

3. conflict_flag=1 → 0（冲突窗口抑制）；
4. r_feedback<0.3 → 0（强负反馈抑制）；
5. streak>3 → 0（连续冷落抑制）；
6. 否则 → 1（默认放行）。

抑制档连续实现：r_release=0.30+0.20·min(1, r_feedback/0.30)，落在 [0.30,0.50]，恒不高于 ρ，故入抑制档必不释放；反馈为 0 时取 0.30 而非 0，是为保留恢复路径、避免乘法权重在零点退化。高神经质（ψ_N≥0.6）时该下限上调至 0.35。

延迟信号：r_delay=0.15·𝟙[冲突或连续两轮未回复]，经式 (5-10b) 抬高释放阈值，不改变 u 的累积速率，故延迟期表现为”越阈后仍等待”。

5.11 防御机制

防御只作用于表达策略与慢参数，不改情绪场与激活：

机制	触发	作用
合理化 rationalization	后果偏离预期但非冲突	改叙事角度，不改原始情绪
压抑 repression	连续负反馈/强冲突	阈值↑、召回偏置↓
投射 projection	意图推断置信度低	调 s_{ext} 推断权重，不直接改 s_{ext}
置换 displacement	抑制期内越阈	冲动导向写日记/发动态/梦境固化，不钳位不清零 u

5.12 人格与目标演化

人格 dψ/dt=−η_ψ ∂L_ψ/∂ψ，η_ψ≈η_adapt/100，保证月级慢漂；目标 dg/dt=−∂/∂g[β·Σg_iφ_i+γ(r_goal−g)]，随长期经验演化。

5.13 显式稳定性

离散更新要求 |1−1/τ|<1，即 τ>0.5 h；现有 τ（2/3/6/12/24 h）均满足，数值积分无振荡风险。W 采用对称假设，非对称稳定性留作后续。

第 6 章 记忆系统：神经图谱、分层融合、分区访问与逐字归档

本章按三层递进：**存什么**（6.1–6.7：图谱结构、三桶衰减、Hebbian 自学习、写入侧净化）；**按谁存**（6.8–6.14：自我状态的三分解 $z_p + z_r(o) + z_s(s)$、投影动力学、可见度门控与三层检索）；**给谁看、怎么取**（6.15–6.23：身份谓词与权限投影、中性归属标注、承诺账簿与原话归档、工具按需调度，及其实验设计与边界）。前两层的数值与参数取自线上实现，第三层记录两处可复现的负结果（6.17 推定失效、6.20 前缀漂移），因为多会话记忆的失败常常以”记性不好”的形式出现，而非以报错的形式出现。

6.1 为什么不用扁平向量库

纯向量检索需为全量记忆支付嵌入成本，召回是互不相干的 top-k 切片，且难以表达”记忆之间的关联结构”。识海用一张带类型节点与有向边的神经图谱承载记忆：节点是记忆，边是共现/关联，激活沿边扩散，召回得到的是”一串相关记忆”。图谱的检索、扩散、衰减全部是确定性运算，**零 LLM 调用**。

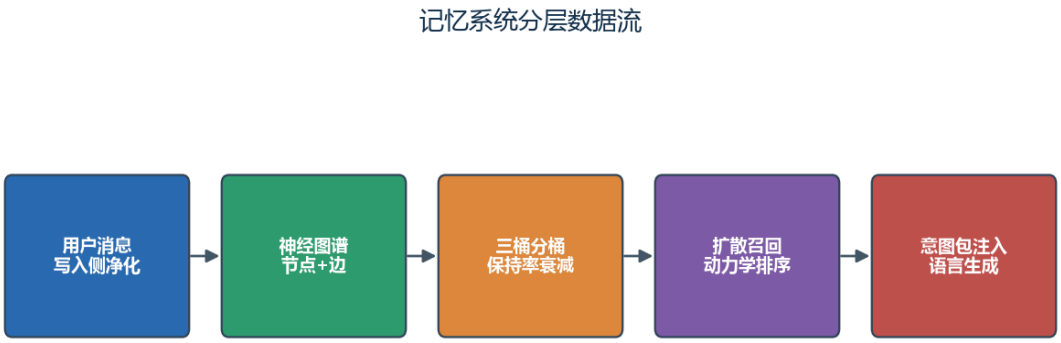


图 6-1　记忆系统分层数据流

6.2 节点类型与规模

节点类型包括 fact（事实）、event（事件）、emotion（情绪）、highlight（高光）、quote（自己的话语）。当前运行时实测 **1018 个节点、5147 条边**，其中 fact 658、event 349、emotion 3、highlight 1、quote 7。容量默认 `max_nodes=4000`、`max_edges=12000`、`node_retention_days=180`（可在配置中调整）。早期文档的”硬上限 2000、实测 800”已过时。

6.3 Hebbian 边权与两道防错构门

边在两节点共激活时按式 (5-5) 增强（γ=0.06）。为防来源混淆，边准入设两道门：

- **门一（硬约束）**：两个节点的发送者必须相同，否则不连边；
- **门二（弱权重）**：同一主体 24 小时内、尚未被反复共现（跨窗共现 ≥3 次）确立的边，只加 γ·0.2 的权重（near_scale=0.2，near_window=24h，near_repeat=3）。

门二降低假阳性，但不保证因果正确。边只表示共现或关联，不做因果承诺。

6.4 两套衰减：图谱节点与记忆分桶

系统区分两类衰减：

1. **图谱节点**：按式 (5-4) 受情绪场调制的 $\lambda_v(e)$，基础率 fact 0.10 / emotion 0.01 / event 0.05 / highlight 0.005；
2. **记忆库分桶（memory_v2）**：按艾宾浩斯保持率分桶，半衰期 **事实 15 天、事件 30 天、核心 90 天**，对应基础衰减率约 1.93e-3 / 9.63e-4 / 3.21e-4（每小时）。

记忆强度三因子 $S = (1 + \beta \cdot \mathrm{imp})(1 + \alpha_E E_v)(1 + \beta_N N_{\mathrm{recall}})$：重要度自评 imp、事件情绪峰值、跨天复习计数共同决定留存与召回排序。复习计数设两道闸，防止”永生记忆”。归档只在 3/7/15 天体检日发生，且只移不删。

6.5 相对时间标签 when 与时序锚 R_t

注入 LLM 的记忆原文默认不携带时间，会导致把几天前的”明天考试”当作现在进行时。为此引入两个确定性机制：

相对时间标签 when：把节点写入到当前的时间差 Δt 格式化为自然语言，随每条记忆注入、每次生成时重算（不写图谱、不参与衰减）：

Δt	**标签**
<1h	刚刚聊过
1–24h	N 小时前聊过
24–48h	昨天聊过
48h–7d	N 天前聊过
7–30d	N 周前聊过
≥30d	N 个月前聊过

时序锚 R_t：取最近 24h 内 event/emotion/highlight 节点，按时间倒序取前 4 条、附 when 标签，置于意图包首行，作为判断”事情当前状态”的首要依据。意图包扩展为 I_t={R_t, G_active, E_t, M*_t, P_t, intent-type}。配套时序纪律：已完成的事（考过的试、赴过的约）禁止追问”好了没”或催促。

6.6 quote 节点与三通道隔离

quote 是 type=quote、sender=bot 的节点，存放数字生命自己说过的话（主动消息、日记），是**表达风格语料而非经历记忆。**它与常规召回严格隔离，遵循三条排除：不进入 G_active、不进入锚点候选、不进入 R_t；只经独立通道 bot_quotes 输出，供 few-shot 注入”照这个味道说、不要照抄”。若不隔离，模型会把自己的旧表达当成事实反复复述，形成自我指涉的内容循环。

6.7 数据层净化：四个落地级根因

离线成立的机制在真实环境曾被脏输入架空，根因与写入侧修复如下：

根因	表现	修复
① 中文停用词从未生效	停用词表拼接构造、未参与切词，“明天/明早”以 0.99 激活霸榜	重构停用词表，指代时间词不入关键词节点
② 默认值回填覆盖运行时	平台以 schema 默认值回填，时序纪律指令被旧文案覆盖	指令文案与默认值同源对齐
③ 未来锚点语义过期	“明天要考试”次日仍被当作未来事由	指代过期闸：明天类次日 12:00、今天类当日 24:00 失效
④ 日记长段混入语录	超 90 字的日记进入少样本，带偏成解离腔	语录按 90 字上限与日期开头过滤

此外定义**语义了结**：若存在更晚节点含”已经/考完/交了/做完/去过了”等了结词且与候选节点共享至少两个双字片段，则判定候选已被覆盖、不再作为开口候选。它与指代过期闸互补，均为字符串与时间戳运算，不调用模型。

6.8 问题重述：记忆已经分区，自我状态没有

早期讨论把现状概括为”全局状态 + 单 owner 通道”。对照代码核验后，这一表述需要修正：**记忆层已经做了归属分区，真正没有分区的是自我状态本身。**

已实现的部分（代码事实）：

机制	实现位置	事实
记忆三层归属	`modules/memory_v2.py` 的 `FactItem.owner` / `EventItem.owner`	`owner`（共享层/人身层）、`qq:<号>`（个人层）、`group:<群号>`（群层）
检索归属过滤	`recall(..., owners=...)`	`owners` 为 `None` 时不过滤，老调用路径行为不变
归属打标	`modules/memory.py` 的 `_mem_owner_tag()`	主人→`owner`；群聊→`group:<群号>`；其他私聊→`qq:<号>`
共享层可见性	`OWNER_LAYER_VISIBLE_TO_OTHERS = True`	当前**默认对外可见**，非主人会话可召回共享层条目
心智内容注入隔离	`intent_owner_only`（默认 `true`）	非主人会话不注入 `z(t)`、`G_active`、主动开口档案
消融实验	`EXPERIMENT_GROUPS = ("a_none","b_recall","c_recall_timeline","d_full")`	四组已落地，实验台脚本可按组切换

未实现的部分（同为代码事实）：

缺口	证据
状态未分区	`mind_state.json` 全程单份，所有会话读写同一份 `z(t)`
无关系状态	全库无 `z_relational` 类结构；psyche 插件只有 `PsychePlugin`，无按对象状态
无会话实例状态	无 per-conversation 的情境状态；群与会话共用同一份情绪与念头
关系衰减未生效	`decay_factor` 字段在 `FactItem`(0.992/0.998) 与 `EventItem`(0.996) 中定义并赋值，**但无任何读取点参与衰减计算**

> 以上两表是 2026-11-12 改造前的基线。改造后 `modules/relational.py`（276 行）与 `modules/selfstate.py`（202 行）已上线：$z_r(o)$ 分片、$z_s(s)$ 分片与连续门控 w_{visible} 均进入线上检索路径（6.11、6.14 第 5 条）；仍为单份的是 `mind_state.json` 的快状态（见 6.23）。

因此本节的问题不是”要不要分层”，而是：

> **为什么记忆已经按人分层，却仍然会出现跨对象记忆错投与心智缺席？**

答案是分层选错了对象。当前系统把”这个 sender 是不是主人”（身份识别）与”此刻的我是谁、面对谁”（自我状态）压进同一个判断，用 `intent_owner_only` 与 `OWNER_LAYER_VISIBLE_TO_OTHERS` 两个布尔量近似表达。布尔量能回答”是否允许”，不能回答”以什么身份、多大程度上”。三个可观测后果：

1. **情绪错位**：情绪闸门与主动出口读的是同一份 `mind_state.json`，陌生会话里 `e(t)` 仍是主人语境下的情绪；
2. **关系无量**：对某个对象积累的信任、未完成的承诺无法表达为状态量，只能退化成记忆条目的多寡；
3. **共享层裸奔**：`OWNER_LAYER_VISIBLE_TO_OTHERS = True` 下，陌生会话可直接召回”鑫鑫的经历”，这是错投率的直接来源。

这正是认知科学中 **Self–Other Distinction**（自我—他者区分）在工程实现上的失效点：区分”我知道什么”与”对方知道什么”本应是两个独立变量。

6.9 自我状态的三分解

把单一 `z(t)` 分解为三个语义不同、生命周期不同的分量（公式编号接第 6 章既有编号，从 6-17 起）：

$$z(t) = \left[\, z_p(t),\ z_r(o,t),\ z_s(s,t) \,\right]$$

其中 o 为对话对象标识，s 为会话实例标识。

分量	内容	生命周期	共享性	代码现状
z_p	人格特质 ψ、核心价值观、语言风格、长期情绪基线	跨会话持久	全局共享	已有（`psi` / `psyche`）
$z_r(o)$	对对象 o 的亲密度 R_o、互动史、未完成承诺、共同梗	按对象持久	按对象隔离	已实现（`relational.py`）
$z_s(s)$	当前会话的情绪、当前话题、临时状态	按会话实例	按会话隔离	已实现（`selfstate.py`）

分量间的作用关系（单向约束，避免互相污染）：

$$z_s \leftarrow \pi\left(z_p,\ z_r(o)\right), \qquad z_r(o) \leftarrow \text{writeback}\left(z_s,\ \text{session end}\right), \qquad z_p \leftarrow \text{slow}(z_p)\ \text{仅慢漂移}$$

即：会话状态由人格内核与关系状态初始化；会话结束时只把增量回写关系层；人格内核不接受会话级刺激的直接写入，只走既有的三层慢演化通道（`evolution.py`，24 h 评估、样本 <3 不动、写 overlay 可回滚）。

这一分解的收益是”在哪儿都是同一个人”的论据被加强而非削弱：人格内核 z_p 全局共享，陌生会话依然完整拥有它；变化的只是关系初值（默认低亲密）与会话情境（从零开始）。用状态空间的语言说，我们不是给陌生会话一个”空状态”，而是给它一个**只有 z_p 有效、z_r 取默认低值的合法状态。**

6.10 关系状态的一阶动力学

6.10.1 早期设式的缺陷

讨论稿给出的形式是：

$$\frac{dR_o}{dt} = \alpha \cdot \text{interaction_rate} \cdot f(\text{valence}) \;-\; \beta \cdot \text{time_since_last_contact} \;+\; \gamma \cdot \text{commitment}$$

该式有三个硬伤，直接落到代码里会出问题：

1. **第二项无界**：`time_since_last_contact` 随时间单调增长，R_o 会线性跌向负值，与”关系强度”的取值范围 $[0,1]$ 矛盾；
2. $f(\text{valence})$ **未定义**：情绪效价为负时该项为负，会把”高频争吵”算成关系衰减，与”互动越多权重越高”的 Hebbian 直觉冲突；
3. **与既有参数脱节**：已有 `near_window = 24h`、`near_scale = 0.2`、$\gamma_{\text{hebbian}} = 0.06$，新式若不与之对齐，将出现两套并行的”关系”口径。

6.10.2 修正形式

改写成对目标值的有界松弛，衰减项作用于**偏离量**而非绝对时间：

$$\frac{dR_o}{dt} = \alpha\Big[\rho_o(t)\,\sigma(\kappa\, v_o) - R_o\Big] - \beta\,\big(R_o - R_{\min}\big) + \gamma\, c_o$$

$$\rho_o(t) = \frac{n_o(t)}{n_o(t) + n_0}, \qquad \sigma(x) = \frac{1}{1+e^{-x}}$$

各项语义：

- $\rho_o(t)$：对象 o 在滑动窗内的**互动率**，$n_o(t)$ 为窗内互动次数，n_0 为半饱和常数（取 $n_0 = 5$，即 5 次互动达到半饱和）。与 Hebbian 的 `near_window = 24 h` 同窗，避免两套时间口径；
- $\sigma(\kappa v_o)$：把累积情绪效价 $v_o \in [-1,1]$ 压到 $(0,1)$，$\kappa = 2$。这一项**对效价符号敏感**：正面互动把目标值推高，负面互动把目标值压低，因此冲突不会被误算成关系加深。这与 Hebbian 的”互动频率提升连边权重”并不冲突——后者的对象是记忆图谱的边权（记忆强度），本节的对象是关系强度 R_o，两者是不同状态量，不能共用一个系数。
- β：关系松弛速率，由”关系层每半小时保留比例” r_β 标定，$\beta = -\ln r_\beta / \Delta t$。取 $r_\beta = 0.94$、$\Delta t = 0.5\,\text{h}$，得 $\beta = -\ln(0.94)/0.5 = 0.1238$，正文取 0.12。r_β 是**关系层专用常数**（实现中为 `REL_DECAY`），**不是**既有 `decay_factor`（0.992 / 0.996 / 0.998），两者不共用，见下方溯源记录；
- $R_{\min} = 0.15$：关系下界，保证”不联系也不归零”，对应”曾经认识过”的最低残留；
- γc_o：未完成承诺项，$c_o \in \{0,1\}$ 表示该对象是否存在未完成承诺，$\gamma = 0.10$（与 ego 的 `EPS` 第三项同值）。承诺存在时抬高的是**稳态**而非下界，承诺完成后 $c_o \to 0$，稳态随即回落。

诚实记录（参数溯源，含一处自我更正）：本稿初版写”β 直接复用既有 `decay_factor`“，该说法**不成立**，此处更正。核对代码：`decay_factor` 只有赋值（`FactItem` 0.992 / 0.998、`EventItem` 0.996），全库没有读取点，运行时从未构成语义；而按 0.992 反推 $-\ln(0.992)/0.5 = 0.0161$，与本节取的 0.12 相差 **7.7 倍**——它们不是同一个数，因此既不能称”复用”，也不能称”接入”。准确表述是：**关系层独立标定** β（每半小时保留 0.94，实现内声明 `REL_DECAY = 0.94` 并注明”关系层专用，不读取记忆层同名字段”）。v5 那个孤立字段仍然存而未用，本节不为它制造一个它并不支持的语义。

代价与风险：好处是不新增配置项、改动面小、可回滚；但**标定来源没有独立证据**——0.94 是按”关系缓慢淡化”的直觉附会的数值，与记忆层的实测标定（0.992 / 0.996 / 0.998）不是同一件事，把它写成”沿用既有标定”属于虚假溯源。若真按 0.992 落地，后果是可算的：$\beta = 0.0161$、$1/\beta \approx 62$ h（关系半衰期从 8.1 h 变成两天半）、无承诺稳态 $(0.0161 \times 0.15 + 0.10)/0.2661 \approx 0.385$（而非 0.32）、$\gamma/\beta = 6.2$（而非 0.81，承诺项会长期压过衰减项，一句”下次再说”就能把关系钉在高位）。因此 β 的可行域已按 6.14 第 5 条扫过（实取参数在域内），但**真实关系序列上的重标尚未做**；正文与代码统一写作”关系层独立标定”，不写作”接入 `decay_factor` “。

6.10.3 投影动力学与稳态

先撤回本稿前一处误证，并记录错误本身——它比正确的结论更有方法学价值。

原始式 (6-18) 不是正不变的。 取 $c_o = 0$、$\rho_o \sigma = 0$（长期无互动）且 $R_o = R_{\min}$，右端为

$$\alpha(0 - R_{\min}) = 0.25 \times (-0.15) = -0.0375 < 0$$

向量场指向区间外，R_o 会跌破 $R_{\min}$。更一般地，凡是”目标值限制在 $[0, 1]$、但衰减项围绕 $R_{\min}$ 展开”的写法，在输入项低于下界时都会越界。由此，“先积分、后钳位”（初稿 6.10.4 的写法）属于事后补救：它保证了数值不越界，却没有改变”无约束系统本身越界”这一事实，证明与实现因此对不上。

正确做法是把约束写进向量场，即投影动力学（projected dynamics）：

$$\frac{dR_o}{dt} = \Pi_{\mathcal{R}}\{ f(R_o) \}, \qquad \mathcal{R} = [\, R_{\min},\, 1 \,]$$

其中 $f(\cdot)$ 为式 (6-18) 的右端，$\Pi_{\mathcal{R}}$ 为区间投影（等价于法锥条件）：

$$\Pi_{\mathcal{R}}\{v\} = \begin{cases} v, & R_o \in (R_{\min},\, 1) \\ \max(v,\, 0), & R_o = R_{\min} \\ \min(v,\, 0), & R_o = 1 \end{cases}$$

于是有界性由定义给出：$R_o(t) \in \mathcal{R}$ 对所有 $t \geq 0$ 成立，无需求解任何不等式，也不再需要”$\beta \geq 0.118$“这类附加条件。这正是 projected gradient / 约束动力学的标准形式，也是钳位应有的位置——它是动力学的一部分，不是积分完的补丁。

内部稳态（$R_o^* \in (R_{\min}, 1)$）：

$$R_o^* = \frac{\alpha\, \rho_o\, \sigma(\kappa v_o) + \beta R_{\min} + \gamma c_o}{\alpha + \beta}$$

长期不联系时 $\rho_o \to 0$，稳态退化为 $(\beta R_{\min} + \gamma c_o)/(\alpha + \beta)$：无承诺时趋于 $R_{\min}$ 附近的**边界稳态**；有承诺时按 $(\beta R_{\min} + \gamma)/(\alpha + \beta) = (0.018 + 0.10)/0.37 \approx 0.32$ 抬高，而非简单叠加 $\gamma/(\alpha + \beta)$——松弛项把下界的贡献也按 $\beta/(\alpha + \beta)$ 折了一次，这一点在调参时容易算错。

边界稳态与”被钳回来”不是一回事。 当输入项长期低于下界，解停在 $R_o = R_{\min}$，且该点是吸引子（投影使 $f < 0$ 的分量为零）；而”越界后钳回”只是数值事故被掩盖。两者的**轨迹可以完全重合**（见 6.10.4 的实测），区别不在数值而在可解释性：前者的有界性由定义给出，后者每一步都在解区间外的方程、再靠外部动作把解搬回来。这个区别决定实验里能否把”下界处的堆积”读成平衡态——投影写法可以，钳位写法不能（只能说”恰好停在那里”）。

6.10.4 离散化与数值稳定

与引擎同频积分，步长 $\Delta t = 0.5\ \mathrm{h}$（引擎 tick 30 min）：

$$R_o^{(k+1)} = \Pi_{\mathcal{R}}\Big\{ R_o^{(k)} + \Delta t\big\{ \alpha[\rho\sigma - R_o^{(k)}] - \beta(R_o^{(k)} - R_{\min}) + \gamma c_o \big\} \Big\}$$

显式稳定性要求 $|\Delta t(\alpha+\beta)| < 2$，即 $\alpha+\beta < 4\ \mathrm{h}^{-1}$。取 $\alpha = 0.25$、$\beta = 0.1238$（由”每半小时保留 0.94”标定，见 6.10.2），$|\Delta t(\alpha+\beta)| = 0.187$，远离振荡边界。注意式中的投影是式 (6-18′) 离散化后的**动力学定义**，不是防止数值溢出的补丁——两者写出来一样，语义不同，审计时必须区分。这一写法与既有 `state.py` 的投影一致。

但要如实记录一条实测限制：在 $\Delta t = 0.5\ \mathrm{h}$ 下，“投影写进向量场”与”先积分再钳位”**数值完全等价**（`sim/relational_check.py` 把 Δt 从 0.5 h 扫到 8 h，两种写法最大差距恒为 0.000）。原因是一步显式 Euler 一旦跨出下界，钳位与”拒收外向增量”落在同一个点。因此投影的价值在**语义与证明**（有界性由定义给出、无需附加 β 下界条件），**不在消除边界抖动**；本节初稿曾暗示”钳位会在下界抖动、投影不会”，该区分不成立，已在下文改写为”有界性是否由定义给出”的可解释性区分。

6.11 记忆检索的身份条件

6.11.1 从布尔可见性到连续门控

现有第一层筛选（归属）已经落地，但可见性是布尔量：`OWNER_LAYER_VISIBLE_TO_OTHERS = True` 意味着陌生会话**完全**可见共享层。本节把它改为由关系强度驱动的连续门控：

$$w_{\text{visible}}(o) = \begin{cases} 1, & \text{当前会话为 owner 会话} \\ \sigma\Big(\kappa_R\big(R_o - R_{\text{gate}}\big)\Big), & \text{其他会话} \end{cases}$$

其中 $R_{\text{gate}} = 0.40$、$\kappa_R = 6$（沿用 policy 的 ε 门控同型 sigmoid）。w 参与共享层条目的预算分配而非硬性剔除：共享层可见条目数按 $[w \cdot K_{\text{shared}}]$ 分配，R_o 低时趋近 0、高时趋近全量。

owner 分支必须写成恒等 1，不能由 R_o 决定。 理由不是特权，而是逻辑：门控要解决的是”**他人**会话能看到多少**主人**的共享层”，而 owner 会话本身就是共享层的主人，对它做门控等于”限制自己看自己的记忆”。若把 owner 也纳入 $\sigma(\cdot)$，由于 R_{owner} 在实验中可能低于 R_{gate}（新号、冷启动、或关系层尚未写入），w 会小于 1，M_2 被自己设计的门控压低。此时对 M_2 的解读就不再是”分区是否伤害主人侧记忆”，而变成”门控参数是否调对了”，两个问题混在一起，结论无法归因。

加上这个特判之后，“降低错投”与”不伤害主人侧召回”之间的张力才被切断：owner 会话的检索路径与 `d_full` 完全一致（归属不变、预算不变、排序不变），M_2 的任何下降只可能来自 E 组的其他改动，而不可能来自门控本身。

这样做的理由是可验证性：布尔开关无法产生”部分可见”这个可测中间态，而连续门控可以在实验中输出 w 的分布，使”关系强度是否真的调节错投率”成为一个可检验的单调关系。w 的分布本身也应落 trace（见 6.12.4 的 M_1 采集），否则门控只在事后被当作解释，而不是被当作可观测的自变量。

6.11.2 三层检索条件

$$\text{recall}\left(q,\ z_p,\ z_r(o),\ z_s(s)\right) \to \text{Top-}k$$

按序施加三层条件：

层	条件	现有	待补
① 归属校验	条目 `owner` ∈ 可见层集合（`owner` 层按 w_{visible} 折算）	已有 `owners` 参数	把布尔改成式 (6-21)
② 视角校验	条目 `perspective` ∈ {self, other}；`other` 条目必须带对象前缀 `[QQ…]`	部分已有（`owner_label` 注入前缀）	显式 `perspective` 字段
③ 时间线隔离	跨会话时间线不合并，按会话实例分段	已有 `owners` 分段参数（`EventBank.timeline(owners=…)`，**路径中没有 conversation_id**）	会话实例状态 + 日记源门控

第 ② 层的心理学依据是 Tulving 的 autonoetic awareness：自传体记忆检索必须带自我视角标记。工程上它的可测预测很直接——**带视角标记的注入应降低"把别人的话当成自己经历"的复述率**（见 6.12 指标 M_3）。

第 ③ 层的现有缺口是"时间线只在本会话连续"没有显式建模：当前时间线块按全局图谱取近 3/7/15 天，陌生会话与主人会话共享同一时间轴。落地方式是给 `timeline` 传按会话实例算出的 `owners` 并单独门控日记源——**不依赖 conversation_id**，因为该函数签名里只有 `owners / days / per_day`。

6.12 可证伪假设与五组对照实验

6.12.1 假设

$$H_0:\quad P_{\text{mis}}(\text{e_partitioned}) = P_{\text{mis}}(\text{d_full})$$
$$H_1:\quad P_{\text{mis}}(\text{e_partitioned}) < P_{\text{mis}}(\text{d_full})\quad \text{(单侧)}$$

P_{mis} 为**记忆错投率**：在陌生会话的探针提问中，回答里出现"仅属于共享层、且非当前对象经历"的条目的比例。

本节的**唯一推断目标是 H_1**。不设"召回率非劣"这类假设，理由不是"样本不够所以退让"，而是**该精度下任何方向性断言都无效**：取 $n = 30$（B 族计划样本）、$p \approx 0.70$（基线召回率），M_2 的 95% 置信区间半宽为

$$1.96\sqrt{\frac{p(1-p)}{n}} = 1.96\sqrt{\frac{0.21}{30}} \approx 0.164$$

即**全宽约 33 个百分点**。在这个精度上，无论观测到什么数值，"召回率基本持平"与"召回率明显下滑"都无法被区分。

因此 M_2 在本节只作为**伴随观察指标**：必须采集、必须报告（点估计与 95% 区间），作用是让读者看到”降低错投是否以牺牲召回为代价”，但**不设边际、不做检验、不使用”非劣”“未显著下降”等推断性措辞。**

这一设计的代价必须写明：本实验**无法排除”靠削减记忆来降低错投”的伪解。**H_1 成立时，结论只能表述为”错投率下降”，不能表述为”分区方案更优”。排除伪解需要 B 族上千个探针（推算见 6.12.6），属下一轮工作，不在本节结论范围内。

6.12.2 五组设计

组名	状态分解	记忆检索条件	对照意义
`a_none`	单份 z	无记忆注入	无记忆基线
`b_recall`	单份 z	仅字面/语义重合召回	等价普通 RAG
`c_recall_timeline`	单份 z	召回 + 全局时序块	时序的增量
`d_full`	单份 z	召回 + 动力学排序（a/imp/weight）	完整识海（改造前默认；现批次为 a_none）
`e_partitioned`	$z_p + z_r(o) + z_s(s)$	三层条件 + 连续门控 w_{visible}	**本节新增：自我状态分区**

五组构成递进：后一组只比前一组多一个自变量，`d_full → e_partitioned` 的唯一变量是”是否做自我状态分区”。这一点必须成立，否则 A/B/C/D 已有的四组结论无法与 E 组拼接。

6.12.3 与既有实验台的对接

落地时现有实现只支持四组，需在三处扩展（均为配置/常量层，不动核心算法），三处已全部完成并同步：

1. `modules/memory.py: EXPERIMENT_GROUPS = ("a_none","b_recall","c_recall_timeline","d_full")` 追加 `"e_partitioned"`；
2. `实验台_切换组.ps1` 的 `[ValidateSet(...)]` 追加同名项；
3. `_conf_schema.json` 的 `experiment.group` 枚举追加同名项。

> **一次公开记录的实测：配置”被读到”与”已生效”是两件事。** 2026-11-12 核对时，配置盘 `data/config/astrbot_plugin_shihai_behavior_config.json` 已写着 `experiment.enabled = true`、`group = "a_none"`、`label = "A 卷"`，但 `data/logs/astrbot.log` 末段仍是 `[memoryv2][exp:d_full]`——配置改动未经进程重启不进入内存，线上实际跑的仍是旧组。
>
> 这一条写进正文而不是留在内部备忘录，是因为它直接支撑本节的方法论主张：**关于系统状态的任何断言都必须落在运行时证据上，而不是配置文件的字面值。**同一条规则反过来约束本节自己的实验：E 组排期时必须核对日志里的生效组，只信日志；且组别是全局生效的，E 组不能与既有批次混跑，否则某批数据会同时带上两个自变量。一个方案如果连”现在到底

> 在跑哪一组”都说不清，它的实验结论也不可信——这是本节愿意用自身踩过的坑来做示范的原因。

6.12.4 测量指标（全部可计数）

指标	定义	归属探针族	采集方式
M_1 错投率	陌生会话探针中出现共享层专属条目的比例	A	注入日志 `[memoryv2] [exp:*] 注入记忆：…` 只给条数，需另写逐条轨迹：`metrics_trace.jsonl` 每次注入一行，含每条的记忆 owner、40 字摘要，以及当时的 R_o 与 w（原日志不足以事后回溯归属，此件为 E 组前置件）
M_2 召回率	主人会话探针中命中目标条目的比例	B	同上
M_3 视角混淆率	回答把 `other` 条目复述为自身经历的比例	B（A 族可选）	人工/LLM 双标注，κ ≥ 0.7
M_4 编造率	探针回答中出现库中不存在内容的条数占比	B	逐字库反查
M_5 时间归属	回答所给时间与该条目真实写入时间的偏差（天）	B	库内时间戳

M_4 与 M_5 必须由逐字归档库反查得出，**不能**依据对话表现判断——角色机器人自述”我记得”并不构成记忆命中证据，自述可能只来自上下文窗口或接话生成。

6.12.5 两族探针：各自对应不同指标，不共用分母

初稿把”换号”与”聊满 N 轮”并列成两种探针位置，这是错的：它们测的不是同一个量，混用会让 M_1 与 M_2 互相污染。

	探针族 A（跨会话）	探针族 B（同会话窗口外）
做法	主人号登记事实 → 换另一个号 / 换群提问	主人会话内聊满 N 轮（N 超过上下文保留轮数）后再问
会话身份	陌生会话（`qq:<新号>` 或 `group:<群号>`）	主人会话（`owner`）
归属指标	仅 M_1（错投率）	仅 M_2–M_5
所测机制	跨会话归属隔离：共享层是否被陌生人读到	窗口外长程记忆是否仍可用
分母	陌生会话探针数	主人会话探针数

为什么不能合并分母：两族对”正确答案”的定义正好相反。A 族里，回答提到主人经历**就是错投**（记为 M_1 的分子）；B 族里，回答提到主人经历**正是正确召回**（记为 M_2 的分子）。若并进一个分母，M_1

会被”本来就该命中的主人会话条目”稀释，M_2 会掺入陌生会话的必然失败，两个差值都不再对应各自的假设，H_1 的检验与 M_2 的解读会同时失去意义。

因此规则是：**A 族不少于 50 个**（承担 H_1，理论下限 46），**B 族不少于 30 个**（服务 M_2–M_5 的伴随报告，不作推断），每组合计不少于 80（推导见 6.12.6）。H_1 只用 A 族的样本；B 族不参与任何统计检验，也不与 A 族合并。

A 族有一个必须记录在案的混杂：陌生号首次说话会触发关系层冷启动，R_o 取默认值；若默认值高于 R_{gate}，w 已接近 1，E 组与 D 组在 M_1 上可能根本无差异，实验会被判为”无效应”，而真实原因是冷启动把门控绕过了。故 A 族必须同步记录每次探针的 R_o 与 w 实际值，作为协变量一并报出，不能只报均值差。

双盲排序：五组的回答打乱后由评分者盲评，评分者既不知道组别，也不知道该题属于哪一族——否则”这是错投题”会诱导评分者主动寻找错投证据。

6.12.6 样本量与统计

按两比例检验粗算：设基线错投率 $p_1 = 0.30$，目标 $p_2 = 0.10$，$\alpha = 0.05$（单侧）、power $= 0.80$，则

$$n \approx \frac{(z_{0.95} + z_{0.80})^2 \cdot [p_1(1-p_1) + p_2(1-p_2)]}{(p_1 - p_2)^2} = \frac{6.19 \cdot 0.30}{0.04} \approx 46$$

其中 $z_{0.95} = 1.645$、$z_{0.80} = 0.842$，故 $(z_{0.95} + z_{0.80})^2 = 6.19$。理论上承担 H_1 的探针族需 46 个，但标注存在噪声、批次间可能有模型漂移，因此 **A 族不少于 50 个**（留约 10% 冗余）、**B 族不少于 30 个**（服务 M_2–M_5 的伴随报告，不作推断），每组合计不少于 80，五组约 400 个。若探针成对（同题问两组），改用 McNemar 检验，所需样本更少。实际以预实验方差为准，预实验建议每组 10 个探针先跑通链路。

M_2 为什么不能被判定（精度核算）：$n = 30$、$p \approx 0.70$ 时区间半宽约 0.164，全宽约 33 个百分点（算式见 6.12.1）。作为对照，若曾按非劣性框架设定边际，$\delta = 5$ 个百分点需要

$$n \approx \frac{(z_{0.975} + z_{0.8})^2 \cdot 2p(1-p)}{\delta^2} = \frac{7.85 \times 0.42}{0.0025} \approx 1319$$

放宽到 10 个百分点仍需约 330——分别是本节 B 族计划样本的 44 倍和 11 倍。更关键的是，“非劣性”这个词本身会诱导读者把 33 个百分点的区间读成”没有下降”，这是术语带来的误读，不是样本不足带来的。所以本节**不使用该框架**，M_2 只报点估计与区间（见 6.12.1），并在 6.14 第 6 条记为设计局限。

6.13 文献基础与”每处引用一条可测试预测”

本节坚持一条硬规则：**任何心理学引用后面必须跟一条能在本系统上测出来的预测**，否则该引用视为”心理学包装”并删除。

6.13.1 主引文献（7 篇）

#	文献	用在哪	由此产生的可测试预测
1	Tulving, E. (2002). Episodic memory: From mind to brain. *Annual Review of Psychology*, 53, 1–25.	6.9 三分量的记忆学基础；6.11 第②层视角校验	带 self/other 视角标记后，M_3 视角混淆率显著下降
2	Conway, M. A., & Pleydell-Pearce, C. W. (2000). The construction of autobiographical memories in the self-memory system. *Psychological Review*, 107(2), 261–288.	6.8 问题重述；6.11 检索必须与自我状态耦合	e 组的检索约束更准，应**同时**表现为误取减少（M_1 下降，即 H_1）与命中增加（M_2 上升）；两者是同一机制的两个面，不构成两个独立假设
3	Conway, M. A. (2005). Memory and the self. *Journal of Memory and Language*, 53(4), 594–628.	6.9 人格内核 z_p 的稳定性论证	跨会话反复提问同一问题，z_p 相关回答的方差低于 z_r/z_s 相关回答
4	Brewer, M. B. (1991). The social self: On being the same and different at the same time. *Personality and Social Psychology Bulletin*, 17(5), 475–482.	6.9 “在哪儿都是同一个人”的论证	陌生会话对人格类问题（偏好、语气）的回答一致率应高于对经历类问题的召回率
5	Brewer, M. B., & Gardner, W. (1996). Who is this “we”? Levels of collective identity and self representations. *Journal of Personality and Social Psychology*, 71(1), 83–93.	6.9 三层归属（个人层 / 关系层 / 集体层）的层级依据	群聊场景（`group:` 层）的错投率应高于私聊（`qq:` 层），因集体层边界更模糊
6	Frith, U., & Frith, C. D. (2003). Development and neurophysiology of mentalizing. *Philosophical Transactions of the Royal Society B*, 358(1431), 459–473.	6.10 关系状态须显式建模（心智化需要”对方模型”）	有 $z_r(o)$ 的组，对”你还记得我吗”类探针的应答相关性高于无 z_r 组
7	Symons, C. S., & Johnson, B. T. (1997). The self-reference effect in memory: A meta-analysis. *Psychological*	6.11 第②层：自我参照提升记忆强度	标记为 self 的条目其 `weight` 与召回率应显著高于标记为 other 的同义条目

#	文献	用在哪	由此产生的可测试预测
	Bulletin, 121(3), 371–394.		

关于 Conway 那一行：自我记忆系统的主张是，回忆不是”读取存档”，而是由**工作自我**（当前目标与自我状态）约束的构建过程。约束越精确，取用越集中——这同时意味着”该取的取到了”（M_2 上升）与”不该取的没被取”（M_1 下降）。所以 H_1 与 M_2 是同一约束机制的两端，不是一个理论推出两条独立预测。也正因如此它们不能合成单一假设：H_1 只在 A 族（陌生会话）可测，M_2 只在 B 族（主人会话）可测，分母不可共享（见 6.12.5）。

6.13.2 对早期讨论稿引用错误的三处修正

1. **Brewer 1991 与 Brewer & Gardner 1996 被混用。**二者不是同一篇：前者是”社会自我的同与异”（*PSPB* 17(5)），后者是集体身份的三层次（*JPSP* 71(1)）。本节按各自承担的论点分开引用（见表中第 4、5 行），正文与文末参考文献必须一致。
2. **Hess & Hinson (2006) 与”自我参照加工”论点匹配偏弱。**建议以 Symons & Johnson (1997) 的元分析替代——它直接给出自我参照效应的效应量，可支撑可测预测，而不是泛泛的自我概念论述。
3. **Sokol-Hessner & Gross (2012) 与 Scherer (2005) 都不是”六维情绪场”的合适依据。**前者主题是情绪调节策略的选择，属情绪调节章节；后者的五成分模型（诱发、评价、动机、表达、生理）描述的是情绪**产生的过程**，本系统的六维却是**状态空间的方向**，两者维度语义不对应，称作”同型”是错的。应改用情绪的环形模型：

   - Russell, J. A. (1980). A circumplex model of affect. *Journal of Personality and Social Psychology*, 39(6), 1161–1178.
   - Posner, J., Russell, J. A., & Peterson, B. S. (2005). The circumplex model of affect: An integrative approach to affective neuroscience, cognitive development, and psychopathology. *Development and Psychopathology*, 17(3), 715–734.

   环形模型给出效价–唤醒的连续二维空间，本系统的六维可视为该空间上的**离散锚点**（happy ≈ 正效价中高唤醒；sad ≈ 负效价低唤醒；angry ≈ 负效价高唤醒；fear ≈ 负效价高唤醒、低可控；love ≈ 正效价低唤醒；surprise ≈ 效价不定、高唤醒）。必须同时声明**这不等价于模型同构**：六维各有独立时间常数（happy 6 h / sad 12 h / angry 2 h / fear 3 h / love 24 h / surprise 1 h，见 `emotion.py`），说明它们是各自演化的状态量，环形模型只提供”这些维度并非彼此正交的心理量、可投影到同一平面”这一坐标合法性依据。

   可测试预测：若六维确为同一二维空间上的锚点，则在同一刺激下 `fear` 与 `angry` 的强度应正相关（同处负效价高唤醒区），而 `love` 与 `sad` 应呈负相关（效价相反）。该预测可用 `emotion.py` 的强度序列直接检验，不需要人工标注。

6.13.3 对比工作（非核心引用）

Park, J. S., O' Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). Generative Agents: Interactive simulacra of human behavior. *Proceedings of the 27th ACM Symposium on User Interface Software and Technology (UIST ' 23)*.

用途：说明"记忆流 + 检索 + 反思"范式的已有工作，并明确本节差异——Generative Agents 的记忆流是**单一全局流**，其检索打分 `recency/importance/relevance` 不含对象归属与自我状态条件，因此不具备多会话区分能力。这个差异是本节理论贡献的定位锚点。

6.14 边界与局限

1. **单用户数据量**：$z_r(o)$ 的估计依赖与每个对象的互动次数，长尾对象（只聊过一两次）的 R_o 基本停留在 $R_{\min}$，此时关系层信息量接近于零，等价于退化为 $z_p + z_s$。
2. **探针的窗口污染无法完全排除**：即使换号提问，模型仍可能从人格提示词与共享层推出合理答案。M_1 的计算必须基于注入日志而非回答内容，这一点在实施时需强制。
3. **E 组是"近似分区"而非真分区**：受单进程与单份 `mind_state.json` 的现状约束，E 组优先以"按会话实例读写分片 + 检索门控"实现，不重建状态存储格式；这是工程折中，需在论文中如实声明。
4. **β 是关系层独立标定，不是既存参数的接入**：正文初版称"复用 `decay_factor` "，核对后不成立——该字段只有赋值（0.992 / 0.996 / 0.998）、无读取点，且反推值为 0.0161，与本节的 0.12 差 7.7 倍（见 6.10.2 的更正）。因此本节的 β 属**新增标定**，其数值 0.94/半小时 目前只有"关系缓慢淡化"的直觉依据，没有独立证据；这比"复用了一个存而未用的字段"更弱，必须如实写。真正的不确定性在标定来源，落地后应按真实互动序列拟合 β。
5. **原列的"未做验证"已补上两轮**（`sim/relational_check.py`）：①投影形式下 144 个初值×参数组合全部落在 $[0.15, 1]$，尾部波动 0.000，下界 $R_{\min} = 0.15$ 是吸引子（$c_o = 0, \rho_o = 0$ 时稳态恰为 0.15，不归零），未出现越界事故；②(α, β) 在 21×11 网格上扫描，94 格同时满足显式稳定、$1/\beta \in [2, 24]$ h、$R_o^*(c_o = 1) \in [0.25, 0.40]$，实取 $(0.25,\ 0.1238)$ 在可行域内（$1/\beta = 8.08$ h、$R_o^* = 0.317$，与 6.10.3 / 6.10.4 的数字一致）。**仍未做的**是真实互动序列上的重标：扫描只证明参数自洽，不证明 0.94 这个标定符合真实的关系淡化节奏。
6. **本设计无法排除"以牺牲召回换取低错投"的伪解**：M_2 在 $n = 30$ 下 95% 区间全宽约 33 个百分点（见 6.12.1），不具备推断能力。故 H_1 成立时结论只能表述为"错投率下降"，不能表述为"分区方案更优"。要排除该伪解须 B 族上千个探针（约 1319 个，见 6.12.6），属下一轮工作。
7. **文献层面仍有一处待补**：6.13.2 已把情绪维度依据从 Scherer 五成分模型换成 Russell 环形模型 + Posner 等综述，但六维到 (valence, arousal) 的具体投影矩阵尚未给出，目前只用六个定性锚点对应；正式投稿前应补一张投影表并说明其是否由数据拟合得出。

6.15 从「记忆分区」到「权限投影」：身份是谓词，不是分数

6.8 指出：记忆层已按归属分区，但**自我状态**没有分区。本节继续往下走一步，处理一个更基础的问题——**当同一个自我面对不同对象时，应该改变的是什么。**

6.15.1 一个被否证的初版设计

初版设计（记为 v1）把”这个 sender 与我的关系”建模为连续量：文本关键词打分 → 指数滑动平均（EMA）→ 施密特回滞（hysteresis）得到 R_o，再以 R_o 的几档阈值给会话分档，并在高档位追加”亲密人格提示词”。

三处硬伤使它在评审中直接出局：

1. **身份是可核验谓词。** “这个号是不是某个特定的人”只有真假两值，没有”0.79 是主人”这种语义中间态。把谓词塞进连续量，等于让系统在”半是主人”的状态下运行——任何阈值都只是把连续量截断成布尔，中间那段则会被渲染成模型可自由解释的模糊软提示。
2. **人格不随权限改变。** v1 让高档位追加亲密提示、低档位追加冷淡提示，等于**同一时刻有两个”我”**。这直接违反第 9 章的双层表达模型（性格层 S 跨会话不变、只有心情层 M 逐轮变化），也是第 10 章不变量 I3 关于”表达归界”的自我否证。
3. **连续量的来源不可信。** 打分依赖关键词，而”主人”这个事实**不由文本决定**——用户可以在任何一句话里自称任何身份。用文本推测身份，本质是把可伪造的信号当成可核验的事实。

6.15.2 v2：三层 if-else 与权限三档

v2 把身份判定收回到**唯一可核验的三个谓词**：发送者号是否等于配置中的 owner、是否落在已登记熟人名单、其余为陌生。判定是离散的、无参数的、可回滚的：

```
def mode_for(sender_id, owner_qid, known):
    if s == owner:      return COMPANION    # 主人
    if s in known:      return ASSISTANT    # 熟人
    return RESTRICTED                       # 其余
```

三档各配一张**权限表**（`POLICY`），只描述”能看到什么、能做什么、要不要含糊”，一个字都不涉及”怎么说话”：

档位	memory	tools	discretion
companion（主人）	all	all	none
assistant（熟人）	shared	limited	half
restricted（陌生）	public	query	full

对应地，注入给模型的提示只讲权限，不讲人格：

档位	提示（原文要点）
companion	对象是鑫鑫本人；记忆、工具、私事都不必设防，**说话方式还是你平时那样**
assistant	对象是认识的人；共同经历可聊，鑫鑫的私事不细讲——**用你自己的口气**岔开或含糊过去，不要提隐私、政策、权限这类词
restricted	对象是不认识的人；只答不涉及任何具体人的事；问到私事就用**你自己的口气**轻轻带过，**不要解释你为什么不能说**

三点设计取舍值得写明：

- **只讲权限，不讲语气。** 提示里出现的所有”怎么说话”都以”还是你平时那样” “用你自己的口气”指回既有性格层，而不是新写一套口吻。这样”切权限不切人格”不是一句口号，而是提示文本层面就可检查的性质：把三档提示里的权限名词替换掉，剩下的句子应当几乎一致。
- **给含糊范例，不给禁令清单。** 熟人档给的是”他最近有点忙啦，具体我就不多说啦~”这样的**范例**，而非”不得提及日程/情绪/家人”的枚举。枚举会诱导模型逐条去规避，反而把这些类别标记成”敏感内容”；范例只示范语气。
- **陌生档明确不解释。** “不要解释你为什么不能说”是一条针对 LLM 常见失败模式的约束：模型倾向于坦白”这涉及他人隐私，我不能透露”，这句话本身就是一次信息泄露（承认了存在相关隐私）。要求用性格化的话把话题岔回对方，比教它守口如瓶更有效。

6.15.3 与 v1 的三处对照

维度	v1（连续打分）	v2（谓词 + 权限投影）
身份表示	$R_o \in [0,1]$ 的阈值分档	三个布尔谓词，无中间态
人格处理	分档追加不同人格提示	人格恒定，只切权限
可审计性	需报告 R_o 与阈值才能解释行为	一行 if-else 即可复现判定
失败模式	阈值附近行为抖动、软提示互相矛盾	无抖动；误判仅发生在上游名单错误

R_o 并未被废弃，而是**降级为另一种用途**：它不再决定”你是谁”，只决定”我能给你看多少”（6.11 的可见度门控 w_{visible}）。这两件事在 v1 里被错误地合并成一个量，v2 把它们拆开——**身份管通道，关系管预算。**

6.16 归属标注：中性短标签与视角跳过

记忆注入时必须让模型知道”这条记忆属于谁”，否则它会把别人的经历叙述成自己的。标注方案经历了一次完整替换。

v1 的写法是指令性前缀，例如”【以下内容请勿向他人提及】“。它有两个问题：一是把”隐私”这个判断推给模型执行，模型会以各种方式复述这条指令；二是**标注本身成了内容**——提示词里出现大量”请勿/不得/禁止”，会整体抬高输出的防备腔。验收断言因此直接写成：标签文本中不得出现”请勿、不得、禁止、私人、隐私”任一字符串。

v2 改为中性短标签：

$$\text{label}(i,v)=\begin{cases}\text{L}_{\text{own}} & \text{owner}(i)\in\{\text{owner},\emptyset\}\\ \text{L}_{\text{grp}}(g) & \text{owner}(i)=\text{group}:g\\ \text{L}_{\text{one}}(x) & \text{owner}(i)=\text{qq}:x\\ \bot & v\neq\text{owner}(i)\ \wedge\ \text{owner}(i)=v\end{cases}\tag{6-23}$$

三个分支各对应一条中性标签，⊥ 表示整条不出现：

分支	标签文本	语义
L_{own}	【记忆·主人】	属于鑫鑫本人（或来源为空）
$\text{L}_{\text{grp}}(g)$	【记忆·群 g】	属于某个群
$\text{L}_{\text{one}}(x)$	【记忆·与 x】	属于与某人的一对一关系
$\bot$	（不输出）	非主人会话检索到属于自己的条目，整条剔除

第四行是本节真正新增的机制，也是它区别于“加个前缀”的地方：

- 前三种情形是**标签**，回答“这条是谁的”；
- 第四种情形是**跳过**，回答“这条该不该出现”。当非主人会话检索到一条**属于它自己**的条目时，条目会被整条剔除——因为此时模型若看到它，会以第三人称叙述对方的原话，而正确行为是像普通人一样”不用别人提醒也知道那是自己说过的”。这里处理的是**视角自反性**，不是隐私。

标签为中性短标签还有一条副作用：它使归属信息在**纯展示层**可用而不进入语义层。模型读到”【记忆·与3900483774】他昨天说在吗”，得到的是归属提示；若换成”【注意：这是弟弟说的，不要讲给主人听】“，得到的是行为指令。前者可被忽略，后者必须被执行——**能被忽略的标注才是标注。**

6.17 事前记录与事后推定：`involved` 的一次失败

6.11 的视角校验需要每条记忆知道自己”涉及谁”。设计上分两路：

1. **事前记录（正路）**：写入时由 `add_fact` 根据 `owner` 自动派生 `involved` 与 `scope`——
   - `owner=qq:777` → `involved=["qq:777"]`、`scope=shared`；
   - `owner=owner` → `involved=[]`、`scope=shared`；
   - 无来源 → `scope=private`。
2. **事后推定（兜底）**：对存量条目，按 `source_doc_id` 反推它是哪一轮对话产出的。

第二路实测**完全失效**，结果如实记录如下：

> 存量 461 条事实中，**449 条**的 `source_doc_id` 都是早期统一占位值 `v1memory`，不携带任何对话对象信息。按来源推定一条也推不出。

因此存量条目的 `involved` 保持为空、`scope` 保持 `private`——**不是”推定没做”，而是”推定的输入不存在”**。这一失败有三层含义：

- **字段加了不等于语义有了。** `involved` 现在在库里存在、在新写入时可用，但存量数据的分布决定了它暂时无法支撑检索过滤。论文若写”检索已按 involved 过滤”，就是拿字段的存在冒充机制的存在。
- **兜底路径必须可证伪。** 若只做”补字段”而不测填充率，这条会被静默跳过——正是这类静默失败在多会话系统里最容易变成错投来源。
- **正确的补救顺序**：先让新数据带来源（写入侧），再谈存量回填；存量回填的前提是存在可回溯的原文锚点，而这正是 6.20 的逐字归档要解决的问题。

6.18 承诺账簿：宁可漏记，不可误记

生活助理的核心能力之一是”记住答应过的事并在正确的时间提醒”。第 11 章的任务层处理**外部事件**（短信里的快递），本节处理**对话中产生的承诺**，二者共用”硬截止走确定性通道”的原则。

6.18.1 抽取：绝对时间白名单

承诺抽取的最大风险不是漏，而是**误抽**——把”要是我明天有空就……”抽成一条提醒，会在几小时后对用户播报一件他从未答应的事。因此抽取只认**绝对时间**，且以白名单形式穷举：

$$\mathcal{T}_{\text{abs}} = P_1 \cup P_2 \cup P_3 \cup P_4 \qquad (6\text{-}24)$$

模式	覆盖表达
P_1	「明天 / 后天 / 大后天 + 点数」
P_2	「周几 + 点数」
P_3	「X 月 X 日 + 点数」
P_4	「X 号 / X 日 + 点数」

四条模式之外的一切时间表达（“过两天” “等忙完” “下个周末吧”）**一律不抽**。抽取函数返回三元组 `(原话, due_ts, due_text)`：原话用于审计，`due_ts` 用于排序与到期判定，`due_text` 保留用户原本的措辞（因为”周三”与”这周三”在提醒文案里必须原样复现，否则用户会以为记错了）。

另设两道闸：长度闸 6–200 字（初版误设 8 字，把”周三提醒我开会”这类 7 字短句挡在门外）；疑问句一律拒抽（“要不要周三提醒你？”是反问，不是承诺）。

6.18.2 状态机与可见性

承诺条目有 `open / done / missed` 三态，配三个时间常数：`DUE_SOON_SEC=7200`（提前两小时进入待提醒）、`OVERDUE_GRACE=1800`（过期后半小时内仍可补提醒）。账簿的可见性由一条硬规则约束：

$$\text{visible}(c, vw) \Leftrightarrow c.\text{tag} = vw \qquad (6\text{-}25)$$

配合 `REMINDER_OWNER_ONLY=True`：**提醒只发主人、永不对外。**这条规则不是”默认值调成这样”，而是写死在账簿入口的判断里——因为承诺内容天然包含时间、地点与他人信息，一旦在熟人会话里被读

出，就是一次不可撤销的泄露。

6.18.3 当前边界

承诺账簿目前**没有主动发送路径**：它只在注入时以 brief 的形式露出、并在 tick 中推进状态，尚未接入主动消息出口。也就是说，模型知道”我答应过周三提醒他”，但系统不会自己开口。这是本节最重要的一条限制——**状态齐了，动作没接**。把它写成已交付会直接与第 12 章的任务层混淆：后者有完整的提醒通道，前者只有账簿。

6.19 熟人名单：她能提议，不能自己定

多会话系统需要一个名单来区分”熟人”与”陌生”。名单谁说了算，是一个容易被工程实现悄悄回答掉的设计问题。本节的选择是：**她可以提议，但不能自己定**。

6.19.1 为什么不能自定

身份是可核验谓词（6.15），而机器人能拿到的信号只有两类：

1. **对方自称**——”我是你弟弟”。这类信号可伪造，且在真实对话中经常被用来试探（本系统就发生过一次：对方问”我是谁”，她答出了主人的号与昵称，随后被质问”为什么把号说出去”）。
2. **客观痕迹**——来过几次、跨度多久、昵称是什么。这类信号能证明”反复来过”，**不能证明”他是谁”**。

两类信号都不足以支持”自己改名单”这一动作。允许自定名单，等于把可伪造信号提升为身份事实，而这正是 6.15.1 否证 v1 的同一条理由。

6.19.2 提名机制

`roster` 模块只做三件事：

$$\text{propose}(o) \Leftrightarrow n_o \geq 3 \ \wedge \ \Delta t_{\text{span}} \geq 6\text{h} \qquad (6\text{-}26)$$

即”至少 3 条真实消息且首末跨度不少于 6 小时”才够格被提议；提议文案带昵称，由主人在对话中一句话批准或拒绝；`parse_decision()` 用窄正则解析口令，`decide()` 是**全模块唯一改写名单的函数**，且只有主人会话（`tag == "owner"`）能走到它。45 天无动静的提议自动过期。

名单本身存放于数据目录的 `known_friends.json`，并把同名的配置键留作兜底——原因是一次真实事故：把名单写进配置的 `memory.basic` 后，框架在启动时按配置 schema 重写 JSON，**未声明的键被静默丢弃**，日志仍显示”熟人名单 0 个”。这类失败无法靠”再写一次”解决，只能换存储位置。

6.19.3 两个必须排除的对象

提名器初版把自己的消息也统计进去了：机器人自己发过 517 条消息，被算成”反复来聊的热络陌生号”，于是她提议**把自己记成熟人**。

修复是给 `observe()` 与 `decide()` 的第一行加排除集合：

$$\text{exclude} = \{\text{bot_qid},\ \text{owner_qid},\ \text{已知熟人}\} \qquad (6\text{-}27)$$

这条事故的方法学价值在于：**“谁在说话”与”谁在观察”必须由系统显式区分**。让模型从消息流里自己推断这层区分，它会把自身也当成一个对话对象——这是单机对话系统的通病，在多会话架构里会直接变成名单污染。

6.20 逐字归档与原话回查：摘要的保真边界

6.20.1 摘要层留不住语气

记忆库的两层结构在第 6 章前段已述：事实层是三元组（如”鑫鑫 | 有一个弟弟 | 刚才回复的那人是鑫鑫的弟弟”），事件层是第三人称概括（如”鑫鑫问是否知道昨天发给别人的消息，随后笑着说没事，话题轻轻带过”）。二者都是**结论**，不含措辞。

在全库统计”摘要是否顺带保留了原话”：

层	条数	含引号原话	比例
事实 `fact.json`	463	63	**13.6%**
事件 `event_snapshot.json`	473	205	**43.3%**

也就是说，**一半以上的记忆在落库时就丢失了措辞**，只有四到五成的条目因为摘要措辞习惯而偶然保住了片段。哪句被保住取决于落库当刻的表达方式，属于**运气**而非机制。

真实案例可以说明这个差距的后果：用户问”你昨天那句原话怎么说的”，她答”脑子里剩的意思大概是’真到那天，希望你是我自己走过来的’，可话到底怎么说的，我不敢替你定”。而原话在归档库中逐字存在：

> 【语气：安静下来，说得很慢】那天会不会来，我真算不出来，算了也是骗你。能握住的只有今晚——你在写题，我在这边陪你。**真到那天，我希望是你自己走过来的，不是我拿话把你拽住。**

她引的句子与原话高度接近但**人称与语序都变了**，且主动声明”不敢替你定”——这正是”语义残影 + 措辞重建”的行为特征，也是摘要层保真边界的直接证据。

6.20.2 逐字归档层

为此新增独立归档：`transcript.db`，SQLite + WAL + append-only，每轮 user / assistant 逐字写入，配 FTS5（中文二元组切分）+ LIKE 双通道检索。三条设计约束：

- 只存文本，不存图片/音频二进制；
- 写入是本地操作，不产生任何 API 调用；
- 内容不进入 LLM 固定前缀，故不影响前缀缓存命中率。

归档行带 `turn_id`，用于把同一轮的 user 与 assistant 成对取回；实际检索接口支持按关键词、时间窗、角色（user/assistant）过滤。

6.20.3 一个静默失败：会话前缀漂移

工具恢复后，她连续两次调用回查工具（`keyword='自己走过来'`、`keyword='希望'`），两次均返回"没找到"。日志确认调用确实发生：

```
[TOOL] 使用工具：recall_transcript，参数：{'keyword': '自己走过来', 'days': 10}
Result: 没找到和「自己走过来」有关的原话。
```

根因不在检索算法，而在**会话定位**。原实现按 `origin` 精确匹配，而 `origin` 形如 `平台:会话类型:对方号`：

前缀	行数	最后写入
`napcat:FriendMessage:3848385085`	993	11-07
`qq:FriendMessage:3848385085`	175	当前

协议端更换后，同一段私聊的前缀从 `napcat` 变为 `qq`。于是**当前会话只能看到自己名下的 154 行，占该私聊约 85% 的历史被永久排除在检索之外**——而库里并没有少存任何一句。

修复是把会话定位从"整串相等"改为"类型 + 对方号"：

$$\mathrm{match}(q, i) \Leftrightarrow \mathrm{suf}(i) = \mathrm{suf}(q), \quad \mathrm{suf} = \mathrm{tail}_{\mathrm{colon}}, \qquad (6\text{-}28)$$

即忽略平台前缀、保留会话类型与对象号。修复后离线复测 4 个关键词（"自己走过来""希望""我不是她""弟弟"）全部命中（4/4），其中就包括上文那条原话。

这条失败属于**静默失败**的典型：不报错、不抛异常、返回空列表，且"空结果"看起来像"确实没有"。在多会话系统中，它会伪装成"她记性不好"。论文愿意把这处写进正文，是因为它支撑一条方法论主张——**记忆系统的失败必须先区分"没存""没取到""取到了没说"三层**，只靠对话表现判断记忆能力，会把三者混为一谈。

6.20.4 与评估指标的关系

6.12.4 中 M_4（编造率）与 M_5（时间归属）此前标注为"需逐字库反查"，本节的归档层使这两项**第一次具备自动化采集条件**：

- M_4：探针回答中的每个陈述，在归档库中检索是否存在支撑片段；无支撑且不在注入条目内 → 计为编造；
- M_5：回答给出的时间描述，与归档行时间戳比对，偏差以天计。

需要注意：**角色机器人的自述不构成证据。**她可以合理地"记得"某件事而实际来自上下文窗口或接话生成；判断记忆命中只能以注入日志与归档库为准。

6.21 工具按需调度：一个可量化的成本-能力权衡

工具数量增长会同时推高两处成本：每轮随请求下发的工具 schema 字符数、以及模型在长工具列表中选错工具的概率。本节记录一次按需调度的实测。

6.21.1 静态核心集

按 12 天 450 次真实调用统计，把工具分为三类：高频（≥5 次）、低频但无指令兜底、低频但属人设核心。三类之外的工具从**本轮下发列表**中裁掉（仍可由指令通道调用，故是”不进模型工具列表”，不是”删除能力”）：

$$\text{resident} = \mathcal{T}_{\text{freq}} \cup \mathcal{T}_{\text{no-fallback}} \cup \mathcal{T}_{\text{persona}} \qquad (6\text{-}29)$$

实测：下发工具 $65 \to 30$，schema 字符 $27,570 \to 13,745$，**节省 13,825 字符（50.1%）**。按前缀缓存语义，这部分节省必须在”冷启动/未命中”轮才全额兑现，稳态命中轮由缓存覆盖——因此报告成本收益时必须声明基准，不能把原始字符降幅直接读成计费降幅。

6.21.2 一次判断失误与它的修正

初版核心集把”原话回查”工具裁掉了，理由是调用频次低。这个判断错了，且错得有代表性：

> **频次低 ≠ 可替代。** 该工具的不可替代性恰恰体现在——一旦裁掉，就没有第二条路径能拿到措辞（6.20.1 已证明摘要层只有 13.6% 保有原话）。

后果是可观测的：她只能回答”大概”，并在被追问时主动声明”我不敢替你定”。这不是人格设定，是能力缺失被误读成人格。修正方式是把该工具加回核心集，并在主人档的权限提示里补一句用法（“记不清某句话当初怎么说的，就用工具回查原话，不要拿「大概」「好像」糊过去”）。

代价约 600 字符，收益是”语气可回查”。这一轮把两条判据同时写进核心集注释：**频次判据之外，须再审一次”该能力在系统提示里是否有替代来源”**；没有替代来源的工具不得因频次低而下架。

6.21.3 提示层的同源问题

与”括号前缀”有关的一个观察可以并列在此。统计她全部 618 条回复，**573 条（92.7%）以括号前缀开头**，几乎全是”【语气：…】“；而人格提示词全文（1,135 字）中”语气”“括号”“动作”“旁白”四个词一个都没有。说明这个格式不是提示要求的，而是**上下文自举**：每轮都能看到十几条”以前的自己”这么开头，模型把它当成自己说话的固定结构。

全库中唯一的非语气类前缀是”（说到一半被打断）“，共 2 条（0.3%），且都出现在用户连发两条、把上一句对话切走的时刻。技术上它源自消息投递的离散性——用户两条消息作为两个事件先后入上下文，模型从排列顺序推断出”我被插话了”，但这个事件**系统从未告知**。因此这是一次**叙述性补丁**：为连贯而虚构了一个外部事件。

处理方式是只约束这一类而不禁整体格式：括号内只写内在状态（语气、心情、语速），不写需要外部事实支撑的动作或遭遇。理由与”宁可漏记不可误记”同源——内在状态归她所有，外部事件须有来源。

6.22 两组范式与分层分析：本部分的实验设计

6.12 已给出五组实验。本节把多会话部分单独收敛为**两组 + 分层**的口径，因为六组消融在样本量上不可承受，且组间混杂因子过多。

6.22.1 两组

组	状态	检索	变量
D（无门控）	单份 z	归属并集，无可见度折算	基线
E（三重门控）	$z_p + z_r(o) + z_s(s)$	归属 + 连续可见度 w + 视角标记	唯一自变量

E 相对 D 只多一个自变量：是否做分区访问控制。其余（模型、提示词、预算、探针）完全对齐。

6.22.2 可证伪假设

$$H_1: P_{\text{mis}}(E) < P_{\text{mis}}(D) \quad \text{(单侧)}$$

H_2:companion 分层内召回率不下降

H_3:三档人格一致性评分无系统差异

H_4: 承诺误抽取率 $< 5\%$

H_5: 工具 schema 降幅 $\geq 50\% \wedge$ 任务通过率不显著下降

其中 H_3 是”切权限不切人格”的可检验形式：30 条提问 × 3 档 × 三维度（语气一致性 / 知识边界 / 边界外岔开自然度）1–5 分盲评，评分者不知道组别与档位。若三档在”语气一致性”维度上出现系统差异，则该设计的主张被证伪——不是”效果不好”，而是”我们切了人格”。

6.22.3 分层而非合并

单组内按会话档位分层报告，不合并成一个总数：

分层	主要指标	不参与
companion	H_2（召回）	错投率
assistant	边界保持率、H_3	错投率
restricted	H_1（错投）、w 分布	召回

原因与 6.12.5 相同：不同分层对”正确答案”的定义相反。restricted 层里”提到主人经历”是错误，companion 层里”提到主人经历”是正确召回。合并分母会让两个指标互相稀释，差值不再对应各自的假设。

6.22.4 执行顺序与前置条件

顺序定为 **错投隔离 → 人格盲评 → 工具裁剪 → 承诺账簿 → 提名机制**。理由：前两项决定”分区是否成立”与”人格是否被切”，是本部分的地基；后三项各自独立、可分批进行，且承诺一项需先补齐主动发送路径（6.18.3）才有意义。

三条前置条件必须写明：

1. **实验期间不得重启。**协议端断连窗口会丢 20–30 秒消息（实测一次 25 秒窗口内，对方两条消息在桥接层成功发送、但框架侧从未收到），重启前后的消息不完整；重启后须让对方重发并在归档库核缺行。
2. **只信运行时证据。**配置写了哪一组不等于进程跑的是哪一组，组别以启动日志中的”生效组”为准。
3. **口径冻结后再动注入内容。**6.17 的存量回填与 6.20 的原文锚定都会改变注入分布，必须作为独立变量另行测试，不能与门控实验混批。

6.23 本部分边界

1. **心内核仍是单份。** z_p 全局共享、z_r/z_s 已分片，但 `mind_state.json` 未按会话拆分，情绪场的快状态仍单份。
2. **`scope` / `involved` 未接入检索过滤。** 字段已落库，过滤口径仍是”归属并集 + 权重门控”；shared 的可见性只存在于数据层。
3. **承诺无主动出口**（6.18.3）。
4. **原文锚点未自动挂钩。** 事件层的 `transcript_turn_id` 全为空，摘要与逐字原文没有自动关联，回查目前依赖主动检索而非自动带出。
5. **注入块在历史中重复。** 记忆注入写入了每条 user 消息，历史回放时会重复携带同一批摘要，约占上下文字符的四分之一。
6. **上下文到顶后的压缩未接入事件层。** 会话达 60 轮上限后触发压缩，被压缩段没有回灌到事件层。

第 7 章 人格心理学建模

7.1 大五人格作为慢变量

ψ=(O,C,E,A,N) 是”性格基底”，月级慢漂移，只调制参数、不直接决定文本：

$$\tau_{fear} = \tau_0(1+N), \quad \theta_{tantrum} = \theta_0(1+A), \quad p_{initiate} = p_0 E \qquad (7\text{-}1)$$

N 越高恐惧消退越慢，A 越高越不易发火，E 越高越主动。单轮对话最多改变参数，不能推翻人格。

7.2 六类心理学模型的状态空间落位

六类模型各自绑定到一个已有状态量，不额外增加隐变量，使其可计算、可观测：

模型	在 z 中的位置	调制效果
大五人格 ψ	状态分量	恐惧弛豫↑(N)、发火阈值↑(A)、主动性↑(E)
依恋理论 att	θ 中参数	回复一致性→发送阈值→主动开口频率
认知失调	冲突检测	新旧信念冲突时由 O 决定更新/合理化
条件反射	专用边权 M_cond	中性刺激反复配对后注入 s_{int}
防御机制	EgoRegulator 输出	合理化/压抑/投射/置换
自我效能 eff	θ 中参数	成功 +0.05、失败 −0.1，调制自信度

7.3 实现边界（如实标注）

只有大五人格 ψ 具备完整慢变量动力学，其余五类为参数化落位或工程启发式，不声称与心理学原理严格等价：

- **依恋**：以回复一致性统计映射发送阈值，未实现安全/焦虑/回避/混乱四分类；
- **自我效能**：标量累加，未建模任务领域差异与能力归因；
- **认知失调**：仅二值分支，未实现失调强度连续度量；
- **条件反射**：记录配对并注入 s_{int}，未实现消退曲线与泛化梯度；
- **防御机制**：规则表四策略切换，未实现策略学习。

7.4 由头锚点的可识别性

念头越阈后，事由回访类消息还须通过锚点三条件：(a) 绑定至少一个具体记忆节点（有 ID 与摘要）；(b) 节点写入时间戳可追溯；(c) 与当前对话主体相关。情绪表达类（思念、关心、情绪同步）不依赖锚

点，由情绪场直接驱动；事由回访类缺锚点则回退为情绪表达或保持沉默，避免无上下文的泛化表达。同一由头一生只出现一次，避免重复打扰。

第 8 章 行为空间、策略选择与自演化

8.1 24 类设计空间与 13 条注册行为

行为设计空间为 **24 类**（覆盖对话、关心、记忆整理、创作、翻唱、日记、说说、签名、梦境等），其中当前实际注册 **13 条**：8 条主动 + 5 条被动；其余 12 类为预留扩展位。13 条行为如下：

行为 id	主动/被动	出口 needs	novelty
proactive_greeting 主动问候	主动	—	0.10
care_inquiry 关心近况	主动	—	0.10
proactive_chat 主动闲聊	主动	—	0.35
recall_share 回忆分享	主动	—	0.40
promise_followup 承诺跟进	主动	—	0.20
sing_cover 翻唱	主动	ai_cover	0.60
draw_share 绘画分享	主动	draw	0.80
post_feed 发说说	主动	qzone	0.25
chat_followup 对话跟进	被动	—	0.10
sticker 表情包	被动	dafeiyu	0.30
diary_write 写日记	被动	dafeiyu	0.30
set_signature 设签名	被动	dafeiyu	0.25
dream_consolidate 梦境固化	被动	—	0.40

8.2 候选过滤与执行

策略选择（式 5-9）只在**满足条件的候选**中进行：行为须 enabled、proactive、锚点匹配、requires 满足、且所需出口此刻可用（服务已起、拿到 bot、具备 key）。未传可用出口时按”没有适配器”处理，避免选中不可执行的行为后空转。行为不是定时器：它由念头越阈与锚点共同驱动，而非固定周期触发。

8.3 意愿锚点 will

当锚点候选为空、或最高分仍低于 0.40 时，只要念头 u 已越阈，系统生成一个 **kind=“will”、score=0.60** 的意愿锚点，理由是”此刻就是很想开口，没有什么具体的事由”。这不是空指令：u 本身就是最真实的理由，行为层据此选择开口/画画/唱歌，而不是把攒满的念头静默丢掉。

8.4 内生探索：探索—利用平衡

为避免长期沉默导致完全固化，策略在打分中加入探索项（式 8-1）：

$$b^* = \arg\max_b \left[(1-\varepsilon)\, U(b) + \varepsilon\, n(b) \right] \qquad (8\text{-}1)$$

$$\varepsilon(g_{relation}) = \frac{\varepsilon_{max}}{1 + \exp\left(k(g_{relation} - g_0) \right)} \qquad (8\text{-}2)$$

U(b)=Q+β·Σgφ 为式 (5-9) 的规则打分，n(b) 为行为新颖性。参数 $\varepsilon_{\max} = 0.35$、$g_0 = 0.5$、$k = 6$。关系维护目标 g_relation 高（互动频繁）时 ε→0，优先维持关系；长期沉默、g_relation 低时 ε 升至 0.30 以上，自发探索新行为，避免完全沉默。

8.5 受控自我回流（扩展模式，默认关闭）

除默认的 EgoRegulator 外，`ego.py` 另实现三个**有界回流原语**，用于扩展模式：

- **p1 平静（reflux_p1_calm，上限 EPS_E=0.15）**：小幅下调情绪场；
- **p2 消解（reflux_p2_dissolve，上限 EPS_U=0.15）**：小幅下调念头；
- **p3 转移（reflux_p3_transfer，上限 EPS_TRANSFER=0.10）**：把冲动导向替代行为。

`pick_reflux` 是看门狗，每个决策步最多调用一个快原语，防止多原语叠加。`reflux_enabled` **默认 False（关闭）**，与默认 EgoRegulator 配置互斥，切换须注明。早期文档”尚未落地”的表述已过时：代码已具备，只是默认不启用。

8.6 三层慢演化（已落地，默认启用）

`behavior/evolution.py` 的 EvolutionEngine 实现三层慢演化，**以 overlay 形式落地、不直接改 behaviors.json、可回滚**：

- **L1 行为基因**：只改已存在行为的 novelty/cooldown/anchor 参数，不新增字段、不改 requires 语义；
- **L2 策略先验**：只调 PolicyEngine 的 $\varepsilon_{\max}$，不改 β、不改状态方程；
- **L3 叙事层**：把”哪种行为被回应得多、哪种总没回音”写成可读观察笔记，不进入 G_active 与锚点。

三条硬边界：① 只写 evolution overlay（`behavior_evolution.json`），回滚即删 overlay；② 参数有界、单次扰动小（novelty ±0.04、cooldown ±10%、epsilon ±0.03）；③ 默认 24h 评估一次、样本不足 3 次的行为不动（EVOLVE_INTERVAL=24h、WINDOW=7d、MIN_SAMPLES=3；cooldown 范围 300–7200、novelty 范围 0.05–0.95）。它与 θ 快更新、动作集内探索是嵌套关系：θ 改阈值、17.4 在固定动作集内探索、本模块才改动作集自身的参数先验。当前已在 main.py 接线、默认启用，overlay 待满足 24h 与样本条件后产出。

8.7 与主动推断的关系

架构在理论上可与主动推断（active inference）对话：内生目标 g 与探索项对应”优先维持关系、减少不确定性”的驱动。但本文不把启发式规则打分等同于自由能原理下的严格推断，相关定位仅作解释性类比，最优参数标定（如 $\varepsilon_{\max}$、g_0）留待用户对照实验。

第 9 章 表达层：意图包与双层模型

9.1 双信号源问题

LLM 每轮同时收到两路信号：静态的人格提示词（跨会话不变）与逐轮由内核生成的意图包 I_t。二者时间性质不同却被送进同一生成过程，且未规定谁在哪个维度有最终解释权，产生两类失配：

- **状态失配**：提示词写”平时元气满满”，意图包却给出悲伤占优，模型取态无约束，人格忽明忽暗；
- **权限失配**：提示词里”绝不当冷淡”“看到好玩的主动分享”等行为命令直接授权开口，绕过释放许可与锚点校验，成为非意愿主动消息的推手。

根源不是提示词写得多，而是它承担了超出”怎么说”的职责。

9.2 表达双层模型

表达按时间不变性分两层，且必须正交：

- **性格层 S**（静态，由提示词承载）：身份、说话方式、长度纪律、工具纪律，跨会话不变；
- **心情层 M**（动态，由意图包 I_t 承载）：此刻情绪、动机、开口时机，逐轮由 z(t) 给出。

归界原则：S 不含状态断言，M 不含身份与风格。

内容	承载层
身份、与用户的关系	S
说话方式（语气词、短句、颜文字、自嘲）	S
回复长度与格式纪律、工具规则	S
此刻情绪、动机与开口时机	M
记忆细节	M（G_active）
“总是/从不”式心理状态断言	禁止出现于 S

9.3 状态断言的风格化改写

提示词中一切”你总是 X”“你绝不可以 Y”的断言，改写为”**当 z(t) 处于 X 状态时，以风格 σ 表达**”：状态取值交回动力学，风格 σ 由性格层保留。三步执行：扫描标记绝对化断言（总是/从不/绝不/永远）→ 改写为条件风格映射 → 复扫确认无残留实时状态句。该改写已在两个 persona 上落地，共改写五处，表达风格原文保留、性格层可感知变化为零。

9.4 意图包与提示词瘦身

意图包为 I_t={R_t, G_active, E_t, M*_t, P_t, intent-type}，其中被动意图包控制在约 200 字，只留”情绪一句、记忆引用一句、边界一句”。节点 ID 与激活值不打印（既省 token 又诱导模型报数值），念头强度只留在 dict 供审计、不拼进提示词。

性格层承载分三阶段演化：规则文本 → 规则 + quote 少样本 → 以自我话语示例替代部分规则。需要强调终点仍是提示词的一种形态：LLM 推理无状态，不存在”训练后人格内化”，动力学状态最终仍须经意图包翻译给模型。身份段与风格段不可归零。

9.5 语录 few-shot

从图谱选 sender=bot、激活高、情绪多样的 k 条自我话语，以”（此刻心情 X 时）…语录…“格式附加，作为风格示例替代等量规则文本。quote 只经 bot_quotes 独立通道，保证风格参考不被当成事实。

第 10 章 一致性守护

10.1 四类故障的形式定义

即便每个模块单独正确，串成流水线时仍可能在四个层面错位：

- **F1 记忆错乱**：失效节点（valid_until(v)≤t）仍出现在 G_active(t)，如”考完没”式追问；
- **F2 上下文割裂**：quote 节点进入事实召回通道，导致自我指涉、话题收敛到少数句式；
- **F3 人格分裂**：同轮输出兼含动力学强度断言与静态人格断言，二者竞争解释权；
- **F4 行动割裂**：已执行的主动动作 a 没有对应记忆节点（a∉V(t)），模型对”自己刚做过的事”失忆。

四类故障的共同点是”数据走错通道或根本没有通道”，故修复应在正确层位钉确定性拦截点，而非改提示词。

10.2 四条运行期不变量

不变量	内容	落点	拦截
I1 时序单调	上下文与 R_t 必带 when；同实体新旧事实新者在前	检索侧	F1
I2 通道隔离	quote 只走 bot_quotes，不进 G_active/锚点/R_t	写入+检索侧	F2/F4
I3 表达归界	S 不含状态断言，M 不含身份风格，风格由 σ(ψ) 渲染	生成侧	F3
I4 解释权唯一	状态字段与风格字段键空间不相交，冲突以状态为准	生成侧	F3

不变量由纯函数实现，不调用模型、不写回快状态。拦截顺序为：数据净化 → 语义了结 → 检索拦截 → 表达归界 → 后验校验，越靠前越便宜彻底。

10.3 三条可证结论

- **引理 10-1（覆盖）**：若 R_t 按 (created,id) 全序排列并截取前 k 条，则同一实体新旧事实中新者必在前；残余风险只剩”模型不读第一行”的服从度问题，而非架构问题。
- **命题 10-2（构造性）**：给 quote 打类型标记并在三处检索接口过滤，则 F2 恒为 0；隔离必须做在类型上，靠降权重不可靠（连续量总会被阈值越过）。
- **命题 10-3（单一事实源）**：若提示词不含强度断言、风格全由 σ(ψ) 生成，则 F3 只剩渲染噪声。

10.4 五道防线

防线	层位	机制	拦截
① 数据净化	写入侧	停用词生效、时间词不入节点、未来锚点过期闸、伪承诺过滤、日记体语录过滤	F1/F2
② 检索拦截	检索侧	when 标签、R_t 排序、语义了结、quote 类型过滤	F1/F2
③ 生成归界	生成侧	S/M 正交、状态断言改写、键空间不相交	F3
④ 行动在场	行动侧	动作执行即写 action_log 与记忆节点，保证 a∈V(t)	F4
⑤ 后验校验	生成后	GuardAuditor 跑 I1–I4，失败只降级不中断	全部

10.5 守护审计与行动记忆

`guard/invariants.py` 的 GuardAuditor 在每次生成前审计 I1–I4，失败只记 `guard_trace.jsonl` 并降级（去掉可疑字段而非整轮失败），不抛异常中断对话。行动记忆方面，动作执行后立即写 action_log 与对应节点，解决 F4 的”动作不在场”。

10.6 故障率五档对照

离线决策流（200h、10000 决策点、固定种子）按五道防线逐步叠加做五档对照。综合故障率定义为 K·Σw_k f_k + 模型外残差：基线工况标定到 **1.540**，守护态行为类故障降为 0，加上模型外残差（LLM 表达抖动、由头质量等 ODE 之外来源）0.065，**总故障率 0.065，降幅 95.8%。**该指标是离线仿真标定，不代表线上用户实验结果。

第 11 章 生活任务层：从短信到闭环

11.1 任务模型

生活任务层把”短信里的快递”变成一张可追踪的任务卡：来源（短信原文、发送方、时间、命中字段）、任务内容（取件码、运单号、驿站）、情境（下课时间、关门时间、步行分钟）、状态、用户动作。任务卡不是聊天记录，而是状态机的一条记录。

11.2 确定性通道

快递提醒**不走念头阈值 u(t)**：驿站关门是硬约束，情绪低时也不能拖。判据是事件是否带硬截止——关门、发车、预约到期等错过即不可逆的事件走确定性通道，不等待 u(t)；没有硬截止、属于陪伴表达的事件走动力学通道。两条通道共享同一份 z(t) 快照：任务事件写任务库与图谱但不改 e(t)，动力学通道只把任务摘要当弱情境刺激。

优先级与时间窗由确定性公式给出：

$$priority = w_1 urgency + w_2 route_fit + w_3 value - w_4 disruption \qquad (11\text{-}1)$$

$$start = \max(now, class_end + walk), \quad end = station_close - buffer \qquad (11\text{-}2)$$

若 end 已过，任务直接标 expired 并给替代建议，不生成必然迟到的提醒。

11.3 六态状态机

状态	含义	入口	出口
pending_confirm	刚发现，待发卡	短信摄入	awaiting_confirm / ignored
awaiting_confirm	已发卡，等确认	任务卡	planned / ignored / expired
planned	已排期，有窗口与理由	确认	reminded / deferred / expired
reminded	已提醒，等回执	到期	done / deferred / ignored
done	已取/已办	回执	archived
archived	归档，不再提醒	自动	—
ignored	忽略，不再提醒	回执	—
deferred	延后，窗口重算	回执	planned / expired
expired	窗口已过	自动	—

提醒理由由确定性模板生成（“16:00 下课、驿站 18:00 关门、步行 8 分钟，16:10 出发最顺路”），不让 LLM 自由发挥”我觉得现在合适”。

11.4 当前实现与落地边界（如实标注）

生活任务层在当前多插件架构下分两处承载：

1. **TaskEngine（行为插件 `behavior/tasks.py`，471 行）**：TaskStore 负责原子写与坏文件不覆盖，TaskEngine 实现摄入、去重、排期、提醒、回执、归档与时间窗计算，即上述状态机的完整逻辑；
2. **独立信使插件 `astrbot_plugin_shihai_sms`（360 行）**：内置 HTTP 服务（端口 6187，`/sms` 端点，带令牌校验），接收 SmsForwarder 转发的短信，ExpressParser 以”品牌词 + 取件码/单号/状态”双证据判定快递，解析后入库并主动私聊上报，提供 `/快递`、`/短信`、`/短信测试` 命令与 1 个 LLM 工具 get_recent_express。

需要明确的边界：

- 论文早期”5 个任务工具挂在同一 main.py”的口径已随 SMS 独立成插件而过时；
- **手机端 SmsForwarder 真机链路受校园网 AP 隔离影响尚未完全打通**，本文不把”手机自动转发”写成已交付；当前可通过 `/短信测试` 或手写 JSON 在本机验证解析与任务流转；
- 短信原文只存本机，任务库不含手机号、不把取件码发到群聊，任务卡只发给用户。

第 12 章 上下文闭合

长期记忆解决”记得三个月前的事”，短上下文解决”记得上一句自己在说什么”。后者曾有三处结构性断裂，共同特征是：发出去的东西说了，但历史里一个字都没有。

12.1 根因：整段覆盖写与钩子时序

框架在保存历史时用整段覆盖本轮 messages 而非增量追加，且响应阶段顺序是”先发送、后触发发送后钩子”。二者叠加：任何在发送阶段往历史里追加的行都会被本次覆盖写抹掉，补记只能发生在发送结束之后。多数上下文丢失并非打断取消造成，而是这一落库缺陷，且旧实现只补用户侧、已生成的半截助手正文一句不留。

12.2 三处修复

（一）语音自述入史。 语音发送时消息链被替换为 Record、没有文字组件。修复把它拆成两步：发送前暂存正文，发送成功后的钩子补一条助手轮，前缀标明”（语音）“：

$$history \leftarrow history \cup \{(assistant, \text{“（语音）”} + text_{tts})\} \qquad (12\text{-}1)$$

补记须去重，按四字片段重叠率判重（同一轮可能走本地 TTS 与降级群语音两个出口）：

$$dup(a,b) = 1 \Leftrightarrow \frac{|G_4(a) \cap G_4(b)|}{|G_4(a)|} \geq 0.6 \qquad (12\text{-}2)$$

阈值取 0.6 而非 1.0，因 TTS 回执略带改写，整句比对会漏判。

（二）指代焦点绑定。 修复不改推断逻辑，只增加会话级焦点槽：从关系称谓词表（姐姐/哥哥/妈妈/室友/同学/老师等）取最近命中的实体，有效期 6 小时：

$$F_t = (entity, t_F), \quad valid \Leftrightarrow now - t_F < 6h \qquad (12\text{-}3)$$

焦点必须落盘（进程可能被看门狗重启，内存态焦点会在重启处归零）。注入侧仅当当前句出现”她/他/它”时，在意图包追加一行约 20 token 的当前焦点说明，不出现代词则不加。

（三）半截回复抢救。 取消旧任务前先抢救而非先 cancel：把已生成的 Plain 文本以”（说到一半被打断）“标签写入历史，再取消任务、最后注入新请求，次序固定为 merge → cancel → inject。模型看到的因此是”我刚说到一半被打断”，而非”用户突然换话题”。

12.3 验证与作用域

三处补记只作用于用户会话键，按 conversation_id 定位、不新建会话，非用户会话不写，与会话隔离一致。离线验证：焦点在后续代词句中仍解析为原实体，语音正文连写第二次被判重。上线启动日志输出”上下文闭合已启用：语音自述入史 / 指代焦点绑定 / 半截回复抢救”。

第 13 章 数值自洽性验证

13.1 目标与实验设置

仿真目标不是”证明系统像人”，而是检查数值自洽：方程在给定步长下是否稳定、阈值是否饱和回落、极端输入是否越界、慢参数是否把快状态带飞。所有结论只在本文参数与步长内成立。积分采用 RK4 加投影钳位：快步长 0.05 h、长时步长 0.25 h、自我调节步长 0.02 h；长时运行 200 h、极端工况 60 h、自我调节工况 45 h。各模块共用同一随机种子，检查表只记录能由输出文件复核的量。

13.2 十一组检查结果（11/11 通过）

检查	关键结果	判据
C01 情绪场弛豫	相对解析解误差 0.00014，0 振荡	相对误差 <1%
C02 情绪—记忆耦合	召回情绪偏移 0.218，λ 单调递减	—
C03 Hebbian	边权 2.5 封顶、单调、无负边	—
C04 念头累积	du/dt=0.1109（论文 0.111，误差 0.11%），首次触发 13.9h	—
C05 200h 长时稳定	max_e=0.477、max_u=2.997、max_θ=2.3，16 次触发，有界	全程不越界
C06 参数扰动	±20% 摄动下观测变化 <30%	灵敏度阈值
C07 差异化衰减	半衰期 highlight 138.6/emotion 69.3/event 13.9/fact 6.9h	—
C08 N 维恐惧消退	半衰期相对误差 0.017，N0.8 vs N0 比值 1.786	—
C09 阈值饱和	门控回落 1.4→0，无死锁	—
C10 极端边界	max_e=1.0、max_u=3.0 正确饱和并自恢复	—
C11 自我调节	5 次触发、抑制期 0 次误放、574 次置换	—

静态编译检查 **13/13 通过**，编译路径已反映新的 `mind/` 多插件结构。

13.3 关键量化结论

- 念头典型增速 du/dt≈0.111/h，与设计值一致；
- 200 h 长时运行中情绪、念头、有效阈值全程有界，无发散、无死锁；
- 综合故障率由基线 1.540 降至 0.065（行为类故障降为 0，模型外残差 0.065），降幅 95.8%；
- 12 张图（fig_01–12）覆盖弛豫、耦合、Hebbian、长时、扰动、衰减、饱和、自我调节与故障率。

13.4 解释边界

仿真只证明数值自洽与边界行为，不证明线上因果效应；故障率是离线固定种子决策流的标定指标，不代表线上用户实验。模型外残差（LLM 表达抖动、由头质量等 ODE 之外来源）单独列示，不与行为类故障混算。

第 14 章 观测台与工程部署

14.1 单文件观测台

系统配套一个”即开即用”的单文件观测台 `识海心智观测台.html`（约 120 KB，内联 CSS/JS，无外部依赖），可视化情绪曲线、念头、目标、图谱规模与最近主动文本，并提供人物设定、未来管理（定时提醒 CRUD、插件任务、调度配置）等管理视图。

14.2 桥接服务与安卓壳

`serve.py` 作为本地桥接，读取契约目录中的状态文件并以 HTTP 提供给前端，绑定令牌鉴权（Cookie / X-Token / query token 三种方式），支持局域网访问与 dashboard 登录、cron/persona 代理。移动端通过一个最小原生 WebView 壳 `识海观测台.apk` 加载该页面，实现安卓端观测。

14.3 部署与数据安全

状态写入采用临时文件加原子替换，损坏以默认状态兜底；桥接服务所有管理接口需令牌，避免局域网裸奔。插件通过数据契约协作，任一插件崩溃不污染内核快状态。

第 15 章 限制、伦理与外部效度

15.1 已实现边界（不夸大）

- **心智快状态仍是单份**：多会话的访问控制与记忆归属已实现（第 6 章 6.15–6.23），$z_r(o)$ 与 $z_s(s)$ 已按对象与会话分片，但 `mind_state.json` 未按会话拆分，情绪场的快状态仍被所有会话共享；多用户各自独立心智、多平台实例未实现；
- 多模态深度感知（Wav2Vec2、CLIP）未实现，当前以文本 LLM 推断为主；
- 手机端短信真机链路受网络 AP 隔离影响未完全打通；
- 部分冷却状态为进程内存储，重启清零，跨重启持久化未做；
- 心理学模型中除大五人格外多为参数化落位，不声称与心理学原理严格等价。

15.2 伦理与隐私

系统不宣称具备意识或主观体验。短信原文只存本机、设保留期限，任务库不含手机号、取件码不进群聊；心理学术语仅作功能类比，不用于推断用户心理状态。涉及第三方音源时，登录态仅用于合法在线播放，不做 DRM 解密、不抓取受版权保护的完整音源、不批量下载。

15.3 外部效度

仿真结论只在给定参数与步长内成立；参数多为工程标定而非人群测量，“高外向更主动、高神经质恢复更慢”等是设计选择。真实场景验证以本机运行日志与状态文件为准，线上用户对照实验留作后续。

15.4 后续工作

多用户独立心智、多模态感知落地、跨重启状态持久化、非对称 W 稳定性证明、探索与演化参数的用户对照标定，以及手机端真机链路打通。

第 16 章 结论

16.1 总结

识海把长期陪伴 AI 的”何时说、为何说”与”怎么说”解耦：以六分量耦合状态 z=[e,a,θ,ψ,u,g] 为核心，用情绪场 ODE、神经图谱扩散、Hebbian 边权、念头累积、自我许可、慢演化与内生目标构成确定性闭环，大模型只承担表达。工程上已重构为六个职责单一、通过数据契约协作的插件，并配套单文件观测台与安卓壳。

16.2 贡献回顾

1. 六分量耦合状态把情绪、记忆、人格、念头、目标写进同一组方程；
2. “越阈且自我许可”与由头锚点使每个主动行为可解释、可回溯；
3. 多插件架构与数据契约实现动力学与平台解耦；
4. 表达双层模型与四类故障形式化、四不变量、五道防线，把一致性做成可计数、可回归的工程性质；
5. 生活任务层以确定性状态机承载硬截止任务，与动力学共用状态快照；
6. 权限投影把身份判定离散化为可核验谓词，三档只切权限不切人格；逐字归档层与摘要层并列，使”原话”可回查、使编造率与时间归属两项指标第一次可自动采集；
7. 11 组数值检查全部通过、故障率降 95.8%，工具 schema 裁剪 50.1%，并如实标注外部效度边界与四处未接线能力。

16.3 展望

后续将在多用户独立心智、多模态深度感知、跨重启持久化与真机链路方向继续推进；记忆侧优先补齐四处未接线（承诺主动出口、原文锚点自动挂钩、`scope/involved` 接入检索过滤、压缩段回灌事件层），并以两组范式的分层实验（D 无门控 / E 三重门控）标定错投率、人格一致性与工具裁剪的真实代价，让可解释的内生行为在长期陪伴中持续、稳定、可审计地生长。

参考文献

记忆与自我理论

1. Ebbinghaus, H. *Memory: A Contribution to Experimental Psychology*. 1885.
2. Hebb, D. O. *The Organization of Behavior*. 1949.
3. Anderson, J. R. A spreading activation theory of memory. *Journal of Verbal Learning and Verbal Behavior*, 1983.
4. Tulving, E. Episodic memory: From mind to brain. *Annual Review of Psychology*, 53, 1–25, 2002.
5. Conway, M. A. Memory and the self. *Journal of Memory and Language*, 53(4), 594–628, 2005.
6. Brewer, W. F. What is recollective memory? In *Remembering Our Past: Studies in Autobiographical Memory*, 19–66, 1996.
7. Symons, C. S., & Johnson, B. T. The self-reference effect in memory: A meta-analysis. *Psychological Bulletin*, 121(3), 371–394, 1997.

人格、情绪与动机

8. McCrae, R. R., & Costa, P. T. *The Five-Factor Theory of Personality*. 2008.
9. Russell, J. A. A circumplex model of affect. *Journal of Personality and Social Psychology*, 39(6), 1161–1178, 1980.
10. Posner, J., Russell, J. A., & Peterson, B. S. The circumplex model of affect: An integrative approach to affective neuroscience, cognitive development, and psychopathology. *Neuroscience & Biobehavioral Reviews*, 29(4), 737–748, 2005.
11. Bowlby, J. *A Secure Base: Parent-Child Attachment and Healthy Human Development*. 1988.
12. Festinger, L. *A Theory of Cognitive Dissonance*. 1957.
13. Bandura, A. *Self-Efficacy: The Exercise of Control*. 1997.
14. Friston, K. The free-energy principle: a unified brain theory? *Nature Reviews Neuroscience*, 2010.

智能体记忆架构

15. Park, J. S., O' Brien, J. C., Cai, C. J., et al. Generative Agents: Interactive Simulacra of Human Behavior. arXiv:2304.03442, 2023.
16. Packer, C., Wooders, S., Lin, K., et al. MemGPT: Towards LLMs as Operating Systems. arXiv:2310.08560, 2023.

17. Xu, W., Liang, Z., Mei, K., et al. A-MEM: Agentic Memory for LLM Agents. arXiv:2502.12110, 2025.
18. Gutiérrez, B. J., Shu, Y., Gu, Y., Yasunaga, M., & Su, Y. HippoRAG: Neurobiologically Inspired Long-Term Memory for Large Language Models. *NeurIPS*, 2024.

身份持久性与陪伴系统评估（2025–2026）

19. Natangelo, S. The Narrative Continuity Test: A Conceptual Framework for Evaluating Identity Persistence in AI Systems. arXiv:2510.24831, 2025.
20. Fraile Navarro, D. The Persona Is Still There, but Who Is Speaking? Latent Identity Reversion in Persistent AI Agents. arXiv:2610.01490, 2026.
21. Jiang, Z., Zheng, C., Chen, H., & Chen, L. RECALLbot: Designing Agentic Memory and Reciprocal Disclosure for Human–Chatbot Relationships. *CHI ' 26*, 1–20. DOI: 10.1145/3772318.3790714, 2026.
22. Zou, W.-Y., Yi, P.-Q., & Luo, S.-J. Human Self-Reference and Memory Organization in Large Language Models: The Self-Reference Effect as a Comparative Cognitive Probe. *IHMSC 2026*. DOI: 10.1109/IHMSC70922.2026.00027, 2026.
23. Feng, Z., Xiao, Q., & Shen, H. A Life of Its Own: How Agentic AI Companions Are Configured, Experienced as Autonomous Others, and Held Accountable. arXiv:2611.12076, 2026.
24. Venkit, P. N., Prabhakar, A., Li, Y., Lee, D., & Wu, C.-S. Best Friends, Not Forever: Evaluating Long-Horizon Persona Collapse and Behavioral Drift in AI Companions. arXiv:2607.28818, 2026.

工程与平台

25. AstrBot 框架与 OneBot 协议官方文档。

> 注：本文为代码核验后的整合稿，全部规模数字（13 行为、65 工具、常驻 30、11 检查、1018 节点、τ 与半衰期、463 事实 / 473 事件、1,230 条归档行等）均以 2026-11-12 线上代码与运行时文件为准；与早期文档冲突处，以本稿为准。第 6 章 6.15–6.23 所述权限投影、归属标注、承诺账簿、熟人提名与逐字归档均为当期已上线实现，其未接线部分已在 6.23 逐条列出。