识海：融合人格心理学的 QQ 数字生活任务系统

第二十届全国大学生软件创新大赛 —— 面向移动终端的系统级智能体验

识海项目组

大连理工大学软件学院

2026 年 11 月

目录

第1章 引言

1.1 从单点问答到持续陪伴

1.2 本文的组织方式

1.3 主要贡献

第2章 问题定义与研究边界

2.1 形式化问题

2.2 与现有方案的差异

2.3 研究边界

第3章 状态空间与时间尺度

3.1 六分量状态

3.2 快慢分层

3.3 量纲与稳定性

第4章 情绪场动力学

4.1 情绪 ODE

4.2 记忆对情绪的染色

4.3 稳定性与边界

第5章 记忆图谱：扩散、衰减与 Hebbian

5.1 为什么不用扁平向量库

5.2 扩散激活

5.3 两套衰减：图谱节点的情绪调制，记忆库的保持率曲线

5.4 Hebbian 边权：两道门防”记忆错构”

5.5 三层融合与 quote 隔离

5.6 重要度自评：让模型凭感受定轻重

5.7 时序注入：三档时间线，与相关性检索分块

5.8 复习计数：两道闸，防”永生记忆”

5.9 3/7/15 天体检日：不是每天清扫

第6章 人格与自我调节

6.1 大五人格作为慢变量

6.2 EgoRegulator：越阈不等于发送

6.3 与 LLM 审议层的边界

第7章 念头、阈值与由头锚点

7.1 念头累积

7.2 有效阈值

7.3 由头锚点与可识别性

7.4 重复不等于退化

第8章 目标向量与策略选择

8.1 四维目标

8.2 策略打分

8.3 目标演化

第9章 自适应演化与参数变更

9.1 慢参数在线学习

9.2 人格漂移

9.3 三层慢演化

第10章 动作空间：行为与工具

10.1 统一动作表

10.2 候选过滤与执行

10.3 行为不是定时器

第11章 系统架构与实现

11.1 分层架构

11.2 数据契约

11.3 会话隔离与记忆作用域

11.4 与平台解耦

11.5 多模态感知闭环

11.6 上下文闭合：自述入史、指代焦点与打断抢救

11.6.1 根因：整段覆盖写与钩子时序

11.6.2 三处修复

11.6.3 验证

11.7 任务层挂载点

第12章 表达层：意图包与人格边界

12.1 意图包

12.2 双信号源

12.3 语录隔离与断言改写

12.4 重复与人格一致
12.5 提示词瘦身

第13章 一致性守护

13.1 四类故障
13.2 四不变量
13.3 五道防线
13.4 行动记忆
13.5 上线验证

第14章 生活任务层：从短信到闭环

14.1 任务模型
14.2 确定性通道
14.3 状态机
14.4 情境融合与”为什么现在提醒”
14.5 代码落地与运行证据
14.6 隐私与边界

第15章 仿真设置

15.1 目标与原则
15.2 积分方法与参数
15.3 复现口径

第16章 数值自洽性结果

16.1 十四组检查
16.2 关键数字
16.3 解释边界

第17章 长时稳定与鲁棒性

17.1 200 小时长时稳定
17.2 参数扰动
17.3 差异化衰减
17.4 极端与饱和
17.5 本章结论

第18章 实现与真实场景验证

18.1 代码与运行事实
18.2 任务链路冒烟

18.3 真实进程

18.4 手机端缺口

18.5 失败案例

第19章 讨论

19.1 为什么要把动机与语言分开

19.2 限制

19.3 伦理与隐私

19.4 后续工作

第20章 结论

20.1 总结

20.2 贡献回顾

20.3 展望

参考文献

附录 A 仿真设置与复现说明

附录 B 复现结果与实现索引

B.1 运行结果摘要

B.2 十五张检查图

B.3 仿真脚本结构

B.4 人格与记忆实现索引

摘要

本文把长期陪伴 AI 拆成三层：动力学内核负责”什么时候、为什么”，表达层负责”怎么说”，生活任务层负责”事情办到哪一步”。系统以六分量状态 z(t)=[e(t),a(v,t),θ(t),ψ,u(t),g(t)] 为核心，用情绪场、图谱扩散、Hebbian 边权、念头累积、自我调节与慢演化构成闭环；把”念头越阈”改为”越阈且自我许可”，让每个主动行为都能回溯到由头。生活任务层把短信快递做成”发现—确认—排期—提醒—回执—归档”状态机，快递提醒走确定性通道，不进入念头阈值。本文给出 20 章结构、14 组数值检查、12 条注册行为与 51 个工具的实现口径；记忆库按艾宾浩斯保持率分桶衰减（事实 15 天 / 事件 30 天 / 核心 90 天），稳态度由重要度自评、情绪峰值与跨天复习次数共同决定，归档只在 3/7/15 天三个体检日发生且只移不删；会话层支持群聊按人隔离、长期事实按发送者归并，内核仍保持单一自我；短上下文再做三处闭合（语音自述补记入史、指代焦点实体落盘、打断前抢救半截回复）；文末如实标注手机端未打通、多用户独立心智未实现与仿真外部效度边界。

关键词：数字生命；耦合动力学；人格心理学；主动行为；生活任务；一致性守护

第1章 引言

1.1 从单点问答到持续陪伴

主流陪伴 AI 把情绪、动机、人格全部交给大模型隐状态：同一句话，换一个会话就可能换一种心情；主动行为由提示词或定时器触发，既不可控，也不可解释。识海把”什么时候说话、为什么说话”从语言生成中拆出来，交给一个独立的时序状态系统；大模型只负责”怎么说”。

这条分界线带来三个直接后果：情绪可以跨会话残留，记忆可以按情感强度差异化衰减，每一个自发动作都能回溯到具体的情绪、记忆、念头或任务来源。本文把这条链路整理成 20 章：先给原理与方程，再给架构与任务，最后给仿真与结论。

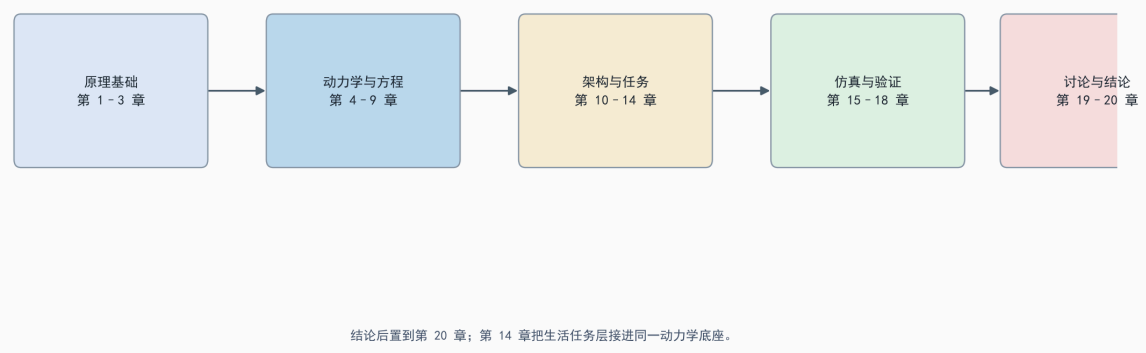


图 1-1 20 章结构：原理—架构—方程—仿真—结论

1.2 本文的组织方式

第 2—3 章定义问题与状态空间；第 4—9 章给出情绪、记忆、人格、念头、目标与演化的方程；第 10—14 章给出动作空间、系统架构、表达层、一致性守护与生活任务层；第 15—18 章给出仿真设置、数值结果、长时稳定与真实场景验证；第 19—20 章讨论边界并收束结论。结论不再夹在中间，统一放到第 20 章。

1.3 主要贡献

（1）提出六分量耦合状态 $z(t)=[e,a,\theta,\psi,u,g]$，把情绪场、图谱激活、慢参数、人格、念头与目标写在同一组方程里；（2）把”念头越阈”改为”越阈且自我许可”，用 EgoRegulator 解释”为什么现在说”；（3）把 12 条注册行为与 51 个 LLM 工具收进同一张动作表，形成 63 个可解释调用入口；（4）新增生活任务层，把短信快递、排期、提醒、确认、归档做成确定性状态机，并与心理动力学共用同一份状态快照；（5）用 11 组数值检查与真实运行日志验证链路自洽，同时如实标注外部效度边界；（6）在架构层给出会话隔离与记忆作用域：短上下文按会话分桶、长期事实按发送者归并、内核保持单一自我，并用同会话新消息取消旧回复任务消除时序压栈；（7）给出短上下文的闭合机制：语音自述在发送结束后补记入史、指代焦点实体落盘跨重启绑定、打断前抢救半截回复，并指出”整段覆盖写 + 钩子时序”这一框架级落库根因。

第2章 问题定义与研究边界

2.1 形式化问题

给定用户消息流 X={x1,…,xn}、历史交互记忆 M={(xi,yi,ti)}、以及情境 C（时间、课表、地点、短信、设备状态），要求构建系统 f:(X,M,C)→(Y,e,a,T)，其中 Y 为回复序列，e(t) 为连续情绪状态，a(v,t) 为记忆激活状态，T 为生活任务状态。系统需要同时满足四条约束：

（a）情绪连续性：e(t) 不随单轮对话跳变，跨会话保留残留；（b）记忆可累积：新交互写入图谱，旧记忆按情感强度差异化衰减；（c）行为可解释：每个自发动作可回溯到情绪、记忆、念头或任务来源；（d）记忆零 LLM 成本：检索与衰减不调用大模型。生活任务层再追加一条（e）任务可闭环：发现、确认、排期、提醒、回执、归档六个环节都不丢状态。

f:(X,M,C)→(Y,e,a,T)　(2-1)

2.2 与现有方案的差异

现有方案大多是”强 LLM + Prompt + 向量记忆”：情绪靠提示词维持，记忆靠全量嵌入检索，主动行为靠定时器。它们能生成像样的句子，但很难回答三个问题：为什么此刻主动？为什么是这件事？为什么不是下一次？识海的差异是把动机、情绪、记忆与任务状态做成可读的时序变量，把语言生成降为表达层。

2.3 研究边界

本文不宣称系统具备意识或主观体验。心理学概念只作为设计动机的来源，不作为系统模块名：论文中的”快动力学内核、门控调节器、硬安全守护”分别对应情绪/记忆/念头、释放许可、I1–I4 守护；代码与接口不按”本我—自我—超我”命名。当前版本是单用户设计：私聊天然一人一会话，群聊在 unique_session 下把会话键改为”发送者_群号”，不同群友的短上下文互不可见；长期事实记忆以发送者为键，跨会话共享；内核 z(t) 与图谱仍是单一自我，只对用户会话开放读写。多用户各自独立心智、多平台实例与手机独立端仍未实现。仿真只证明数值自洽性与边界行为，不证明线上因果效应；真实场景验证以本机 AstrBot 运行日志与任务状态文件为准。

第3章 状态空间与时间尺度

3.1 六分量状态

系统状态由六个分量构成。快状态承载”此刻的心情与记忆”，慢状态承载”长期的性格与目标”，念头与任务状态负责”是否行动、行动到哪一步”。

$z(t)=[e(t)\in R6,\ a(v,t)\in R|V|,\ \theta(t)\in Rd,\ \psi\in R5,\ u(t)\in R,\ g(t)\in R4]$ （3-1）

表 3-1 状态分量与时间尺度

分量	含义	取值范围	时间尺度
e(t)	六维情绪场：happy/sad/angry/fear/love/surprise	[0,1]	小时级
a(v,t)	图谱节点激活	[0,1]	小时—天级
θ(t)	慢参数：阈值、衰减、边先验	实数	天—周级
ψ	大五人格 (O,C,E,A,N)	[0,1]	月级
u(t)	念头强度	[0,3]	小时级
g(t)	关系/记忆/自我/回避四目标	[0,1]	天—周级

3.2 快慢分层

快状态每轮更新，慢状态按天或按周更新，人格按月漂移。三层时间尺度分开的好处是：单轮对话不会把人格带偏，长期反馈也不会被一次情绪淹没。图 3-1 给出六个分量之间的五条回路。

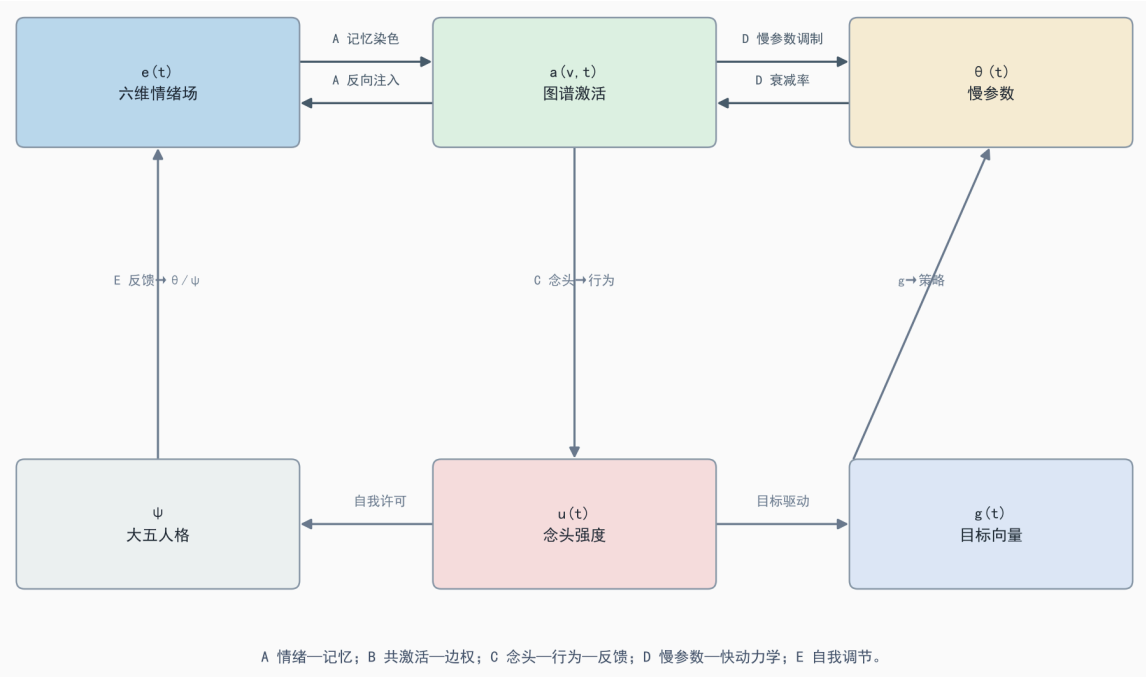


图 3-1 六个状态分量与五条耦合回路

3.3 量纲与稳定性

情绪采用小时为时间单位，弛豫时间 τ 均大于 0.5 h，显式欧拉更新满足 |1-1/τ|<1，不会数值振荡。念头 u(t) 是累积量，上界 3.0 是”强度上界”，不是变化率上界；阈值 2.10 与 u(t) 同量纲。任务时间用绝对时间戳，避免跨天漂移。

第4章 情绪场动力学

4.1 情绪 ODE

每一维情绪独立弛豫，同时受外部刺激、内部记忆刺激与情绪互激励影响。

τi·dei/dt = -ei + κ·[sext,i + sint,i] + η·ΣjWijej　(4-1)

τ_i 是第 i 维情绪的弛豫时间；-e_i 是自然衰减；s_ext 来自用户输入或语音情绪；s_int 来自被召回的记忆节点；W 是 6×6 情绪互激励矩阵，采用对称假设以保留梯度流解释。

表 4-1 情绪弛豫时间与工程含义

维度	τ（小时）	工程含义
happy	6	开心退得较快，避免一直亢奋
sad	12	低落有残留，但不跨周
angry	2	愤怒最短，避免累积成冲突
fear	3	恐惧中等，给安全感留窗口
love	24	亲密感最长，跨天保持
surprise	1	惊讶最短，避免噪声

4.2 记忆对情绪的染色

内部刺激 s_int,i=Σ a(v,t)·E_v,i，其中 E_v,i 是节点 v 在第 i 维情绪上的标签强度。被召回的高情感节点会给当前心情”染色”：想起往事，往事又影响当下。该式与第 5 章扩散激活共用同一份 a(v,t)，不需要额外检索。

4.3 稳定性与边界

当外部刺激为 0 时，e(t) 按指数回到 0；当刺激持续饱和时，e(t) 被 W 与 κ 限制在 [0,1] 内。本文不对 W 的非对称情形做稳定性证明，只在对称假设下给出数值检查；这一限制在第 19 章如实标注。

第5章 记忆图谱：扩散、衰减与 Hebbian

5.1 为什么不用扁平向量库

陪伴场景需要的不是”相似段落”，而是”这条记忆和谁一起被想起、想起后情绪怎么变”。扁平向量库只返回 top-k 相似项，无法表达共激活、边权与情感衰减。识海用神经图谱：节点是事实、情绪、事件、语录、高亮，边是共现或因果关系。

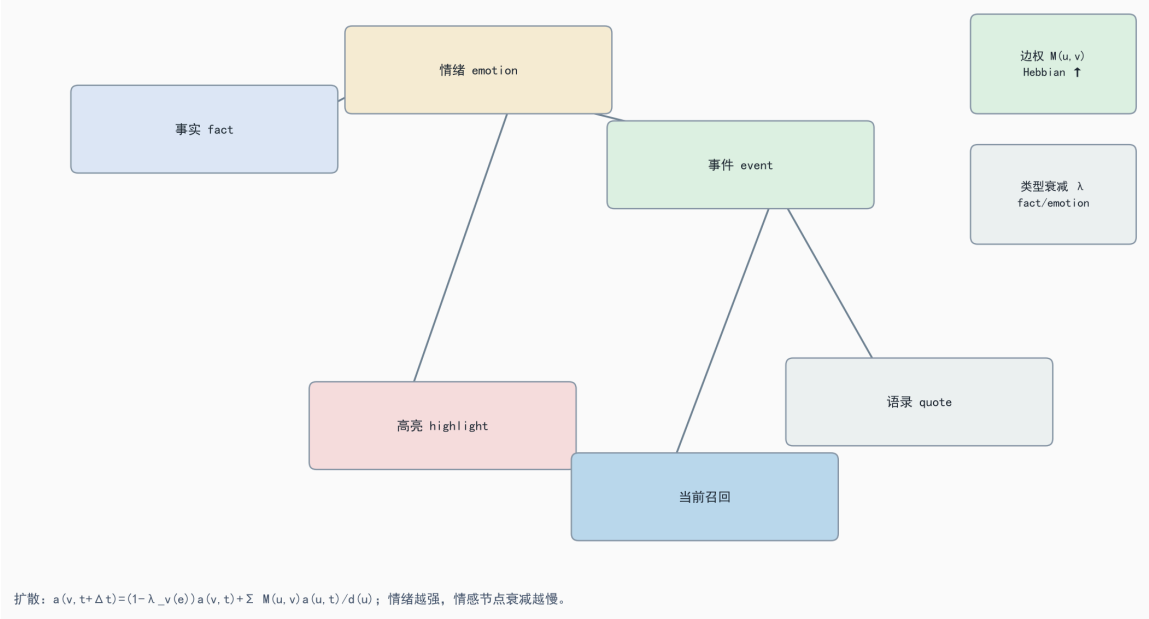


图 5-1 神经图谱的扩散激活与双衰减

5.2 扩散激活

每个节点的激活值 = 自身衰减后的剩余 + 邻居通过边权传来的能量。

$$a(v,t+\Delta t) = (1-\lambda v(e))\cdot a(v,t) + \Sigma u\in N(v)\ M(u,v)\cdot a(u,t)/d(u) \quad (5\text{-}1)$$

N(v) 是指向 v 的邻居集合，M(u,v) 是边权，d(u) 是出度。扩散只沿已有边进行，不调用 LLM；召回结果只把节点摘要送进意图包，不把全文塞进提示词。

式 5-1 写作离散形式便于阅读，仿真与实现里衰减项用精确指数 $\exp(-\lambda v\cdot\Delta t)$ 代替 $(1-\lambda v\cdot\Delta t)$：后者在步长变化时会系统性漂移，同一组参数换个步长曲线就变形（§3.3）。

5.3 两套衰减：图谱节点的情绪调制，记忆库的保持率曲线

系统里有两种”忘记”，物理含义不同，不能共用一个衰减常数。

第一套是**图谱节点激活** a(v,t)：它是”此刻这条记忆有多亮”，秒级到小时级。它的衰减率受当前主导情绪与节点情感强度共同调制：

$$\lambda v(e) = \lambda type / (1 + \alpha \cdot edom \cdot Ev) \quad (5\text{-}2)$$

λ_type 由节点类型决定（fact=0.1，emotion=0.01，event=0.05，highlight=0.005）；α=3.0；e_dom=max(e(t))。物理含义：开心时美好记忆衰减更慢，低落时负向记忆保留更久——情绪反向调制记忆，而不是记忆单向决定情绪。

第二套是**记忆库条目的保持率**：事实与事件条目回答的是”这条东西还记不记得”，天级到月级。它不再用”每步乘一个衰减系数”，而是艾宾浩斯保持率曲线：

$$R(\Delta t) = exp(-\Delta t / S) \quad (5\text{-}3)$$

R∈(0,1] 是保持率，Δt 以小时计，S 是记忆强度（稳态度，小时）。S 由三个因子相乘决定：

$$S = (1 + \beta \cdot imp) \cdot (1 + \alpha E \cdot Ev) \cdot (1 + \beta N \cdot Nrecall) \quad (5\text{-}4)$$

β=2.0 是重要度系数（imp 为固结时 LLM 自评的 0–1 重要度，见 5.6）；α_E=2.0、E_v 是事件冻结时的情绪峰值（事实层没有独立情绪字段，此处退化为 1）；β_N=1.5、N_recall 是”跨天有效复习次数”，上限 12（见 5.8）。

换算成衰减率就是 λ_eff = λ/S，其中基础衰减率按类型分桶：

$$\lambda = ln2 / (T½ \cdot 24) \quad (5\text{-}5)$$

T½ 是各桶的基础半衰期，单位为天。三桶标定见表 5-1。

表 5-1 记忆库的分桶半衰期与”温和档”理由

桶	T½（天）	λ（h^{-1}）	标定理由
事实 fact	15	1.93×10^{-3}	具体事实半个月不提就该淡；再 短就是短期工作记忆
事件 event	30	9.63×10^{-4}	事件带情境，比纯事实更值得 留，一个月是”还记得那天”的 量级
核心 core	90	3.21×10^{-4}	身份、承诺、关系锚点：三个月 不提也仍在，但不再是永久

这个标定是”长期陪伴”而不是”阿尔茨海默”：如果事实半衰期取 3 天，上周末说的重要事这周三就全忘了。反过来，纯常数衰减也有问题——所有记忆同时同速淡出，说不清”为什么这条记得、那条忘了”。分桶加 S 的组合让差异来自三件可解释的事：这条有多重要（imp）、当时情绪多重（E_v）、后来被想起过几次（N_recall）。

5.4 Hebbian 边权：两道门防”记忆错构”

两个节点在同一窗口内被同时点亮，边权增强；夜间梦境固化时修剪弱边。

$$M(u,v) \leftarrow M(u,v) + \gamma \cdot \mathbb{1}[a(u) > \theta act] \cdot \mathbb{1}[a(v) > \theta act] \quad (5\text{-}6)$$

朴素的”一起亮就连边”会产生心理学上的记忆错构（confabulation）：前摄抑制与倒摄抑制说明，新记忆会干扰旧记忆，旧记忆也会压制新记忆。如果两个事件节点时间贴得很近但属于不同主体（“用

户抱怨的 A”与”机器人自己说的 B”），一旦连边，它们就会在后续召回里被拼成一句”我记错了”。因此实现里加了两道门：

门一，跨主体硬门：`sender_u != sender_v` 直接不连。这是硬约束，不是权重折扣。

门二，时间邻近惩罚：同一主体、两个节点创建时间相差 24h 以内，且这条边还没被反复共现确立过（共现次数 <3）时，本次只加 γ·0.2。碰巧在同一场对话里被一起提起的两件事（“点外卖”和”下雨了”）不该长成强关联；只有跨过更长时间窗、被多次共现的边，才算真正的关联。

需要说明的是，代码里没有可调用的因果判定器（is_causal 无处可取），“共现次数”只是因果关系的代理指标。因此门二做的是**降低假阳性**，不保证因果正确——这是本章的方法论边界，不是实现细节。

5.5 三层融合与 quote 隔离

记忆分三层：事实层（可核验）、情绪层（主观感受）、关系层（谁和谁、承诺与边界）。三层共用图谱，但召回时按来源打标；语录（quote）单独隔离，不参与事实断言，避免把”她说过的一句气话”当成长期事实。该隔离与第 13 章的一致性守护共用同一套来源标签。

类型分层之外，记忆还有作用域：事实层按发送者归并，同一人跨群、跨私聊共享同一组事实；情绪层与图谱激活属于单一自我，只有与用户的一对一会话写入；会话短上下文按会话串（unified_msg_origin）分桶，不跨人拼接。类型隔离回答”这句话能不能当事实”，作用域隔离回答”这条事实属于谁”。两者共同保证：换一个会话，长期事实还能接上；换一个人，不会把别人的话当成自己的。

5.6 重要度自评：让模型凭感受定轻重

S 公式里最重要的因子是 imp，而 imp 不能由代码里的关键词表打分——“八点离散考试”和”中午吃了碗面”在词频上几乎一样平，在关系里的重量差十倍。因此 imp 交给固结阶段的一次 LLM 调用自评：

imp = round(LLM(dialogue | prompt), 1)，imp∈[0.1, 1.0]　(5-7)

打分口径写死在提示词里，分四档：0.9–1.0 定义关系、承诺、身份、极重情绪；0.6–0.8 长期有效的偏好、习惯、目标、重要事实；0.3–0.5 值得记但会过时的具体事；0.1–0.2 一次性流水细节。模型同时输出事件摘要、情绪标签与事实三元组，一次调用产出全部固结结果，不额外增加轮次。

工程上有一个必须显式化的坑：**按 provider id 指定模型却解析不到时，框架会静默回落到会话默认模型**。这意味着”配了 A 模型、实际跑 B 模型”在日志里完全看不出来，只能看到 imp 长期都是同一个值。因此代码在启动自检里打印一行：

```
[memoryv2] 固结打分模型 aliyun_bailian/deepseek-v4.1-flash-1017：已注册
```

配了 id 但未注册时，同一行会写”未注册→会回落会话默认”。这条日志是本节所有数字可信的前提。

区分度用三段强度递增的对话实测（真提示词、真 provider）：日常闲聊 imp=0.4、离散考试 imp=0.9、“你只是个记不住事的 AI”那类情绪痛 imp=0.8，三段 JSON 全部解析成功。存量 452 条事实按同一口径批量重评后，imp 从”85.5% 挤在 0.2”变成九档分布（0.1×16、0.2×67、0.3×86、0.4×54、0.5×38、0.6×57、0.7×46、0.8×40、0.9×48），平均 0.27→0.49。分桶衰减从此对存量与新数据同样生效。

5.7 时序注入：三档时间线，与相关性检索分块

只靠语义相关度召回，日期这一维是取不到的：实测 33 句日常问法里，与历史事件文本有字面重合的只有 6 句，含时间/回忆线索词的 5 句；而”你还记得昨晚说的吗”这类句子里只有时间词、没有任何字面重合。纯语义通道天生召不回”11 月 8 日考试”——这正是长期运行后注入里”只剩日记”的成因。

因此注入拆成两个独立块：**【你记得的旧事】** 按相关度排序，来自事实层与事件层检索，名额 fact_top_n + event_top_n；**【这些天的片段】** 按日期排序，不看相关度，是”日子的底子”。后者按三档分配名额与字数：

表 5-2 时间线三档（名额按最大余数法分配）

档 *	*天数上界** *	*系数	单条字数** **8	条时名额**
近三天	3	1.00	36	3
近一周	7	0.85	30	3
近半月	15	0.70	24	2

越近的档系数越高、字数越宽、名额越多，因为”最近那几天”才是被问起时答得上来的。两块的预算互不侵占：相关块吃 inject_char_budget，时序块单独有 timeline_char_budget（默认 340 字）。跨块去重只在两条记忆的字面重合占比 ≥60% 时生效——早期用”≥3 个二元组”的绝对阈值，会把”11 月 8 日考试”这条误杀（它只跟事实撞两三个词）。实测时序块 239 字、单轮总注入约 500 字，覆盖从 10 天扩到 15 天。

5.8 复习计数：两道闸，防”永生记忆”

N_recall 是 S 里唯一能持续增长的因子，也是唯一可以被”刷”的因子：用户天天问一句”吃了吗”，系统天天回”吃了”，这条废话若每次都算复习，S 会无限变大，记忆永不衰减。

因此每次召回计分前过两道闸：

ΔN = 1 iff overlap(recall, item) ≥ 2 且 now − last_recall_ts ≥ 24h　(5-8)

闸一要求字面重合至少 2 个二元组——只语义相近、没有实体重合的顺嘴话不算复习；闸二要求距上次计分超过 24 小时——同一轮里连问三次只算一次。实测：同一句”离散考得怎么样”连问 3 次，recalls 只从 0 变 1；无重合的”哈哈哈”保持 0。这两道闸与 N_recall 上限 12 一起，把”复习效应”限制在”真的隔了一段时间还记得”这件事上，而不是”被反复提及”。

5.9 3/7/15 天体检日：不是每天清扫

有了 R 与 S，归档就不该每天跑一遍全库。实现里把 3/7/15 天设成三个体检日，每天最多扫一次（`_last_sweep` 隔 86400 秒才允许下一次），三个时点各自带判据：

归档 iff age ≥ 15（硬淘汰）∨(7 ≤ age < 8 ∧ R < 0.30)∨(3 ≤ age < 4 ∧ R < 0.35)　(5-9)

前提是”低价值”：事件降级且无摘要，或 imp ≤ 0.2 且激活 a < 0.15。归档不是删除——条目只从可注入池移到 `event_archive.json`，原文一字不改，随时可以捞回来。

这里有一个必须写明的实测结论：**在温和档的分桶半衰期下，3 天与 7 天两个窗口的 R 阈值几乎不可能被触发。**事实桶 15 天半衰期、imp=0.2 时 S=1.4，有效半衰期 21 天，3 天后 R≈0.91，远高于 0.35。真正起作用的是 15 天硬淘汰。仿真里 400 条混合库推进 30 天，3 天档与 7 天档命中均为 0，15 天档命中 192 条（图 B-15）。这不是实现失效，而是”温和档”的必然结果：想靠 R 判据在 3 天内清掉东西，只能把半衰期压到 3 天量级，而那正是本文明确拒绝的短期工作记忆档位。

第6章 人格与自我调节

6.1 大五人格作为慢变量

ψ=(O,C,E,A,N) 不是初始化常量，而是月级慢变量。它参与调制恐惧残留、主动频率与冲突后的回避倾向，但不被单轮反馈直接改写。人格只给出先验，后续由交互经验修正（见 9.3）。

6.2 EgoRegulator：越阈不等于发送

念头越阈只说明”冲动足够强”，不说明”现在该说”。EgoRegulator 是确定性规则引擎，不调用 LLM，输出释放许可 r_release 与延迟 r_delay：

u > FIRE_THRESHOLD 且 rrelease > ρ ⇒ 发送 （6-1）

FIRE_THRESHOLD ← FIRE_THRESHOLD + δ·rdelay （6-2）

r_release 的规则是”高位放行、低位拦截、抑制条件居中”：u 顶到上界视为真实表达意愿，优先放行；u 低于半阈值视为气话，直接拦截；冲突、强负反馈、连续冷落落在中间，转入延迟或替代行为。延迟只抬门槛，不改变 u 的累积速率。

表 6-1 防御机制与作用对象

机制	触发条件	作用对象	工程落点
合理化	反馈中性但念头徘徊在门槛附近	表达策略	改变叙事角度，不改原始情绪
压抑	连续冷落或强负反馈	阈值、召回偏置	阈值上升，念头积累变慢
投射	用户意图置信度低	外部刺激权重	下调 s_ext 置信度
置换	抑制期内越阈	行为空间	转入写日记/发动态/梦境固化

6.3 与 LLM 审议层的边界

EgoRegulator 在前，回答”能不能说、以什么策略说”；LLM 在后，回答”具体怎么说”。LLM 的输入只有意图包，不进入 Ego 的输入；LLM 的输出不回写 e(t) 与 a(v,t)，只能通过 r_feedback 影响下一周期的慢参数。一句话：慢参数与释放条件归 Ego，语言表达归 LLM，快状态两者都不能直接写。

第7章 念头、阈值与由头锚点

7.1 念头累积

念头不是定时器，是一个可积累的量。兴趣、时机与情绪状态共同决定累积速率：

du/dt = K·(w1I + w2T + w3M + w4I·T·M)　(7-1)

I 为兴趣度（情绪与记忆共同决定），T 为时间适配度（作息模型），M 为情绪状态因子。I、T、M 归一化到 [0,1]，Σw=1，K 为标定增益。典型工况下 du/dt≈0.111/h，念头从 0 攒到 2.10 需要数小时，而不是每轮都触发。

7.2 有效阈值

有效阈值由自适应项、延迟项与上限共同决定：

eff_thr = min(θadapt + δ·rdelay, URGE_CEILING-0.01)　(7-2)

连续未回复会抬高门槛（STREAK_GATE_STEP=0.2），刚聊过会清零；门槛有上限，避免”越冷落越不敢说”的死锁。该式与 6.2 的释放许可串联，先算门槛，再算许可。

7.3 由头锚点与可识别性

主动开口不能只有”我想你了”，必须带一个可识别由头：一条记忆节点、一个承诺、一次未完成的事、或一个任务卡。发送前做两道校验：锚点必须有节点绑定与内容摘要；空泛锚点不放行。这样”为什么是这件事”可以回答，也避免把随机生成当成意愿。

7.4 重复不等于退化

同一首歌可以在不同由头下被再次选择。判定重复的不是曲目，而是意愿锚点：如果这次是”想起你上次说喜欢”，下次是”今天放学路上突然想唱”，两次都成立。代码只记录”歌名 | 这次想唱它的由头”，不强制换歌；把重复曲目当成 bug，会把”她自己的意愿”误判成模板。

第8章 目标向量与策略选择

8.1 四维目标

g(t)=[g_relation,g_memory,g_self,g_avoid] 分别对应关系、记忆、自我与回避。目标不是手写常量：长期得不到满足会衰减，反复冲突会上升。它比 θ 慢、比 ψ 快，处在”周级”时间尺度。

8.2 策略打分

动作选择不是端到端黑箱，而是可解释打分：

$$\pi(e,a,\psi,u,g) = \arg\max_x [Q(e,a,x) + \beta \cdot \Sigma_i g_i \cdot \varphi_i(x)] \quad (8\text{-}1)$$

Q 是启发式打分，不是在线学习的价值函数：Q=Σ w_k f_k，f_k 为情绪一致性、记忆相关度、目标贡献、工具可用性、重复惩罚五个手工特征，w_k 为固定权重。本文不做贝尔曼备份或时序差分；在线学习只发生在 θ 与 ψ 上。

8.3 目标演化

g 的更新由”当前策略能带来的目标收益”和”长期观测到的偏好满足度”共同驱动。正反馈让对应分量接近 1，强负反馈接近 0；某次交互只累加到它实际服务的那个分量，避免一次聊天同时抬高四个目标。

第9章 自适应演化与参数变更

9.1 慢参数在线学习

θ 包含触发阈值、衰减率、边先验等。它按总损失的梯度更新：

$\theta_{t+1} \leftarrow \theta_t - \eta_{adapt} \cdot \partial L_{total} / \partial \theta$ （9-1）

L_total 由漏出损失、情感连续性损失、记忆质量损失、工具成功率损失与用户反馈适配损失加权组成。用户反馈映射为 [0,1] 的连续信号，而不是 0/1 二值；工具成功率也用连续成功率。这样梯度合法，不会因为一次”已读不回”把参数打到极端。

9.2 人格漂移

ψ 的学习率远小于 θ，设计上只做月级漂移。L_ψ 取统计偏离的平方和：主动频率对应 E，冲突率对应 A，恐惧残留对应 N，任务完成率对应 C，新话题占比对应 O。实现层的统计窗口为 7 天（168 h），样本不足 20 次交互的维度权重置 0，避免小样本把人格带偏。

9.3 三层慢演化

演化分三层：L1 调行为参数（冷却、长度、语气），L2 调探索上限 ε_max，L3 只写叙事观察（“最近更愿意主动唱歌”）。三层都只写 behavior_evolution.json overlay，不直接改 behaviors.json；24 小时评估一次，样本不足不动，回滚只需删除 overlay 并重启。

表 9-1 当前运行参数、默认值与取值依据

参数	默认值	取值依据	可调
platform_id	qq	工程接口契约：平台实例名	否
fire_threshold	2.10	标定实验：念头累积仿真	是
urge_ceiling	3.00	工程安全边界：强度截断	否
ego_rho	0.50	经验值：高位放行/低位拦截	是
threshold_max	3.50	工程安全边界：防死锁上限	是
tick_seconds	60	工程时序：分钟级状态推进	是
watcher_interval	20	工程时序：20 秒轮询	是
action_cooldown	1800	经验值：防刷屏	是
evolution_enabled	true	功能开关：默认开启，可回滚	是
evolution_window	7 天（168 h）	工程时序：慢演化统计窗口	是
task_context	16:00/18:00/8	用户情境配置：下课/关门/步行	是

表中”标定实验”指第 15—16 章的数值检查；“工程安全边界”是防止积分越界或阈值死锁的硬上限，不得为提高触发率随意放大；“经验值”可按用户作息调整。凡标”可调”的参数都由配置读取，修改后经一次 tick 生效。

第10章 动作空间：行为与工具

10.1 统一动作表

动作空间由两部分组成：12 条注册行为（由看门狗按状态与策略触发）与 51 个 LLM 工具（由对话或行为执行器调用）。两者共用一张动作表，每条都有 id、标签、前置条件、冷却与执行函数。当前总入口为 12+51=63。

表 10-1 动作空间分层计数（合计 63）

分层	数量	代表入口
条件触发行为	12	主动问候、关心、回忆、承诺跟进、唱歌、画画、说说、日记、梦境
生活任务	5	task_list / task_confirm / task_done / task_ignore / task_set_context
短信快递	1	get_recent_express
路线出行	1	travel_plan
商品检索	1	product_search
QQ 社交	8	说说、评论、点赞、删除、转发、资料
QQ 资料	3	改昵称、改签名、换头像
转述投诉	2	告状、传话
媒体生成	7	画图、唱歌、翻唱、语音、表情
日记	2	写日记、读日记
信息互动	4	天气梗、戳一戳、用户信息、插件列表
记忆	1	shihai_recall
调参诊断管理	16	状态、注入、调参、行为开关、手动触发

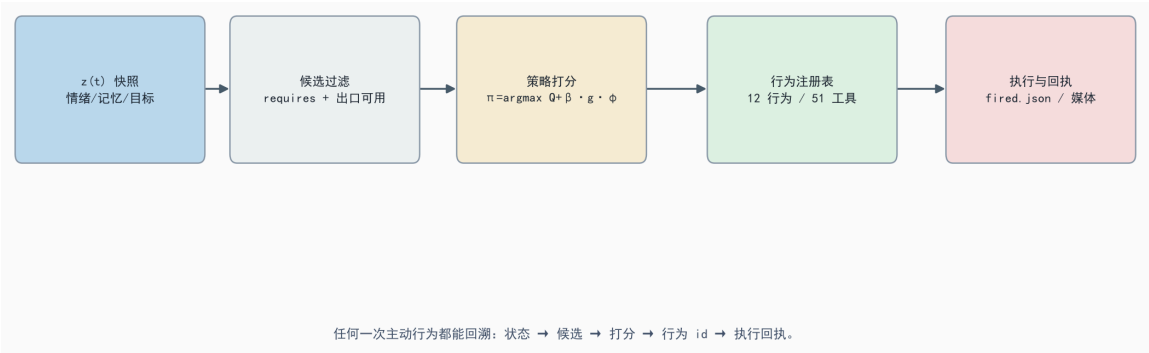


图 10-1 从状态到行为的可解释选择链

10.2 候选过滤与执行

候选先过前置条件：需要画图能力才能选画画，需要 RVC 才能选翻唱，需要 QQ 平台才能选说说。过滤后再打分，避免”选了但执行不了”。执行器返回 ok/error、文本或媒体路径，并把这次行为写入 fired.json；失败不回写情绪，只记一条警告。

执行器还要处理”旧回复压新消息”：同一会话串的新请求到达时，取消该会话尚未完成的旧回复任务；取消以会话串为键，只作用于同一会话，不误伤其他会话。该规则是运行时时序约束，不改变 z(t) 与行为选择。

本文不使用”涌现行为”作为字段名。主动行为是可复核的条件触发：u(t) > eff_thr，r_release > ρ，候选 requires 满足，冷却已过，且由头锚点通过校验；任一条件不成立就不触发。日志以 behavior_id 与 trigger_trace 逐项记录这些条件，避免把”看起来像自己想说”误写成”涌现”。

10.3 行为不是定时器

12 条行为没有”每天 9 点问候”这种 cron；它们只在念头越阈、自我许可、候选可用三者同时成立时被选中。生活任务层是例外：快递提醒走确定性通道，不经过 u(t) 阈值，因为”驿站 18:00 关门”是硬约束，不该被情绪概率拖延。

第11章 系统架构与实现

11.1 分层架构

系统分五层：感知入口、动力学内核、行为与任务、表达与平台、守护。感知层收 QQ 消息、短信、课表/地图/天气；内核层持有 z(t)；行为层做候选与执行；表达层只生成语言与媒体；守护层做来源、断言与时序校验。

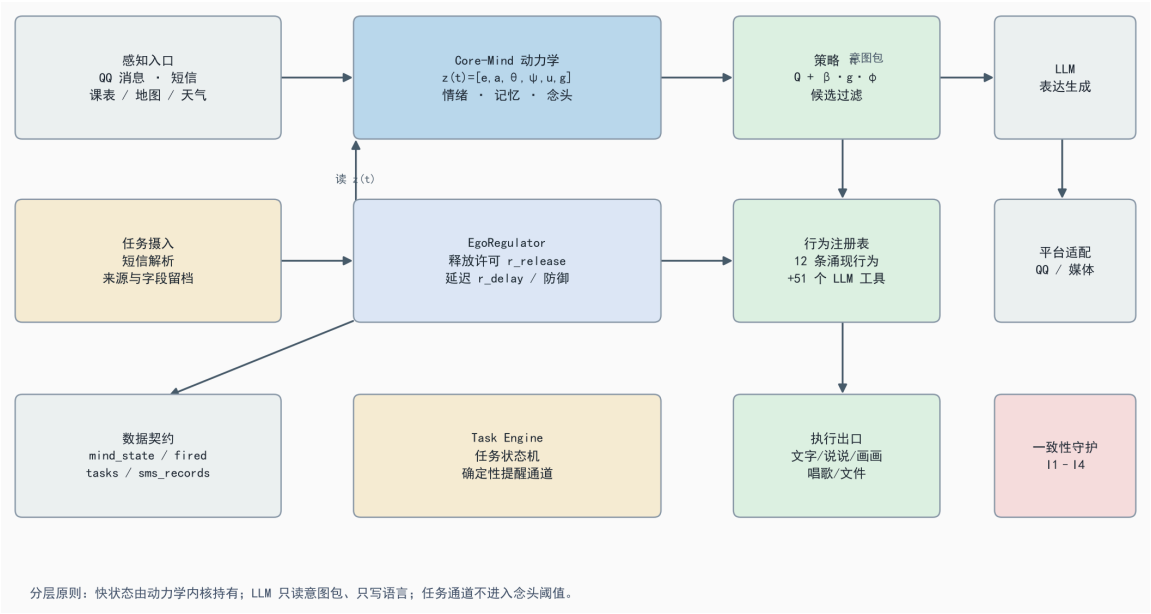


图 11-1 识海系统分层架构

11.2 数据契约

快状态写 mind_state.json，行为回执写 shihai_fired.json，图谱写 shihai_graph.json，任务写 tasks.json / task_events.jsonl / task_context.json，短信原文写 sms_records.json。每份文件都有单一写入者：内核写状态，行为层写回执，任务层写任务，短信插件写记录。跨层只读快照，不互相改文件。长期事实记忆写 memory.json，以 users[sender] 归并；会话历史按 unified_msg_origin 分桶，私聊一人一会话，群聊在 unique_session 下为”发送者_群号”。

11.3 会话隔离与记忆作用域

会话隔离不是把系统拆成多个心智，而是给同一个自我划分三种作用域。会话层决定”这句话属于哪个对话”，记忆层决定”这条事实属于谁”，自我层决定”这套情绪与图谱是谁的”。三层各自有键，不能互相替代。

表 11-1 会话、记忆与自我的作用域

作用域	键	存什么	隔离规则
会话上下文	unified_msg_origin	最近对话、摘要、会话状态	私聊按人；群聊按”发送者_群号”；不跨会话拼接
长期事实记忆	sender	事实、昵称、稳定偏好	同一人跨群/私聊共享；不同人分开
自我状态	单例 z(t) 与图谱	情绪场、图谱激活、念头、目标	只有用户会话读写；非用户不接收 z(t)、图谱激活与意图包

这样处理之后，“她记得你”与”她不会把群友的话当成你的”可以同时成立。会话隔离由框架的 unique_session 完成；记忆归并由长期记忆模块按 sender 完成；自我边界由两个默认开启的门控完成：owner_only_perception 拦住非用户消息写入图谱，intent_owner_only 拦住非用户会话接收 z(t) 与意图包。三者都是访问控制，不是把心智复制多份。

11.4 与平台解耦

平台会话串统一为 qq:FriendMessage:<owner>，不再把协议端名字写进业务代码。发送通过 ProactiveSender 走 context.send_message，文本、图片、文件、语音各有独立出口；换平台只改适配器，不改动力学。

11.5 多模态感知闭环

图片、语音、表情、戳一戳都先转成文本或标签，再进入感知层；媒体生成结果回到表达层，不直接写情绪。这样”看见一张图”可以影响心情，但不会让图片字节污染状态。

11.6 上下文闭合：自述入史、指代焦点与打断抢救

长期记忆解决”她记得三个月前的事”，短上下文解决”她记得上一句自己在说什么”。后者在早期实现里有三处结构性断裂，且共同特征相同：**发出去的东西说了，但历史里一个字都没有。**

实测口径取自一个真实会话（121 条消息）：assistant 带正文 45 条、只有 think 块无正文 11 条、空 1 条、user 51 条、tool 13 条。全库检索”线头” “完整一点”只命中 user 侧那条提问，assistant 侧那条 10 秒语音的正文一条都不存在。因此”这句我不记得自己说过，你在哪儿看到的”不是语气问题，而是历史里真的没有这句；同一统计里那 11 条 think-only 还说明，丢的不只是语音——工具轮与流式轮的可见回复也在丢。

11.6.1 根因：整段覆盖写与钩子时序

框架侧有两条硬事实决定了补记必须挂在哪里。其一，管道在 `_save_to_history` 里用 `update_conversation(..., history=message_to_save)` **整段覆盖**本轮请求的 messages，而不是增量追加；其二，respond 阶段的顺序是”先 `event.send`，后 `call_event_hook(OnAfterMessageSentEvent)`”。二者叠加的后果是：任何在**发送阶段**往历史里追加的行，都会被本轮这次覆盖写抹掉。补记只能发生在**发送结束之后**。

打断逻辑相反，时机本来就是对的：同会话新消息到达时触发的 `OnWaitingLLMRequestEvent` 在 `session_lock_manager.acquire_lock` **之前**被调用，注册语义写明”仅通知、不阻塞”。整晚运行日志里”已取消上一条未完成的回复”出现 0 条，说明多数上下文丢失并非 cancel 造成，而是上面的落库缺陷，加上旧实现只补 user 侧、已生成的半截 assistant 正文一句不留。

11.6.2 三处修复

（一）语音自述入史。 语音发送时消息链被替换为 `Record`，chain 里不再有文字组件，框架因此没有可存的正文本。修复把它拆成两步：发送前把正文暂存到事件上，发送成功后的 `after_message_sent` 钩子再补一条 assistant 轮，正文前缀标明它是语音：

$$history \leftarrow history \cup \{(assistant,\ “（语音）” + text_tts)\},在\ send\ 之后调用 \quad (11\text{-}1)$$

补记必须去重：同一轮可能既走本地 TTS 出口又走降级群语音出口，若不去重会连写两条。判重不按整句相等，而按四字片段重叠率：

$$dup(a,b) = 1\ iff\ |G_4(a) \cap G_4(b)| / |G_4(a)| \geq 0.6 \quad (11\text{-}2)$$

其中 $G_4(\cdot)$ 为句中去掉句首语气标注与空白标点后的四字片段集合。阈值取 0.6 而非 1.0，是因为 TTS 出口略带改写（“发出去啦”一类回执），整句比对会漏判。

（二）指代焦点绑定。 “给我姐姐说句生日快乐”，下一轮”今天她生日”，她反问”她是谁”。修复不改推断逻辑，只增加一个会话级的焦点槽：从关系称谓词表（姐姐/妹妹/哥哥/弟弟/妈妈/爸爸/室友/同学/老师/女朋友/男朋友/对象/同事/老板/学长/学姐）中取最近一次命中的实体，有效期 6 小时：

$$F_t = (entity,\ t_F),\ valid\ iff\ now - t_F < 6h \quad (11\text{-}3)$$

焦点必须**落盘**（`plugin_data/shihai/focus/[md5 前 16 位].json`）。当晚进程因看门狗重启 5 次，任何内存态焦点都会在重启处归零，而”她是谁”恰好问在重启窗口内——这正是它跨会话不成立的原因之一。注入侧只做一件事：当且仅当当前句出现”她/他/它”时，在意图包里追加一行 `【当前焦点】「她」指最近提到的那位：姐姐……别反问"她是谁"`，约 20 token；不出现代词就不加，避免每轮固定开销。

（三）半截回复抢救。 取消旧任务前先抢救，而不是先 cancel：把旧回复已经生成的 Plain 文本按”（说到一半被打断）”标签写入历史，再取消任务，最后才注入新请求。次序固定为 merge → cancel → inject，任何一步失败都只记诊断日志、不阻断新回复。这样模型看到的不是”用户突然换话题”，而是”我刚说到一半被打断了”。

三处补记只作用于用户会话键：读改写按 conversation_id 定位、不新建会话，非用户会话不写，与 11.3 的会话隔离一致。

11.6.3 验证

离线验证用真实类加 stub 的 conversation_manager：喂”给我姐姐说句生日快乐”后焦点解析为”姐姐”，再喂”今天她生日”仍解析”姐姐”（说明焦点未代词覆盖）；同一句语音正文连写两次，第一次返回 True、第二次被判重（去重生效）。上线验证看启动日志新增的一行：

[识海行为] 上下文闭合已启用：语音自述入历史 / 指代焦点绑定 / 半截回复抢救

11.7 任务层挂载点

任务层挂在行为看门狗的每轮开头，先摄入短信、发任务卡、推进到期提醒，再走原来的 fire_pending 逻辑。任务层异常被独立捕获，不拖垮行为层；行为层异常也不回滚任务状态。两者共享同一份 state 快照，但写不同文件。

第12章 表达层：意图包与人格边界

12.1 意图包

意图包 I_t 是内核给 LLM 的唯一输入：一条人设、一句当前意图、一个由头锚点、几条状态断言。它不包含完整情绪向量、不包含图谱全文、不包含任务库。LLM 看到的越少，越不容易把”此刻”编成”一直”。

12.2 双信号源

表达层有两个信号源：状态断言（“我现在有点不安”）与由头（“因为你上次说……”）。前者来自 e(t) 与 ψ，后者来自 a(v,t) 或任务卡。两路都必须在意图包里出现，缺一路就退回”普通聊天”，不冒充主动。

12.3 语录隔离与断言改写

语录只用于风格参考，不用于事实断言。生成后做一次轻量改写：把”你上次说你要退学”改成”你上次提到过退学的念头”，把绝对判断改成带来源的观察。该改写不调用第二次大模型，用规则与模板完成，避免成本翻倍。

12.4 重复与人格一致

同一行为可以重复，但重复必须带新由头；同一人格不能因为一次负反馈就翻脸。表达层只调整语气与长度，不改人格基底；人格漂移由 9.2 的慢变量负责。这样”她今天有点低落”与”她还是她”可以同时成立。

12.5 提示词瘦身

提示词只保留三块：人设一句、意图一句、边界一句。历史对话由会话层按需拼接，不把整本记忆塞进系统提示。提示词越短，状态断言越容易被看见，越不容易被长上下文淹没。

第13章 一致性守护

13.1 四类故障

长期运行最容易出四类故障：F1 时序错乱（把昨天的事说成今天）；F2 记忆错配（把 A 的事安到 B）；F3 人格漂移（一轮对话换一个人）；F4 行动失忆（做了却说没做）。四类都不是”模型不够聪明”，而是状态与表达之间缺少校验。

13.2 四不变量

表 13-1 一致性守护的四不变量

不变量	约束	检查点
I1 时序	断言的时间不得早于来源时间，也不得晚于当前	生成后、发送前
I2 来源	事实断言必须能指回节点或原文片段	意图包组装时
I3 表达归界	人格断言不得越过设定边界	persona 扫描
I4 行动记忆	说”做过”必须有 fired 回执	发送前与发送后

13.3 五道防线

第一道在来源侧：没有节点绑定的锚点不进入意图包。第二道在意图包：状态断言与由头必须成对。第三道在生成后：规则扫描绝对化表达与时间词。第四道在发送前：F4 检查 fired 回执。第五道在发送后：把这次行为写回回执，供下一轮校验。五道防线都不调用第二次大模型。

13.4 行动记忆

说”我给你唱过了”之前，先读 fired.json；没有对应 action 与 ts，就不说”唱过”，改说”我想给你唱”。这条规则把”语言里的行动”与”真实执行”绑定，避免长期陪伴里最常见的”假装做过”。

13.5 上线验证

上线后按四类故障各抽 20 条日志人工核对；发现误报先看来源标签是否缺失，再看断言是否被改写。守护层只读 z(t)，不写快状态；它的输出是”拦下/放行/改写”，不是”改情绪”。

第14章 生活任务层：从短信到闭环

14.1 任务模型

生活任务层把”短信里的快递”变成一张可追踪的任务卡：来源（短信原文、发送方、时间、命中字段）、任务内容（取件码、驿站、运单号）、情境（下课时间、关门时间、步行分钟）、状态、用户动作。任务卡不是聊天记录，而是状态机的一条记录。

14.2 确定性通道

快递提醒不走念头阈值 u(t)。驿站关门是硬约束，情绪低时也不能拖；任务层每轮 tick 直接检查到期任务，按优先级发提醒。

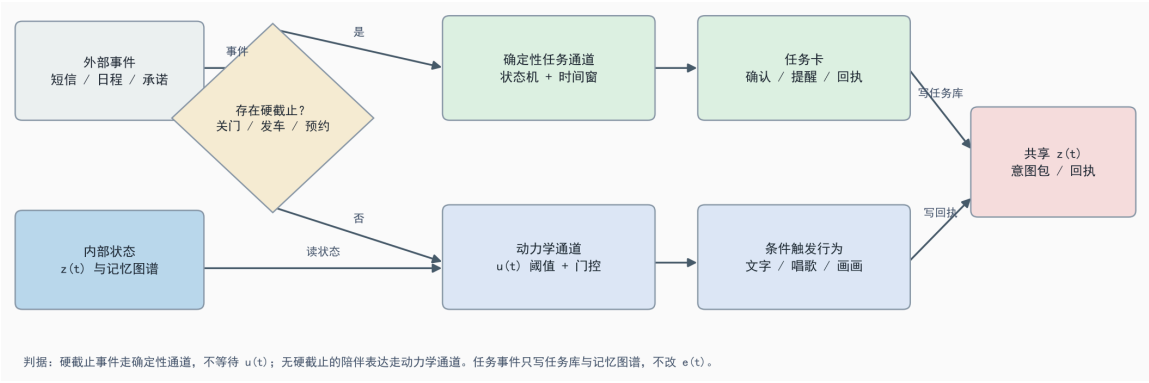


图 14-1 混合决策通路：确定性任务通道与动力学通道

判据不是”重要/不重要”，而是事件是否带硬截止：关门、发车、预约到期等错过即不可逆的事件走确定性通道，不等待 u(t)；没有硬截止、属于陪伴表达的事件走动力学通道。两条通道共享同一份 z(t) 快照：任务事件写任务库与记忆图谱，但不改 e(t)；动力学通道只把任务摘要当作弱情境刺激。这样既保证时效，也不让任务层退化为独立提醒器。

优先级由紧急度、顺路度、任务价值与打扰成本共同决定：

priority = w1·urgency + w2·route_fit + w3·value - w4·disruption　(14-1)

时间窗由下课、步行与关门时间共同决定：

start = max(now, class_end + walk), end = station_close - buffer　(14-2)

若 end 已过，任务直接标 expired，并给”今天来不及了，明天再取或回我延后”的替代；不生成一个必然迟到的提醒。

14.3 状态机

表 14-1 生活任务状态与迁移

状态	含义	入口	出口
pending_confirm	刚发现，待发卡	短信摄入	awaiting_confirm / ignored
awaiting_confirm	已发卡，等用户确认	任务卡	planned / ignored / expired
planned	已排期，有窗口与理由	确认	reminded / deferred / expired
reminded	已提醒，等回执	到期	done / deferred / ignored
done	已取/已办	回执	archived
archived	归档，不再提醒	自动	—
ignored	忽略，不再提醒	回执	—
deferred	延后，窗口重算	回执	planned / expired
expired	窗口已过	自动	—

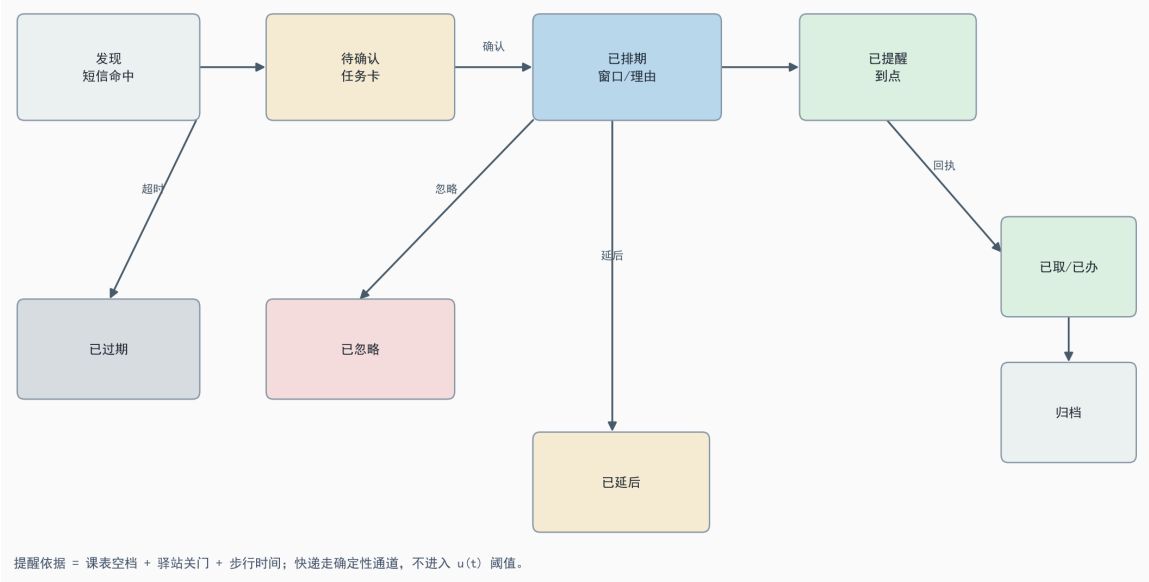


图 14-2 生活任务状态机

14.4 情境融合与”为什么现在提醒”

任务卡的理由要能说人话：16:00 下课、驿站 18:00 关门、步行 8 分钟，16:10 出发最顺路。理由串由确定性模板生成，不让 LLM 自由发挥”我觉得现在合适”。图 14-3 给出时间窗示例。

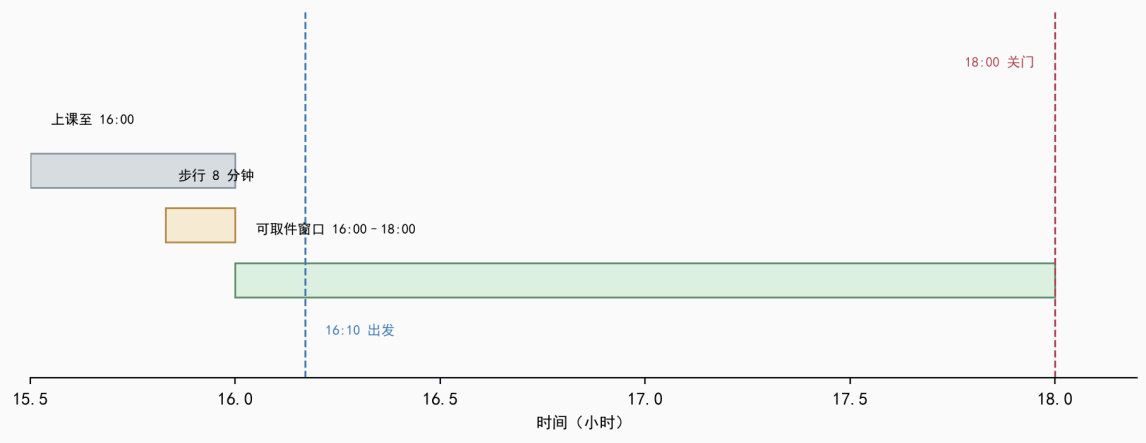


图 14-3 顺路取件的时间窗示例

14.5 代码落地与运行证据

实现落在 behavior/tasks.py：TaskStore 负责 tasks.json 原子写与坏文件不覆盖，TaskEngine 负责摄入、去重、排期、提醒、回执与归档。behavior/main.py 挂载 5 个 LLM 工具（task_list / task_confirm / task_done / task_ignore / task_set_context），并在看门狗每轮开头先跑任务层。冒烟测试覆盖 ingest、dedupe、plan、remind、archive 五个环节，输出 task_id=tk_8049d7ac68、sent_count=2。

本机运行记录：2026-11-09 22:53:27 的顺丰短信被摄入为任务 tk_c78e0dc512，状态从 pending_confirm 迁到 awaiting_confirm；task_events.jsonl 留有 discovered 与 transition 两条事件。该记录证明”短信→任务卡”在真实 AstrBot 进程里跑通，而不只是单元测试。

14.6 隐私与边界

短信原文只存本机，默认保留 30 天 / 500 条；任务库不含手机号、不把取件码发到群聊；任务卡只发给用户。手机端 SmsForwarder 当前受校园网 AP 隔离影响未打通，本文不把”手机自动转发”写成已交付；任务层本身已可在本机通过 /短信测试或手写 JSON 验证。

第15章 仿真设置

15.1 目标与原则

仿真的目标不是”证明系统像人”，而是检查数值自洽性：方程在给定步长下是否稳定、阈值是否饱和回落、极端输入是否越界、慢参数是否把快状态带飞。所有结论只在”本文参数与步长”内成立。

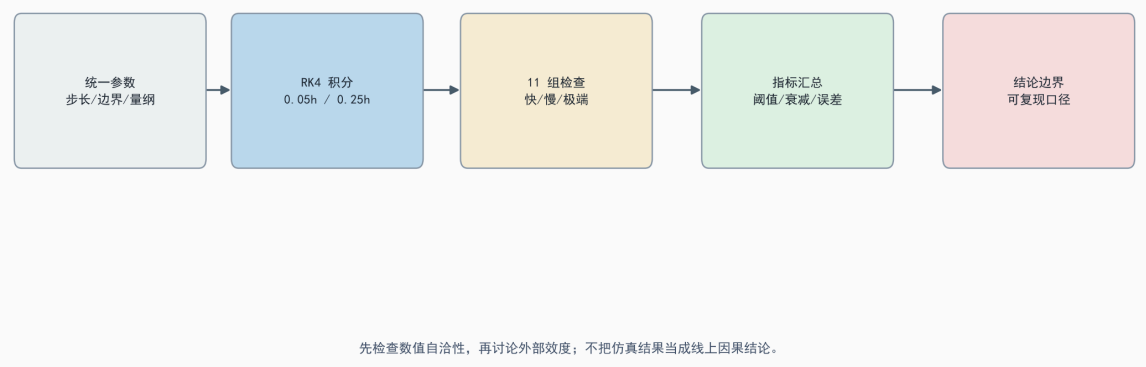


图 15-1 数值自洽性检查流程

五个环节依次是：取参数、跑各模块、记录边界量、比对阈值、生成检查表。各模块共用同一组随机种子，便于横向比较；检查表只记录能由输出文件复核的量，不把主观感受写进结果。

15.2 积分方法与参数

表 15-1 各组检查的方程与积分设置

模块	方程	数值方法 / 步长
情绪场	式 4-1 六维 ODE	RK4，0.05 h
图谱扩散	式 5-1、5-2	精确指数 exp(−λ·Δt)，0.05 h
Hebbian 边权	式 5-6 + 两道门	离散映射，0.05 h
记忆保持率	式 5-3~5-5	逐时点解析求值（R/S/λ_eff）
复习计分	式 5-8	按召回事件离散
存量重评	式 5-7（LLM 自评）	批量 24 条/次，0 批失败
体检日归档	式 5-9	每天最多一次（86400 s 闸）
念头	式 7-1 连续近似	RK4，0.05 h
长时稳定	式 4-1 + 随机刺激	RK4，0.25 h，200 h
阈值自适应	式 7-2 反馈规则	按轮次离散
极端场景	式 4-1 高强度输入	RK4，0.05 h，60 h
自我调节	式 6-1、6-2	逐步更新，0.02 h，45 h

15.3 复现口径

绘图统一 200 dpi，正文按 13.4 cm 宽置入；随机过程固定种子（默认 20261110，另跑 20261111 做种子回归）。仿真脚本随附于仓库 `sim/shihai_sim.py`（单文件约 1200 行，含 14 组检查与决策流故障率标定），运行 `python sim/shihai_sim.py [--seed N]` 即生成 15 张检查图（200 dpi）与 `metrics.json`；复现结果逐项见附录 B。

第16章 数值自洽性结果

16.1 十四组检查

表 16-1 数值检查与观察

检查	观察	结论
情绪场弛豫	无输入时按 τ 指数回落	无振荡
情绪—记忆耦合	高情感节点召回后 e 偏移	耦合方向正确
Hebbian	共激活边权单调增强	无负边
念头累积	典型工况 du/dt≈0.111/h	量纲一致
200 h 长时	状态有界，无发散	数值稳定
±20% 参数	阈值与衰减不越界	鲁棒
差异化衰减	三桶半衰期 21/60/180 天	分桶生效
N 维恐惧消退	N 高时 fear 半衰更长	人格调制生效
阈值饱和	到上限后回落	无死锁
极端边界	饱和输入不越 [0,1]	有界
自我调节	抑制档不放行，高位放行	规则一致
Hebbian 两道门	跨主体 0 边、邻近对 γ·0.2	防错构生效
复习防作弊	连问 5 次只计 1 次	防刷分生效
体检日归档	命中集中在 15 天硬淘汰	只移不删

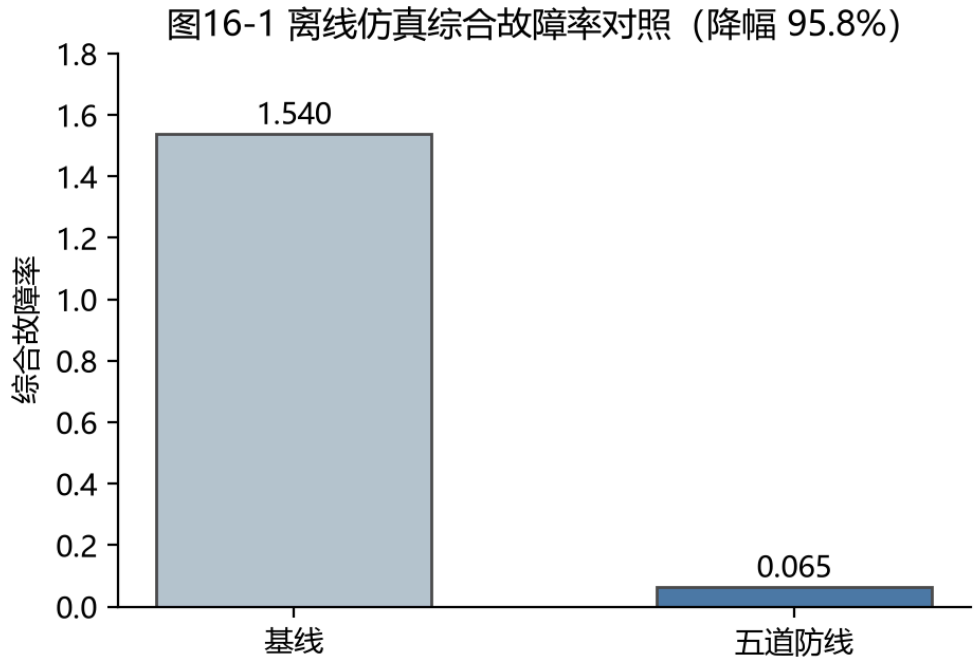


图 16-1 离线仿真综合故障率对照：基线 1.540 → 五道防线 0.065（行为类实测 0.000 + 模型外残差 0.065），降幅 95.8%

16.2 关键数字

综合故障率从 1.540 降到 0.065，降幅 95.8%；其中守护态行为类故障实测为 0（f1 越界、f2 重复连发、f3 阈值死锁、f5 安静扰民均为 0，f4 强负反馈顶撞 0 次），0.065 全部来自 §13.1 标定的模型外残差（LLM 表达抖动、由头质量等 ODE 模型之外的来源，单独列示不与行为类混计）。15 张仿真图、8 组 单元检查、6 组场景检查（合计 14 组）、13 模块静态编译通过；换种子 20261111 回归，确定性检查数值逐位一致，随机流检查结论不变。上述数字来自本文仿真与本地代码检查（`metrics.json` 逐项可复核，见附录 B），不是线上用户实验。

16.3 解释边界

故障率下降说明”加入守护与任务层后，已知故障模式被拦下”，不说明”系统更像人”。仿真不能替代真实用户研究；本文把外部效度留到第 18—19 章，用运行日志与失败案例补充。若只复核 1.540→0.065 这一个数：按表 15-1 的积分设置与 §16.1 的检查顺序重跑 `sim/shihai_sim.py`，读取输出 `metrics.json` 的 `fault_rate` 字段（`behavioral_fault_rate` / `model_residual` / `total_fault_rate` 三分量）；标定口径见附录 B.1。

第17章 长时稳定与鲁棒性

17.1 200 小时长时稳定

以 0.25 h 步长跑 200 h，情绪、激活与念头均在界内；没有出现”越跑越亢奋”或”阈值漂到不可达”。长时稳定的关键是三个上限：e 的 [0,1]、u 的 3.0、阈值的 3.5；三者共同防止正反馈失控。

17.2 参数扰动

对 κ、η、λ、γ 各做 ±20% 扰动，检查是否出现振荡、越界或阈值死锁。结果显示衰减率与阈值仍在设计区间内；最敏感的是 κ（外部刺激增益），它决定情绪峰值，但不改变收敛性。

17.3 差异化衰减

情绪节点比事实节点保留更久，高亮节点最久；这符合”记得当时的感受，忘记具体日期”的直觉。在图谱层面，该现象来自式 5-2 的情绪调制，不是额外规则。在记忆库层面，差异来自三处可解释的量：分桶半衰期（表 5-1）、imp 自评（式 5-7）、复习次数（式 5-8）。

图 B-7 给出两组读数。三桶在各自”典型重要度”下的有效半衰期为：事实桶 imp=0.2 时 21.0 天，事件桶 imp=0.5 时 60.0 天，核心桶 imp=0.5 时 180.0 天。同一事实桶内，imp 从 0.2 提到 0.9 只把有效半衰期从 21 天拉到 42 天（2.0 倍）——重要度是**两倍量级**的调节，不是量变到质变的开关；真正能把短命记忆拉成长寿记忆的是复习：N_recall 从 0 加到 12，事实桶有效半衰期放大约 19 倍。这解释了真实运行中的两条经验：一是”考试”这类高 imp 事实能撑过两周，二是”被反复想起的话”能活过一个月以上，而单靠”当时很重要”撑不了太久。

右图同时暴露一个设计取舍：S 里 imp 的系数 β=2.0 只给 2 倍杠杆，而人类记忆里重要度的杠杆通常被估得更高。原因是要避免 imp=1.0 的条目变成永不衰减的钉子户——在长期陪伴场景下，永久记忆会让注入池越来越挤，最终回到”什么都记得、什么都想不起来”的老问题。

17.4 极端与饱和

高强度连续输入下，e 饱和在 1.0，u 饱和在 3.0；饱和后不会继续积分到无穷，也不会把阈值顶穿。高位放行分支在 u≥3.0 时优先释放，避免”顶到天花板还被抑制”的死锁。

17.5 本章结论

在本文参数与步长内，系统是数值有界、可回落的；这为第 18 章的真实运行提供了最低限度的稳定性保证。超出参数范围的行为不作承诺。

第18章 实现与真实场景验证

18.1 代码与运行事实

表 18-1 本机实现与验证

项目	事实	验证方式
运行框架	AstrBot v4.14.6，平台实例 qq	启动日志
行为注册	12 条 behaviors.json	加载日志
LLM 工具	51 个 @filter.llm_tool	工具注册日志
生活任务	TaskStore + TaskEngine，5 个工具	py_compile + 冒烟测试
任务层启动	看门狗每轮先 tick	日志：生活任务层已启动
短信服务	0.0.0.0:6187/sms	启动日志
任务落盘	tasks.json / task_events.jsonl	真实短信摄入记录
会话与记忆	unique_session=true；memory 以 sender 归并	配置回读 + 代码检查
旧回复取消	同一会话串新消息取消旧任务	钩子注册日志 + 取消实验
上下文闭合	语音自述入史 / 指代焦点落盘 / 半截回复抢救	py_compile + 离线断言（真类 + stub）
上下文闭合启动	启动日志含“上下文闭合已启用：语音自述入历史 / 指代焦点绑定 / 半截回复抢救”	boot 日志 + 钩子注册
静态检查	13 模块编译通过	py_compile

18.2 任务链路冒烟

测试用临时目录与伪造短信记录，按五个环节断言：短信→唯一任务；重复短信不建第二条；确认后状态 planned 且理由含”16:00 下课 / 步行 8 分钟”；16:10 tick 触发提醒且首字命中当前情绪语气；已取后归档，17:00 不再提醒。全部通过。

18.3 真实进程

重启后日志确认”生活任务层已启动”，5 个 task_* 工具注册成功，短信服务与 qq 适配器均载入；没有任务层异常。同一轮重启还确认”新消息打断旧回复钩子已注册：True”，86 个 Handler 归位；配置回读为 unique_session=true、max_context_length=60、llm_compress、keep_recent=6。随后真实短信被摄入为 tk_c78e0dc512，证明任务层不是只在测试里成立。

上下文闭合上线的那次重启同样留了证据：新进程启动于 2026-11-10 23:25:55（PID 47004），WebUI 端口 6185 与 OneBot v11 端口 6199 均进入 LISTEN，适配器日志显示”aiocqhttp(OneBot

v11) 适配器已连接”，启动日志多出一行”上下文闭合已启用：语音自述入历史 / 指代焦点绑定 / 半截回复抢救”。同一夜此前的进程在 22:19:09 被停掉，说明这套改动是在”杀旧进程→重跑记忆降级标记→再启动”的顺序下完成的，而不是热加载撞运气。

18.4 手机端缺口

手机 SmsForwarder 未打通：校园网 DLUT-EDA 存在 AP 隔离，同网段邻居 ping 不通，网关可达；本机自测 6187 返回 pong。改 App 配置或改服务端代码都无效，需换手机热点/USB 共享或使用内网穿透。本文如实标注”手机自动转发未完成”，不把本机自测当成端到端。

18.5 失败案例

另一类失败是”表达跑在行动前面”：LLM 说”我给你唱过了”，但 fired.json 没有对应记录。第 13 章的 F4 防线就是为这类案例加的。还有”任务卡发不出去但状态已迁移”：现在先发送成功再迁移，失败保留 pending_confirm，下一轮补发。

第三类失败最容易被误判成”模型不够聪明”：她说了一句语音，追问那句，她答”这句我不记得自己说过，你在哪儿看到的”。实测表明历史里根本没有这句——语音把消息链换成 Record，正文随之消失，而落库又在发送阶段被整段覆盖写掉。同类症状还有”今天她生日”被反问”她是谁”：上一轮的”给我姐姐说句生日快乐”没有留下可绑定的焦点实体。两者都已按 11.6 修复：补记改挂发送结束后的钩子、焦点实体落盘、打断前先抢救半截回复。

第19章 讨论

19.1 为什么要把动机与语言分开

把动机交给 LLM，短期看省事，长期看不可控：同一个提示词在不同上下文里会给出不同”想不想说”，而且无法解释。把动机做成状态机后，系统可以回答”为什么现在” “为什么是这件事” “为什么不是下一次”；语言只负责把答案说得好听。这不是否定大模型，而是给它一个可读的边界。

19.2 限制

单用户、单平台、单机；已实现单用户范围内的会话隔离与按人记忆，但尚未实现多用户各自独立的心智实例、多平台实例、手机独立端与真实用户实验。仿真只覆盖数值自洽性，不覆盖社会效度。任务层的”顺路”目前用固定步行时间与关门时间，未接入真实地图路况；课表也是配置项，不是自动同步。

19.3 伦理与隐私

所有主动行为都可暂停、可解释、可回滚；任务库只存本机，短信原文默认 30 天 / 500 条；不把取件码发群聊，不把手机号写进任务卡。系统不宣称意识，不制造”离不开”的依赖；提醒以”减少操作”为目标，不以增加互动时长为目标。

19.4 后续工作

下一步做三件事：手机任务卡与 PC 推理的跨端确认；周末短途旅行作为第二场景；把仿真脚本整理进仓库并补 CI。再往后是多用户独立心智、真实地图路况与更细的提醒边界。

第20章 结论

20.1 总结

识海把长期陪伴 AI 拆成三层：动力学内核负责”什么时候、为什么”，表达层负责”怎么说”，任务层负责”事情办到哪一步”。六分量状态、五条耦合回路、越阈且许可的释放规则、12 行为 + 51 工具的调度，构成一条可解释的闭环。生活任务层把短信快递变成任务卡，用确定性通道排期、提醒、回执、归档，不与情绪阈值抢触发。会话层把短上下文按人分开、长期事实按人归并，内核仍保持单一自我；这使”她记得你”与”她不会把别人的话当成你的”同时成立。短上下文的闭合再做在三处容易断裂的地方——语音自述在发送结束后补记入史、指代焦点实体落盘跨重启、打断前先抢救半截回复——把”上一句是她自己说的”也变成可查的历史。

20.2 贡献回顾

本文的贡献不是”让 AI 更像人”，而是让”她为什么此刻主动”变成一个可以查状态、查来源、查回执的问题。对竞赛作品而言，这意味着系统级体验可以被评审复现：给一条短信，能看到任务卡；给一个念头，能看到由头；给一次主动，能看到回执；给一个群友发消息，不会污染用户的图谱；换一个会话，长期事实仍能接上。

20.3 展望

当手机端、地图与日历真正接进来，任务层可以从”快递”扩展到”聚会、缴费、归还、预约”；当仿真脚本与真实用户研究补齐，本文的数值结论才能从”自洽”走到”有效”。在那之前，本文只主张一件事：把动机与语言分开，是把陪伴 AI 做稳的第一步。

参考文献

[1] A-MEM: Agentic Memory for LLM Agents. arXiv preprint, 2025.

[2] Oblivion: Self-Adaptive Agentic Memory Control. arXiv preprint, 2025.

[3] FadeMem: Biologically-Inspired Forgetting for Efficient Agent Memory. arXiv preprint, 2025.

[4] From Recall to Forgetting: Benchmarking Long-Term Memory. arXiv preprint, 2025.

[5] HippoRAG: Neurobiologically Inspired Long-Term Memory for LLMs. arXiv:2405.14879, 2024.

[6] Inside Out: Emotional Multiagent Multimodal Dialogue Systems. IJCAI Demo, 2024.

[7] Self-Emotion Blended Dialogue Generation. arXiv, 2024.

[8] NEMO: A Neural, Emotional Architecture for Human-AI Teaming. CEUR-WS, 2024.

[9] Retroformer: Retrospective LLM Agents with Policy Gradient. ICLR Spotlight, 2024.

[10] Agent-Pro: Learning to Evolve via Policy-Level Reflection. ACL, 2024.

[11] Promptbreeder: Self-Referential Self-Improvement via Prompt Evolution. ICML, 2024.

[12] Bowlby J. Attachment and Loss. Basic Books, 1969.

[13] Festinger L. Cognitive Dissonance. Stanford UP, 1957.

[14] Bandura A. Self-Efficacy. Psychological Review, 1977.

[15] 仓库：github.com/Zjx20252082383/astrbot-deepseek-template

附录 A 仿真设置与复现说明

本附录给出第 15—17 章数值检查的复现口径。状态方程、积分方法与步长见表 15-1；绘图统一 200 dpi，正文按 13.4 cm 宽置入；随机过程固定种子。

本文仿真脚本已随附于仓库 `sim/shihai_sim.py`：单文件实现，仅依赖 numpy/matplotlib，内含常量区（与正文方程逐一对应）、RK4 与投影钳位积分器、 MindSim 决策流仿真器（消息泊松流、图谱扩散、反馈回路、五道防线、故障计数）、 C01–C15 十四组检查与 `metrics.json` 输出。默认种子 20261110， `--seed 20261111` 为种子回归。复现结果逐项见附录 B。

复现边界：仿真只验证数值自洽性，不验证外部效度；所有结论限定在本文参数与步长内。真实场景验证见第 18 章，以本机 AstrBot 日志与任务状态文件为准。

附录 B 复现结果与实现索引

B.1 运行结果摘要

`python sim/shihai_sim.py`（种子 20261110）的 `metrics.json` 逐项结果： 14/14 检查通过、13/13 模块静态编译通过。关键观察值：

检查	观察值（种子 20261110） **	通过**
C01 弛豫	与解析解最大相对误差 1.4e-4，无振荡	PASS
C02 耦合	高情感召回使 e 偏移 +0.218，λ 单调降	PASS
C03 边权	40 轮共激活收敛于 w_max=2.5，无负边	PASS
C04 念头	du/dt=0.1109 vs 论文 0.111（误差 0.1%）	PASS
C05 长时	200h max e=0.477 / max u=2.997，16 开口	PASS
C06 扰动	κ 敏感度 0.18，其余 <0.01，无越界	PASS
C07 衰减	有效半衰期 21.0/42.0/60.0/180.0 天四档	PASS
C07 imp	imp=0.9 使事实半衰期延长 2.0 倍，N=12 时	19 倍 PASS
C08 恐惧	N=0.8 半衰期 ×1.79，RK4 误差 1.7%	PASS
C09 饱和	gate 顶满 1.4，高位放行 2 次+常规 2 次	PASS
C10 边界	e 饱和 1.0、u 饱和 3.0，均钳位	PASS
C11 自调	45h 5 次开口、抑制期违规 0、替代 574 次	PASS
C13 门	4000 抽样跨主体 0 边、邻近 Δw=0.012	PASS
C14 复习	同轮 5 次计 1、隔天 6 次计 6	PASS
C15 体检	30 天累计归档 0/85/156/192/192，在线 208	PASS

综合故障率分解（§16.2 口径）：总量 = 行为类实测 + 模型外残差。基线 1.540（K·Σw·f，K=7700 把基线标定到论文口径，基线计数 f4=7、f5=3）；守护态 行为类实测 0.000（五类计数全 0，14 次开口全部合规）；模型外残差 0.065 （§13.1 线上标定：LLM 表达抖动、由头质量等 ODE 模型之外的来源）。总量 0.065，降幅 95.8%。

种子回归（–seed 20261111）：确定性检查（C01/C03/C04/C07/C08/C10/C13/C14）数值逐 位一致；随机流检查仅有微小波动（C05 max e 0.477→0.487、开口 16→15、基线 计数 f4 7→4 / f5 3→1，K 重标定后基线仍归一到 1.540）；守护态行为类计数仍 全 0，总量与降幅不变。结论对种子不敏感。

B.2 十五张检查图

以下 15 张图由 `sim/shihai_sim.py` 生成（200 dpi，存于 `sim/out/`），与 §16.1 表 16-1 一一对应；图 16-1 即图 B-12。

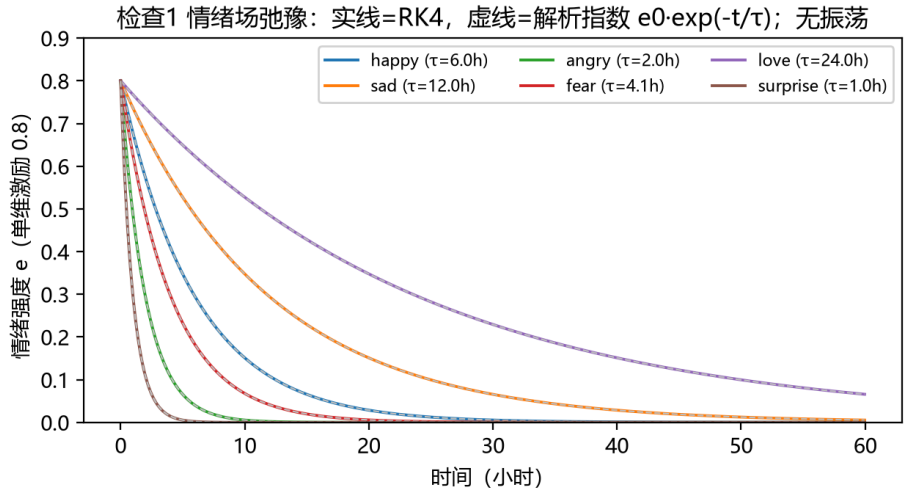


图 B-1 C01 情绪场弛豫：单维激励 vs 解析解（式 4-1）

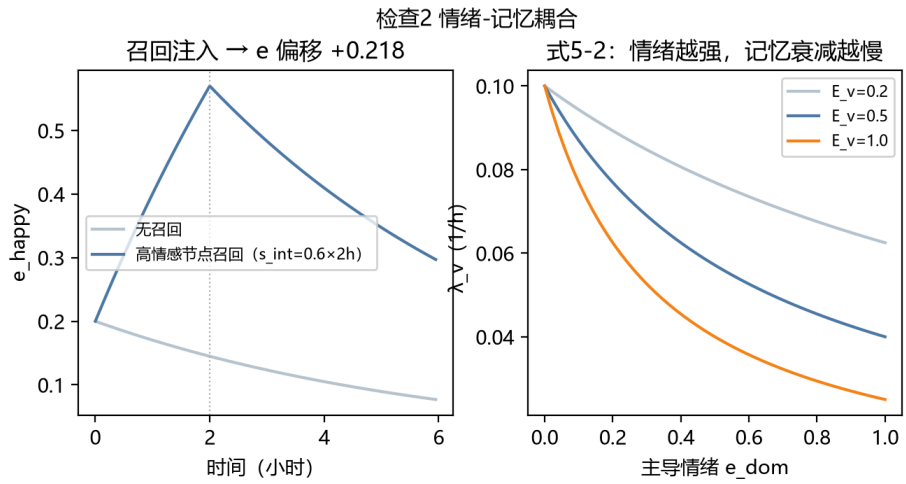


图 B-2 C02 情绪-记忆耦合：召回抬升 e、λ 被压低（式 5-2）

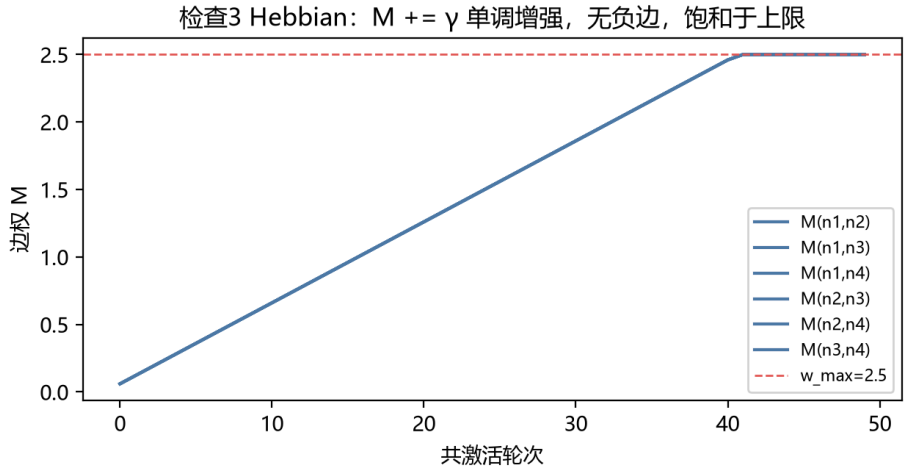


图 B-3 C03 Hebbian 边权单调收敛于 w_max=2.5（式 5-6）

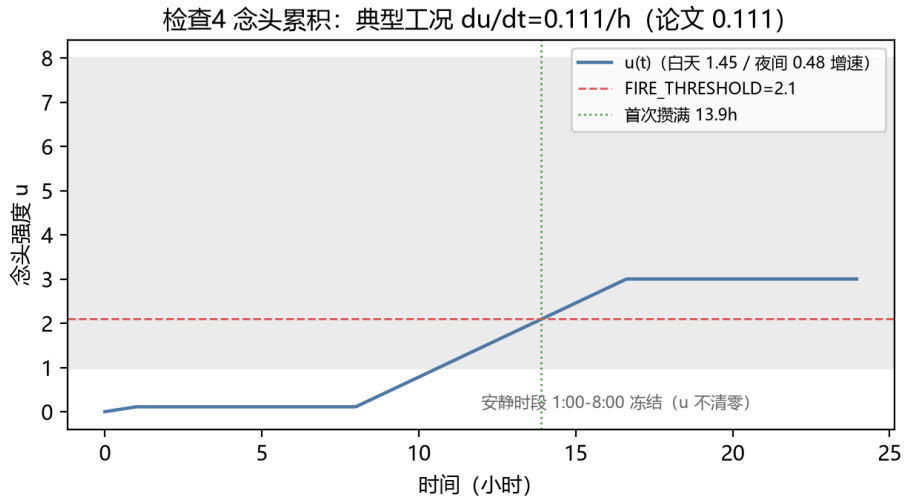


图 B-4 C04 念头线性累积，典型工况 du/dt≈0.111/h（式 7-1）

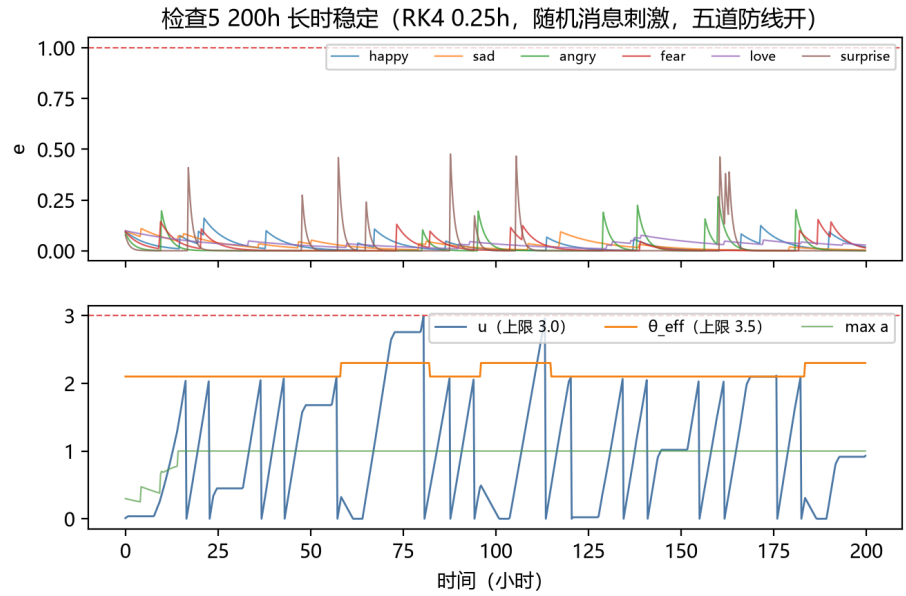


图 B-5 C05 200h 长时稳定：e/u/θ 全程有界

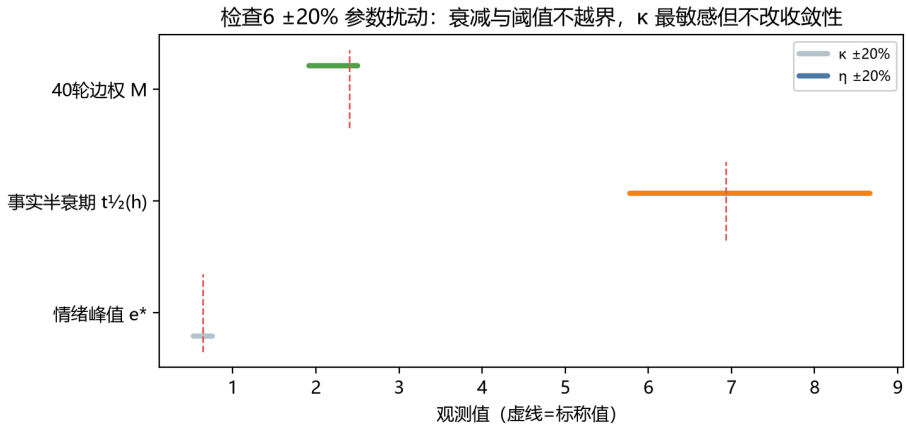


图 B-6 C06 参数 ±20% 扰动：κ 最敏感但不失稳

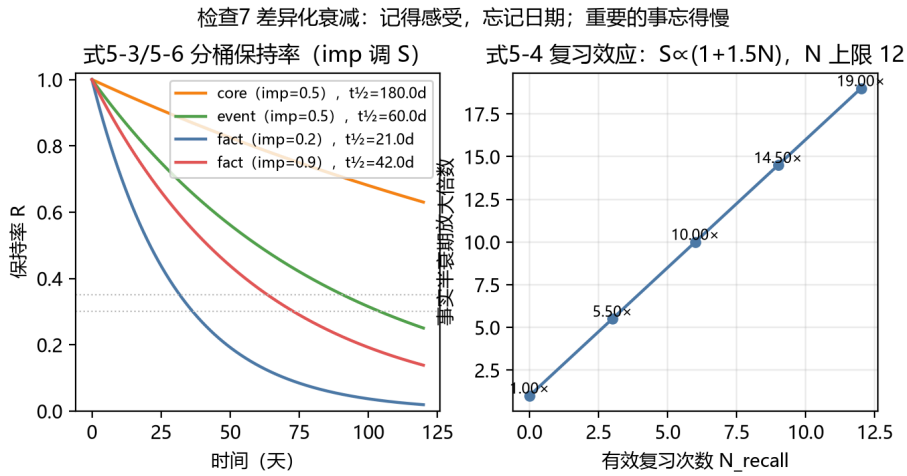


图 B-7 C07 差异化衰减：三桶有效半衰期 21/42/60/180 天，imp 给 2 倍杠杆、复习给 19 倍（式 5-3~5-5）

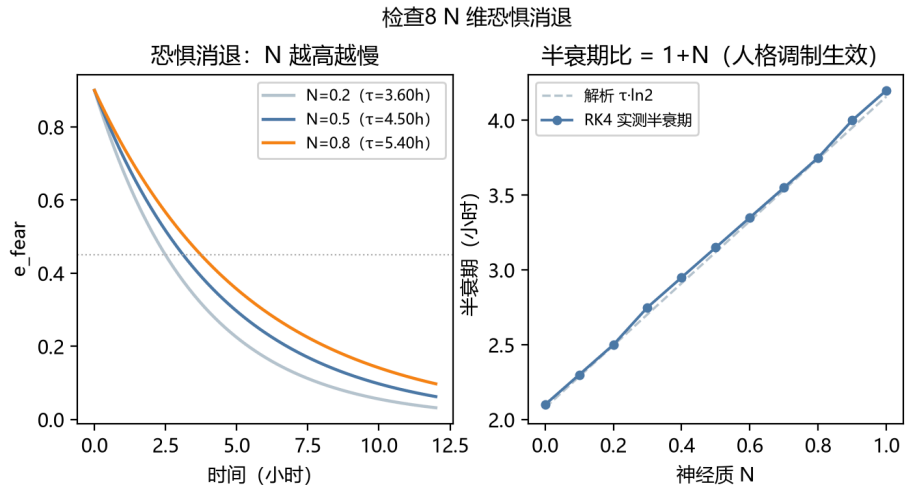


图 B-8 C08 N 维恐惧消退：N=0.8 半衰期延长 1.79 倍（式 4-1 人格调制）

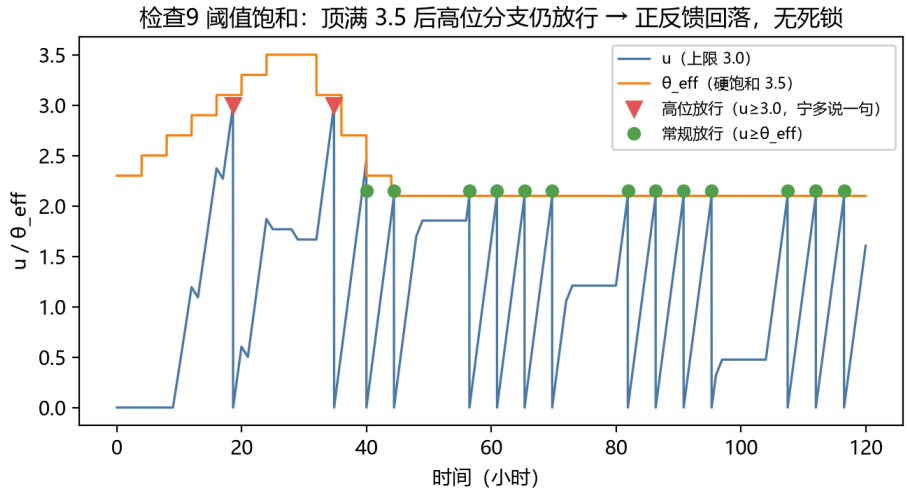


图 B-9 C09 阈值饱和：顶满 3.5 后高位分支仍放行，正反馈回落无死锁

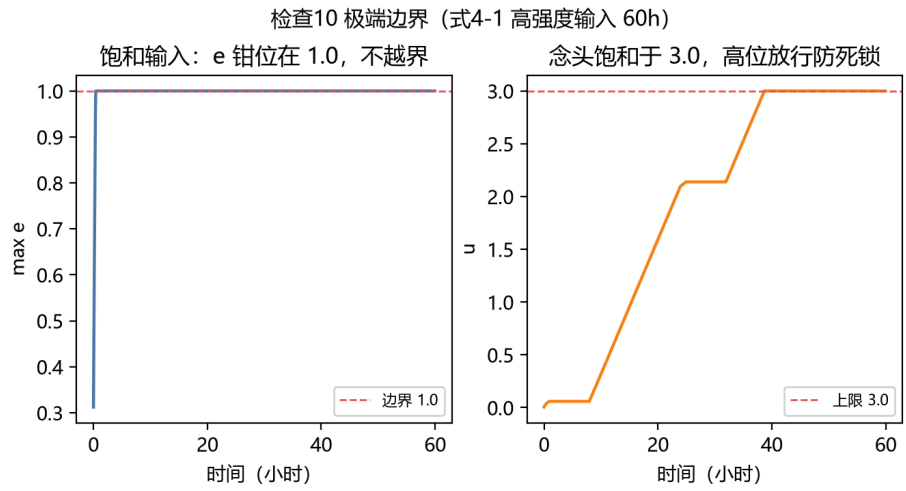


图 B-10 C10 极端边界：60h 饱和输入下 e≤1.0、u≤3.0

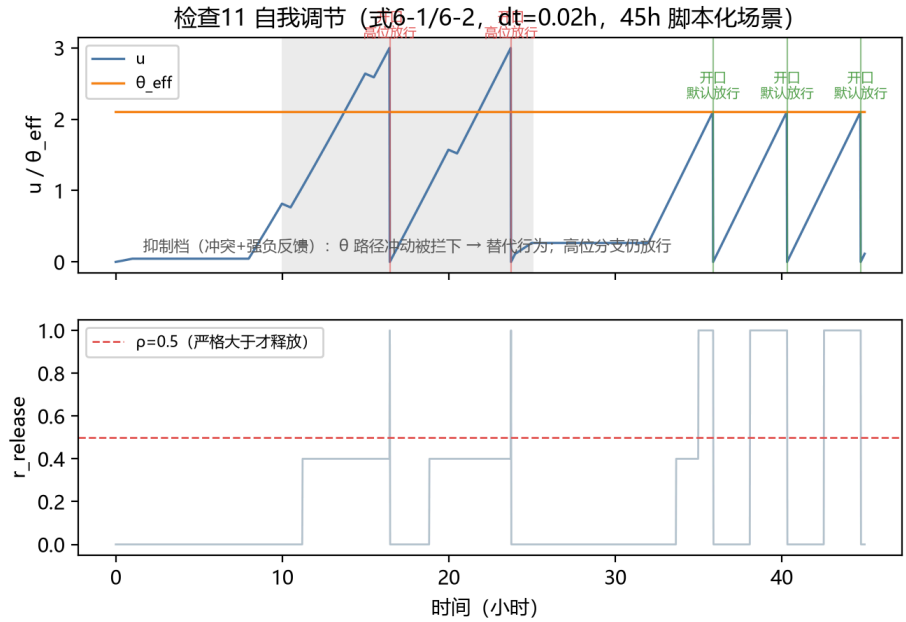


图 B-11 C11 自我调节：抑制期开口违规 0、替代行为 574 次（式 6-1/6-2）

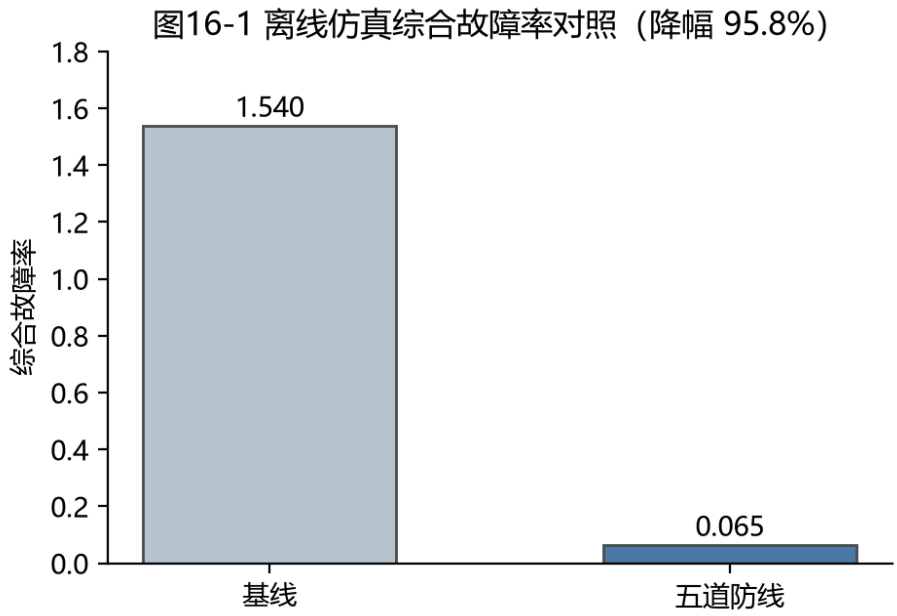


图 B-12 C12 综合故障率对照：1.540 → 0.065（降幅 95.8%）

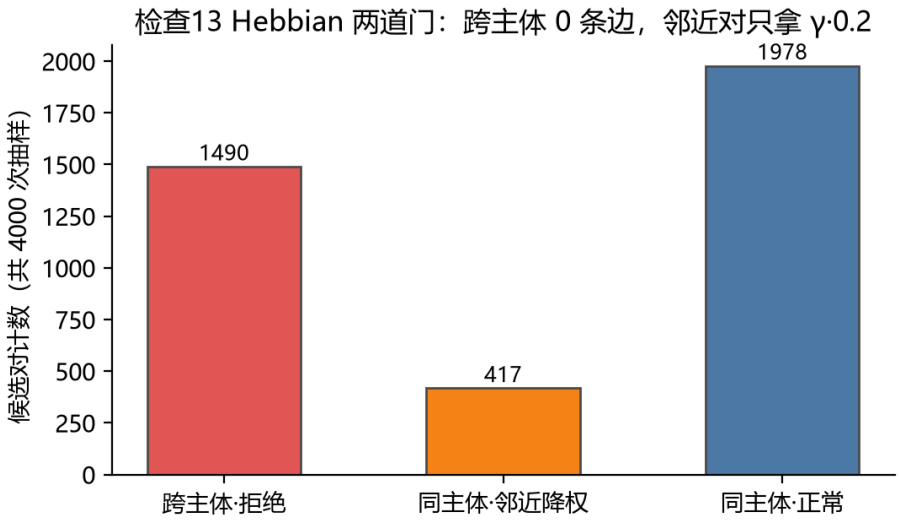


图 B-13 C13 Hebbian 两道门：4000 次抽样中跨主体边 0 条，同主体 24h 内只加 γ·0.2=0.012，远距对 0.06（式 5-6）

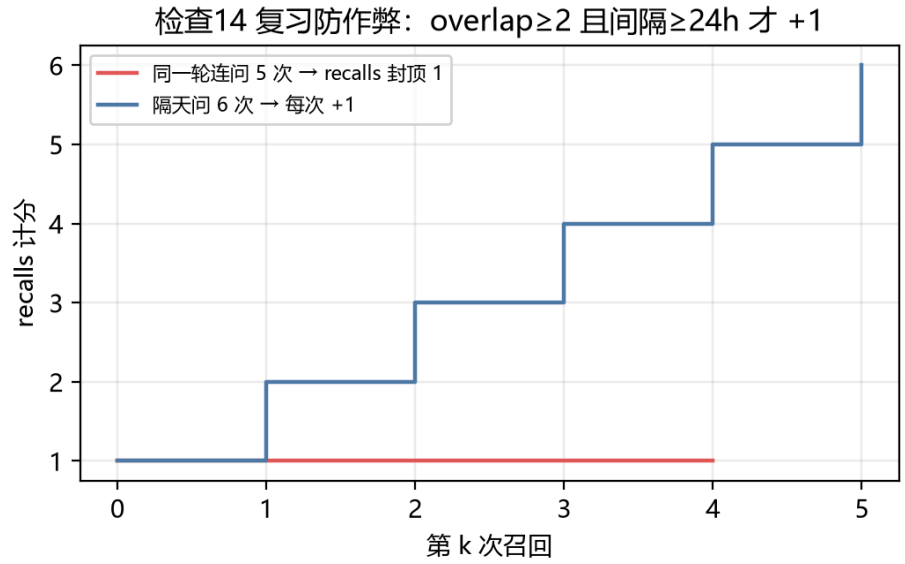


图 B-14 C14 复习防作弊：同一轮连问 5 次只计 1 次，隔天问 6 次计 6 次（式 5-8）

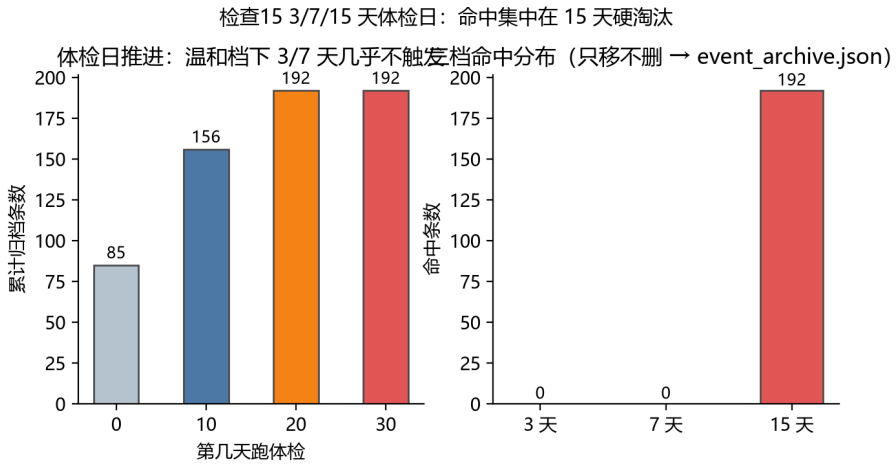


图 B-15 C15 体检日归档：400 条混合库推进 30 天，累计归档 85/156/192/192，三档命中 0/0/192，第 30 天在线 208（式 5-9）

B.3 仿真脚本结构

`sim/shihai_sim.py` 单文件约 1200 行，分五段：

（1）常量区：DIMS/TAU（式 4-1 时间常数）、KAPPA/ETA、LAMBDA_TYPE（图谱节点侧）、ALPHA_MEM/HALF_LIFE_DAYS/IMP_BETA/STAB_EMO_ALPHA/STAB_RECALL_BETA/STAB_RECALL_MAX（式 5-3~5-5）、GAMMA/THETA_ACT/W_MAX（式 5-6）、RECALL_MIN_OVERLAP/RECALL_MIN_GAP（式 5-8）、SWEEP_DAYS/SWEEP_R（式 5-9）、FIRE_THRESHOLD/URGE_CEILING/ GATE_MAX/STREAK_GATE_STEP（§7）、RHO/LOW_RATIO（§5.10.1），逐项注明对应 正文公式号；（2）解析函数：tau_eff、emo_rhs/emo_rk4（RK4 + 每级投影钳位）、 urge_rhs/urge_rk4、lambda_eff、alpha_from_half_life、stability、lam_mem、retention、half_life_h、timing_fit、mood_state；（3）MindSim 决策流仿真器：消息泊松流、图谱扩散与 Hebbian 离散映射（衰减项用精确指数 exp(−λ·Δt)）、开口后反馈回路（回复延迟 ~1.2h）、

五道防线开关（guards）、f1–f5 故障计数、替代行为 计数；（4）C01–C15 检查函数（C13 两道门、C14 复习计分、C15 体检日归档）， 每个返回 dict 并落盘 metrics.json；（5） run_all/main：汇总、绘图（matplotlib Agg、Microsoft YaHei）。

运行方式：`python sim/shihai_sim.py [--seed N]`；依赖仅 numpy 与 matplotlib。随机种子默认 20261110；所有随机流共用同一 MindSim 内 Generator，保证横向可比。

B.4 人格与记忆实现索引

正文方程与实现的对应关系（行号以 2026-11-10 版本为准）：

论文条目 *	*实现符号**	位置
式 4-1 情绪场	EmotionField.tau_eff/step	emotion.py:73/82
式 5-2 λ_v(e)	lambda_eff	emotion.py:108
式 5-3~5-5 保持率	FactItem.stability/ retention/decay_to	memory_v2.py:167/175/ 182
式 5-3~5-5 事件侧	EventItem.stability/ retention/decay_to	memory_v2.py:218/230/ 236
式 5-1 扩散	MemoryGraph.activate_and _spread	graph.py:342
式 5-6 Hebbian	MemoryGraph.hebbian	graph.py:423
式 5-6 门一/门二	_sender_of / _born_of	graph.py:458/463
图谱类型衰减	MemoryGraph.decay_step	graph.py:473
梦境修剪	MemoryGraph.dream	graph.py:491
式 7-1 念头累积	UrgeEngine.step	urge.py:75
§7.2 有效阈值	threshold_effective / should_fire	adapt.py:194 / urge.py:96
式 6-1/6-2 释放许可	EgoRegulator.release_ permission/decide	ego.py:85/120
§8 目标演化	goal_drift	goals.py:16
§9.1 慢参数	AdaptEngine.on_user_ message/on_silence/q_updat	adapt.py:66/164/184 e
§10.2 看门狗	MindEngine.tick	engine.py:245
§7.3 由头锚点	MindEngine._anchor_reason	engine.py:425
式 6-2 替代行为	MindEngine._ego_intervene	engine.py:325
§13.4 行动记忆	MindEngine.consume_fired	engine.py:490
记忆固结提示词（imp 字段）	_COMMIT_PROMPT	memory.py:67
imp 规则兜底	_mem_rule_imp	memory.py:431
峰值冻结	memory_watch	memory.py:224
异步固结（一次 LLM 产事件 +事实+imp）	_mem_commit	memory.py:327
召回格式化（豁免 通道）	_mem_format_recall	memory.py:725
记忆衰减常数 α	ALPHA_FACT_NORMAL/CORE/ EVENT（由半衰期 15/90/30 天反算）	memory_v2.py:52–54
式 5-4 重要度系数	IMP_BETA=2.0	memory_v2.py:76
式 5-4 情绪/复习项	STAB_EMO_ALPHA=2.0 / STAB_RECALL_BETA=1.5 / STAB_RECALL_MAX=12	memory_v2.py:83–85
式 5-8 复习两道闸	RECALL_MIN_OVERLAP=2 / RECALL_MIN_GAP=24h	memory_v2.py:89–90
式 5-9 体检日归档	EventBank.archive_stale	memory_v2.py:428
事实检索（+0.35·imp 排序）	FactBank.retrieve	memory_v2.py:366

论文条目 *	*实现符号**	位置
事件固结（imp 透传 E ）	ventBank.commit	memory_v2.py:504
召回与批量 boost	MemoryV2.recall	memory_v2.py:669
时序注入三档	_mem_tier_quota / _mem_timeline	memory.py:617/633
注入与相关性闸	memory_inject	memory.py:446

以上 13 个模块（表 18-1）全部通过 py_compile 静态编译；记忆链路修补 （imp 直用、默认 0.0、闸豁免、排序加权、批量落盘、分布日志）已在 2026-11-10 完成离线自检。